

西安交通大学

硕士学位论文

基于多模态时序感知数据的人体运动状态建模方法研究

学位申请人：邢立豹

指导教师：王飞 副教授

类别（领域）：工程硕士（软件工程）

2026 年 04 月

Research on Human Motion State Modeling Based on Multimodal Time-Series Sensor Data

A thesis submitted to
Xi'an Jiaotong University
in partial fulfillment of the requirements
for the degree of
Master of Engineering

By
Libao Xing
Supervisor: Associate Prof. Fei Wang
Master of Engineering (Software Engineering)
April 2026

硕士学位论文答辩委员会

基于多模态时序感知数据的人体运动状态建模方法研究

答辩人：邢立豹

答辩委员会委员：

西安交通大学教授：朱利 (注：主席)

西安交通大学副教授：徐亦飞

答辩时间：2026 年 05 月 06 日

答辩地点：西安交通大学创新港鸿理楼 4-3202

摘要

随着智能穿戴设备与人工智能技术的发展，基于非视觉传感器的人体运动状态建模已成为智能感知领域的重要研究方向。相较于传统视觉方法，非视觉感知具有隐私友好、部署灵活和环境适应性强等优势。其中，惯性测量单元（Inertial Measurement Unit, IMU）能够连续测量人体运动过程中的加速度与角速度等动力学信息，WiFi 信号中的信道状态信息（Channel State Information, CSI）能够反映人体运动对无线传播环境的扰动。然而，现有方法在多模态特征有效融合、跨受试者泛化以及未来状态预测等方面仍存在不足。针对上述问题，本文围绕人体活动识别与人体姿态重构两个任务展开研究，由活动语义识别进一步延伸至运动状态建模与预测。

在人体活动识别任务中，针对 IMU 与 WiFi CSI 在信号形式与特征分布上存在显著差异，导致多模态特征难以有效融合，以及跨受试者泛化能力不足的问题，本文提出一种基于多模态对齐与融合的人体活动识别方法 **WIHAR**。该方法首先利用双分支时序编码网络提取 IMU 与 WiFi CSI 的模态特征，在此基础上引入双向跨模态对比学习策略，通过构建批内跨模态相似度矩阵，将两种模态映射到统一语义空间，从而减小异构模态之间的表示偏差；随后通过交叉注意力机制实现模态间的细粒度特征交互，提升融合特征的判别能力。进一步地，针对跨受试者场景下模型性能下降的问题，本文设计了一种基于类别原型的跨受试者适配策略，通过源域类别原型引导目标域特征向共享语义空间聚合，从而提升模型对新受试者的适应能力。实验结果表明，在 **XRFBV2** 数据集上，**WIHAR** 的人体活动识别准确率达到 96.06%；在跨受试者设置下，通过少量目标受试者数据微调，模型平均准确率可由 72.57% 提升至 90.99%。

在人体姿态重构任务中，针对现有方法主要关注当前姿态重构、缺乏未来姿态预测能力的问题，本文提出一种基于自回归建模机制的人体姿态重构与预测方法 **AIPose**。该方法以 IMU 序列为输入，构建由 IMU 特征提取模块、姿态重构模块和 IMU 预测模块组成的统一建模框架：一方面利用当前 IMU 序列进行当前人体姿态重构；另一方面通过自回归方式预测未来 IMU 序列，并将预测结果用于后续姿态重构，从而实现未来姿态预测。通过联合建模 IMU 时序特征与姿态重构过程，**AIPose** 在保持当前姿态重构性能的同时实现了对未来姿态的预测能力。实验结果表明，**AIPose** 在 **XRFBV2** 数据集上的当前姿态重构平均关节位置误差为 47.82，未来姿态预测平均关节位置误差为 54.11。

关键词：活动识别；姿态重构；多模态融合；跨模态对齐；自回归建模

论文类型：应用研究

ABSTRACT

With the development of wearable devices and artificial intelligence, modeling human motion states based on non-visual sensors has become an important research direction in the field of intelligent perception. Compared with traditional vision-based approaches, non-visual sensing offers advantages in terms of privacy preservation, flexible deployment, and robustness to environmental conditions. Among these, Inertial Measurement Units (IMUs) can continuously measure dynamic information such as acceleration and angular velocity during human motion, while Channel State Information (CSI) from WiFi signals can capture the impact of human activities on the wireless propagation environment. However, existing methods still suffer from limitations in effective multimodal feature fusion, cross-subject generalization, and future state prediction. To address these challenges, this thesis focuses on two tasks, namely human activity recognition and human pose reconstruction, extending from activity-level semantic recognition to motion state modeling and prediction.

For the human activity recognition task, to address the significant differences in signal forms and feature distributions between IMU and WiFi CSI, which hinder effective multimodal fusion, as well as the limited cross-subject generalization ability, a multimodal alignment and fusion-based method, termed WIHAR, is proposed. Specifically, a dual-branch temporal encoding network is first employed to extract modality-specific features from IMU and WiFi CSI. Then, a bidirectional cross-modal contrastive learning strategy is introduced to map the two modalities into a shared semantic space by constructing a batch-wise cross-modal similarity matrix, thereby reducing the representation gap between heterogeneous modalities. Subsequently, a cross-attention mechanism is applied to enable fine-grained feature interaction across modalities, enhancing the discriminative capability of the fused representation. Furthermore, to mitigate performance degradation in cross-subject scenarios, a prototype-based cross-subject adaptation strategy is designed, where source-domain class prototypes guide target-domain features toward the shared semantic space, improving adaptability to unseen subjects. Experimental results show that WIHAR achieves an accuracy of 96.06% on the XRFV2 dataset. Under cross-subject settings, the average accuracy can be improved from 72.57% to 90.99% with a small amount of target-subject data for fine-tuning.

For the human pose reconstruction task, to overcome the limitation that existing methods mainly focus on current pose reconstruction while lacking the ability to predict future poses, an autoregressive modeling-based method, named AIPose, is proposed for both pose reconstruction and prediction. Taking IMU sequences as input, AIPose constructs a unified framework

consisting of an IMU feature extraction module, a pose reconstruction module, and an IMU prediction module. On the one hand, the current pose is reconstructed from the input IMU sequence; on the other hand, future IMU sequences are predicted in an autoregressive manner, and the predicted results are further utilized for subsequent pose reconstruction to achieve future pose prediction. By jointly modeling IMU temporal features and the pose reconstruction process, AIPose maintains the performance of current pose reconstruction while enabling future pose prediction. Experimental results demonstrate that, on the XRFV2 dataset, AIPose achieves a Mean Per Joint Position Error (MPJPE) of 47.82 for current pose reconstruction and 54.11 for future pose prediction.

KEY WORDS: Activity recognition; Pose reconstruction; Multimodal fusion; Cross-modal alignment; Autoregressive modeling

TYPE OF THESIS: Application Research

目 录

摘 要.....	I
ABSTRACT	III
1 绪论	1
1.1 选题意义与应用背景	1
1.2 国内外研究现状分析	2
1.2.1 人体活动识别方法研究现状.....	2
1.2.2 人体姿态重构方法研究现状.....	3
1.3 论文的主要研究内容	4
1.4 论文的组织结构	5
2 相关理论与技术.....	7
2.1 传感器	7
2.1.1 惯性测量单元.....	7
2.1.2 WiFi 信道状态信息.....	7
2.2 深度学习时序建模网络	8
2.2.1 Transformer.....	8
2.2.2 Mamba	9
2.3 多模态特征对齐与融合	11
2.3.1 对比学习.....	11
2.3.2 交叉注意力机制.....	13
2.4 自回归建模机制	14
2.5 本章小结	14
3 基于多模态对齐与融合的人体活动识别.....	15
3.1 问题描述	15
3.2 方法描述	16
3.2.1 整体方法框架.....	16
3.2.2 WIHAR 模型.....	16
3.2.3 基于类别原型的跨受试者适配策略.....	20
3.3 实验与结果分析	22
3.3.1 实验设置.....	22
3.3.2 评价指标.....	23
3.3.3 数据集与划分策略.....	24
3.3.4 方法对比实验.....	26
3.3.5 模型架构与训练策略实验.....	28

3.3.6 样本构建与数据处理实验.....	31
3.3.7 模态和传感器消融实验.....	33
3.3.8 跨受试者泛化实验.....	35
3.4 本章小结	37
4 基于自回归建模机制的人体姿态重构与预测	38
4.1 问题描述	38
4.2 方法描述	39
4.2.1 整体方法框架.....	39
4.2.2 AIPose 模型	40
4.3 实验与结果分析	43
4.3.1 实验设置.....	43
4.3.2 评价指标.....	43
4.3.3 数据集与样本构建.....	44
4.3.4 方法对比实验.....	47
4.3.5 骨干网络选择实验.....	48
4.3.6 样本构建与数据处理实验.....	49
4.3.7 传感器消融实验.....	50
4.3.8 泛化实验.....	52
4.3.9 长时姿态预测实验.....	54
4.4 本章小结	55
5 结论与展望	56
5.1 结论	56
5.2 展望	56
致谢.....	58
参考文献.....	59
攻读学位期间取得的研究成果.....	61
答辩委员会会议决议.....	62
常规评阅人名单.....	63
声明	

CONTENTS

ABSTRACT (Chinese).....	I
ABSTRACT (English)	III
1 Introduction	1
1.1 Research Significance and Application Background	1
1.2 Related Work.....	2
1.2.1 Research on Human Activity Recognition	2
1.2.2 Research on Human Pose Reconstruction	3
1.3 Main Research Content	4
1.4 Organization of the Thesis	5
2 Related Theories and Techniques	7
2.1 Sensors.....	7
2.1.1 Inertial Measurement Unit.....	7
2.1.2 WiFi Channel State Information	7
2.2 Deep Learning Sequence Modeling Networks	8
2.2.1 Transformer.....	8
2.2.2 Mamba	9
2.3 Multimodal Feature Alignment and Fusion.....	11
2.3.1 Contrastive Learning	11
2.3.2 Cross-Attention Mechanism	13
2.4 Autoregressive Modeling Mechanism	14
2.5 Summary	14
3 Human Activity Recognition Based on Multimodal Alignment and Fusion.....	15
3.1 Problem Description	15
3.2 Method Description	16
3.2.1 Overall Framework	16
3.2.2 WIHAR Model	16
3.2.3 Class-Prototype-Based Cross-Subject Adaptation Strategy	20
3.3 Experimental Results and Analysis	22
3.3.1 Experimental Settings	22
3.3.2 Evaluation Metrics.....	23
3.3.3 Dataset and Splitting Strategy	24
3.3.4 Method Comparison Experiments	26
3.3.5 Model Architecture and Training Strategy Experiments	28

3.3.6 Sample Construction and Data Processing Experiments	31
3.3.7 Modality and Sensor Ablation Experiments	33
3.3.8 Cross-subject Generalization Experiments	35
3.4 Summary	37
4 Autoregressive Human Pose Reconstruction and Prediction	38
4.1 Problem Description	38
4.2 Method Description	39
4.2.1 Overall Framework	39
4.2.2 AIPose Model	40
4.3 Experimental Results and Analysis	43
4.3.1 Experimental Settings	43
4.3.2 Evaluation Metrics	43
4.3.3 Dataset and Sample Construction	44
4.3.4 Method Comparison Experiments	47
4.3.5 Backbone Network Comparison Experiments	48
4.3.6 Sample Construction and Data Processing Experiments	49
4.3.7 Sensor Ablation Experiments	50
4.3.8 Generalization Experiments	52
4.3.9 Long-term Pose Prediction Experiments	54
4.4 Summary	55
5 Conclusions and Future Work	56
5.1 Conclusions	56
5.2 Future Work	56
Acknowledgements	58
References	59
Achievements	61
Decision of Defense Committee	62
General Reviewers List	63
Declarations	

1 绪论

1.1 选题意义与应用背景

人体行为感知是智能计算与人机交互领域的重要研究方向，其目标是通过传感设备获取人体运动信息，并对人体行为状态进行识别与理解。在智慧康养、智能家居、人机交互以及虚拟现实等应用场景中，系统需要实时获取人体活动信息或人体姿态信息，以支持行为监测、健康评估和交互控制等功能。因此，如何实现稳定、可靠的人体行为感知，已成为当前智能感知领域的重要研究问题。

传统的人体行为感知研究多依赖视觉传感器，如 RGB 摄像机或深度相机等。视觉方法在姿态重构和活动识别任务中取得了显著进展，但其应用仍受到隐私保护、光照条件以及环境遮挡等因素的限制。例如，在家庭、医疗或公共场所等场景中，持续使用摄像设备可能引发隐私问题；在弱光或复杂遮挡环境下，视觉方法的感知性能也可能明显下降。因此，近年来越来越多研究开始探索利用非视觉传感器实现人体行为感知。

在众多非视觉感知技术中，IMU 和 WiFi CSI 被广泛应用于人体活动识别和姿态重构任务。IMU 能够直接测量人体运动过程中的加速度和角速度信息，记录人体佩戴部位的运动状态，因此在人体活动识别和人体姿态重构任务中具有较高的应用价值。而基于 WiFi CSI 的感知方法则利用人体运动对无线信号传播环境产生的扰动，通过分析 WiFi CSI 来推断人体行为。与视觉传感器相比，这类感知方式具有隐私友好、设备成本低以及部署灵活等优势，在实际应用中具有较高的潜在价值。

尽管近年来相关研究取得了一定进展，但基于 IMU 与 WiFi CSI 的人体行为感知仍面临若干挑战。首先，IMU 与 WiFi CSI 在数据形式和物理特性上存在显著差异，两种模态之间的特征分布差异较大，导致多模态信息难以有效融合，从而影响识别性能。其次，在人体活动识别任务中，不同个体之间的运动习惯和执行方式存在差异，模型在跨受试者场景下往往出现性能下降的问题。此外，在人体姿态重构任务中，现有研究大多侧重于当前时刻的姿态重构，而缺乏对未来姿态的预测能力，这在实时交互或预测控制等应用场景中会限制系统的实际应用价值。

针对上述问题，本文围绕人体活动识别与人体姿态重构两个任务展开研究。在人体活动识别任务中，重点研究 IMU 与 WiFi CSI 之间的异构特征对齐与融合问题，并探索跨受试者场景下的少样本适配方法，以提升模型的泛化能力。在人体姿态重构任务中，重点研究通过引入自回归建模机制，在实现当前姿态重构的同时实现未来姿态预测。

1.2 国内外研究现状分析

1.2.1 人体活动识别方法研究现状

人体活动识别 (Human Activity Recognition, HAR) 旨在对人体的动作类别进行判别, 是智能感知、智慧康养、智能家居和人机交互中的基础研究问题。近年来, 随着可穿戴传感器、无线射频感知技术以及深度学习方法的发展, HAR 已逐渐从依赖视觉输入的场景扩展到面向隐私友好和长期部署需求的非视觉感知范式。

从感知模态来看, 现有 HAR 方法大致可以分为基于视觉的方法、基于可穿戴惯性传感器的方法、基于无线射频信号的方法, 以及面向多源信息协同的多模态方法。基于视觉的方法通常利用 RGB 视频、深度图像或人体关键点序列对动作演化过程进行建模, 在公开数据集上能够取得较高的识别精度。然而, 该类方法通常依赖稳定的成像条件, 对光照变化、视角偏移和人体遮挡较为敏感; 同时, 在家庭、卧室、康养等隐私敏感环境中, 持续部署摄像设备也存在明显局限。因此, 近年来越来越多研究开始关注非视觉 HAR 方法。

在非视觉 HAR 研究中, 基于可穿戴惯性传感器的方法是最重要的技术路线之一。IMU 能够直接测量人体局部运动产生的加速度和角速度信息, 因而对细粒度动作变化具有较强敏感性。随着深度学习在时序建模中的广泛应用, 研究者开始使用卷积网络、循环网络、Transformer 以及状态空间模型等结构对惯性时序数据进行建模, 从而提升活动识别性能。近年来, 相关研究进一步从纯监督识别拓展到自监督表征学习、轻量化部署和跨域泛化等方向。例如, Spatial-Temporal Masked Autoencoder 通过掩码重建任务学习多设备可穿戴数据的时空表示, 有效提升了下游活动识别任务的性能; HARMamba 将双向选择性状态空间模型引入可穿戴 HAR, 在长时序建模效率和识别精度之间取得了较好平衡, 表明新型时序骨干网络在该任务中具有较大潜力^[1-2]。

除可穿戴惯性传感器外, 基于无线射频信号的人体活动识别方法也受到持续关注。这类方法利用人体运动对无线传播环境造成的扰动, 通过分析 WiFi CSI 等射频信号中的幅值、相位或时频特征, 实现非接触式行为识别。与可穿戴方法相比, WiFi 感知无需用户主动佩戴设备, 具有隐私友好、成本较低和部署灵活等优点, 因此在智能家居、环境感知和被动监测等场景中具有较高应用潜力。然而, 无线信号在传播过程中易受多径效应、设备摆放方式及环境布局变化的影响, 导致模型的鲁棒性和跨场景泛化能力仍受到限制。

为了同时利用不同模态的互补优势, 近年来多模态 HAR 逐渐成为研究热点。相关工作表明, 视觉、IMU、音频、压力、射频等多源信号能够从不同角度刻画人体活动, 从而提升识别鲁棒性与语义完整性。例如, MMTSA 通过多模态时序分段注意力机制联合建模不同模态信息, 在识别性能、计算开销和部署效率之间实现了较好的折中, 说明多模态协同不仅能够提升精度, 也有助于满足实际系统对实时性和轻量化的要求^[3]。进一步地, 近年来多模态 HAR 已不再局限于简单的特征拼接, 而是越来越强调跨模态

共享表示学习、显式模态对齐以及更充分的跨模态交互。

除多模态融合外, 如何提升模型在真实部署条件下的泛化能力也是当前 HAR 研究的重要方向。由于不同用户、设备类型、佩戴位置和采集环境会导致数据分布发生明显变化, 跨数据集、跨场景和跨受试者泛化问题逐渐受到重视。例如, CrossHAR 面向跨数据集活动识别问题, 通过层次化自监督预训练增强模型对未见目标域的迁移能力; ContrastSense 则从域不变对比学习角度出发, 提升模型在真实复杂场景中的稳健性; 更进一步, MASTER 将研究视角拓展到多模态基础模型, 体现出 HAR 正从单任务识别逐步走向统一表征学习和可迁移预训练的新阶段^[4-6]。

综上所述, 现有研究在人体活动识别方面已经取得了较大进展, 但仍存在两方面不足: 其一, 多数多模态方法虽然证明了融合策略的有效性, 但对异构模态之间如何建立统一语义空间、如何在对齐后进一步实现细粒度交互仍缺乏深入研究; 其二, 尽管跨受试者和跨域泛化已成为研究热点, 但现有方法在新受试者少样本适配条件下的表现仍有待进一步提升。因此, 围绕 IMU 与 WiFi CSI 的异构双模态人体活动识别, 进一步研究跨模态特征对齐、跨模态深度融合以及跨受试者泛化方法, 具有明确的研究价值。这也构成了本文开展多模态人体活动识别研究的主要动机。

1.2.2 人体姿态重构方法研究现状

人体姿态重构旨在根据传感器采集的人体运动观测信息, 恢复人体关节位置、骨骼拓扑关系或连续运动轨迹, 在虚拟现实、人机交互、运动分析、康复评估等场景中具有重要应用价值。根据输入模态的不同, 现有方法主要包括基于视觉的方法和基于惯性传感器的方法。近年来, 随着可穿戴设备与深度学习技术的发展, 人体姿态重构研究正逐渐从依赖高质量视觉设备或高密度惯导配置的实验室方案, 转向面向消费级设备、稀疏传感器配置以及实时交互场景的实用化方向。

基于视觉传感器的人体姿态重构方法通常利用单目、双目或多目摄像机采集人体图像, 通过关键点检测、三维骨架回归或人体网格恢复等方法估计人体姿态。近年来, 视觉方法在三维人体姿态估计和动作理解任务中取得了显著进展。然而, 该类方法通常依赖稳定的成像条件, 在光照变化、视角遮挡和复杂背景下容易出现性能下降; 同时, 在家庭、医疗、办公等隐私敏感场景中, 持续部署摄像设备也存在较大限制。因此, 研究者开始探索基于非视觉信号的人体姿态建模方法。

在非视觉姿态建模中, 基于 IMU 的人体姿态重构是一条重要研究路线。IMU 能够连续测量人体运动过程中的加速度和角速度信息, 通过在人体关键部位布置若干惯性传感器, 可以获取人体运动的时序观测信号, 并进一步估计人体姿态。早期方法通常依赖运动学建模和骨骼约束, 通过对惯性信号进行解析实现姿态恢复, 但这类方法往往需要复杂的参数标定过程, 对传感器安装位置和人体模型假设较为敏感。随着深度学习的发展, 越来越多研究开始通过神经网络学习 IMU 信号与人体姿态之间的映射关系, 从而提升了姿态重构的精度与稳定性^[7-8]。

近三年来, 基于 IMU 的人体姿态重构研究呈现出三个显著趋势。第一, 研究对象

正从高密度专用惯导系统转向消费级设备与稀疏传感器配置。IMUPoser 探索了使用手机、手表和耳机中的低成本 IMU 进行全身姿态估计,说明由用户日常已有设备组成的稀疏传感系统具备支持全身姿态建模的可行性; MobilePoser 则进一步面向移动消费设备场景,实现了实时全身姿态估计与全局位移恢复,体现出该方向向实时交互系统持续靠近^[9-10]。

第二,姿态估计算法正从简单的时序回归逐步走向更强调动力学建模和结构建模的范式。DynaIP 通过部位级运动动力学学习增强了稀疏惯性条件下的人体姿态估计能力; Accurate and Steady Inertial Pose Estimation 则进一步说明,序列结构学习与调制机制对提升惯性姿态估计的精度和稳定性具有重要作用^[11-12]。这表明,仅仅依赖局部时序特征进行逐帧回归已难以充分刻画复杂人体运动过程中的动态约束关系。

第三,生成式建模方法开始进入稀疏 IMU 人体运动重构任务。DiffusionPoser 将自回归扩散机制引入任意稀疏传感器配置下的人体运动重构,在实时性与重构质量之间取得了较好的平衡,说明生成式建模在处理复杂运动分布、多解性以及稀疏观测条件方面具有良好潜力^[13]。这也意味着,人体姿态建模正在从确定性的当前姿态回归,逐渐走向同时考虑时序一致性、动态先验和分布建模能力的更统一框架。

另一方面,现有多数 IMU 姿态方法仍主要聚焦于当前时刻或给定历史窗口内的姿态恢复,即根据历史观测回归同步人体姿态结果。相比之下,对未来运动趋势的显式建模仍相对不足。然而,在虚拟现实、远程交互和运动预测等应用中,系统通常不仅需要恢复当前姿态,还需要在一定程度上预测未来人体运动状态,以降低系统延迟并提升交互连续性。近年来,人体运动预测研究开始从传统的确定性回归拓展到补全式建模和生成式建模。例如,HumanMAC 从 masked completion 的角度研究人体运动预测,说明未来运动建模已经开始强调多样性表达和全局时序一致性^[14]。这些研究为基于 IMU 的姿态重构与预测一体化建模提供了新的思路。

综上所述,现有基于 IMU 的人体姿态重构研究在重构精度、稀疏配置适应性以及实时性能方面已经取得了较大进展,但多数方法仍主要关注当前姿态恢复,对未来人体运动趋势缺乏显式建模。因此,进一步研究能够在统一框架下同时实现当前姿态重构与未来姿态预测的方法,具有重要的理论意义和应用价值。这也构成了本文研究基于 IMU 的人体姿态重构与预测方法的主要动机。

1.3 论文的主要研究内容

针对现有非视觉人体感知方法在多模态特征融合、跨受试者泛化以及未来姿态预测等方面存在的不足,本文围绕人体活动识别与人体姿态重构两个任务开展研究。

在人体活动识别任务中,本文重点研究 IMU 与 WiFi CSI 之间的多模态融合问题。由于两类传感数据在信号形式和物理特性上存在明显差异,直接进行特征融合往往难以获得理想的识别效果。为此,本文提出一种基于多模态对齐与融合的人体活动识别方法 WIHAR。该方法通过双向跨模态对比学习策略,在 IMU 到 WiFi CSI 与 WiFi CSI

到 IMU 两个方向上约束特征对齐，将 IMU 的运动动力学特征与 WiFi CSI 的射频感知特征映射到统一的语义空间。在此基础上，引入交叉注意力机制对两种模态特征进行深度交互，以提升多模态信息融合能力。此外，针对人体活动识别任务中普遍存在的跨受试者性能下降问题，本文进一步设计了一种基于类别原型的跨受试者适配策略，通过利用源域训练阶段学习得到的类别原型对目标受试者特征施加类别语义约束，并结合参数高效微调机制，实现对新受试者的快速适配，从而缓解不同个体之间的特征分布差异，提高模型在跨受试者场景下的泛化能力。

在人体姿态重构任务中，本文关注基于 IMU 信号的人体姿态重构与预测问题。现有基于惯性传感器的人体姿态重构方法通常以当前姿态重构为主要目标，对人体运动的未来姿态缺乏建模能力。针对这一问题，本文提出一种基于自回归建模机制的人体姿态重构与预测方法 AIPose。该方法仅利用 IMU 信号作为输入，通过构建由 IMU 特征提取模块、姿态重构模块和 IMU 预测模块组成的闭环结构，实现人体姿态重构与 IMU 信号预测的协同建模。具体而言，模型通过对历史 IMU 序列进行时序建模预测未来 IMU 信号，并将预测结果反馈至 IMU 特征提取模块，进一步输入至姿态重构模块，从而在实现当前姿态重构的同时获得未来姿态变化的预测能力。该方法能够在保持姿态重构精度的基础上增强模型对人体运动时序变化的建模能力，从而为实时交互和动态应用场景提供支持。

通过上述研究，本文从多模态特征融合与人体运动时序建模两个方面对非视觉人体感知问题进行了探索，为基于可穿戴传感器和无线信号的人体行为理解提供了一种可行的技术方案。

1.4 论文的组织结构

本文共分为五章，各章节的主要内容如下。

第一章，绪论。本章首先介绍论文的选题意义与应用背景，分析人体活动识别与人体姿态重构领域的国内外研究现状，在此基础上明确本文的研究目标与主要研究内容，并对论文的整体结构进行说明。

第二章，相关理论与技术。本章主要介绍本文研究所涉及的基础理论与关键技术，包括 IMU 和 WiFi CSI 两类传感器的工作原理，以及 Transformer^[15]和 Mamba^[16]两种深度学习网络。随后介绍多模态特征对齐与融合的相关方法，包括对比学习和交叉注意力机制。最后介绍自回归建模机制，为后续章节的方法设计与实验分析提供理论基础。

第三章，基于多模态对齐与融合的人体活动识别。本章首先对人体活动识别研究问题进行描述，并介绍实验数据集的构建方式；随后对人体活动识别方法的整体流程进行说明，并对 WIHAR 模型的整体结构及其关键模块进行详细介绍；最后通过实验对所提出方法进行全面评估。

第四章，基于自回归建模机制的人体姿态重构与预测。本章首先对人体姿态重构研究问题进行描述，并介绍实验数据集的构建方式；随后对人体姿态重构与预测方法

的整体流程进行说明，并对 AIPose 模型的整体结构及其关键机制进行详细介绍；最后通过实验对所提出方法进行全面评估。

第五章，结论与展望。本章对本文的研究工作进行总结，归纳本文在人体活动识别以及人体姿态重构与预测方面的主要研究成果，并在此基础上分析研究中存在的不足，对未来可能的研究方向进行展望。

2 相关理论与技术

本章介绍本文研究涉及的相关理论与关键技术，为后续方法设计提供必要的理论支撑。首先介绍 IMU 与 WiFi CSI 两类传感器的基本感知原理。随后介绍 Transformer 与 Mamba 两种时序建模网络。在此基础上，进一步介绍多模态特征对齐与融合方法，包括对比学习与交叉注意力机制。最后介绍自回归建模机制的基本思想，为后续人体姿态重构与预测方法奠定基础。

2.1 传感器

2.1.1 惯性测量单元

IMU 是人体运动感知中最常用的可穿戴传感器之一，通常由三轴加速度计和三轴陀螺仪构成，用于测量载体在三维空间中的线性加速度与角速度信息。相较于视觉传感器，IMU 主要刻画人体局部运动状态，对遮挡及环境光照变化具有较强的鲁棒性。然而，其感知能力受限于传感器的佩戴位置，同时在跨受试者泛化、佩戴偏差以及长期积分漂移等方面仍面临一定挑战。目前，IMU 已广泛应用于人体活动识别、步态分析、运动评估以及人体姿态重构等任务中^[17-19]。

在加速度测量方面，加速度计输出的是载体坐标系下的比力，即线性加速度与重力加速度共同作用的结果。设时刻 t 的加速度计观测值为 a_t ，其测量模型可表示为：

$$a_t = C_n^b(a_n - g_n) + b_a + n_a \quad (2-1)$$

其中， C_n^b 表示从导航坐标系到载体坐标系的旋转矩阵， a_n 为人体肢体在世界坐标系下的线性加速度， g_n 为重力加速度向量， b_a 为加速度计零偏误差， n_a 为测量噪声。

陀螺仪用于测量载体的角速度信息，其观测模型可表示为：

$$\omega_t = \omega_t^{\text{true}} + b_g + n_g \quad (2-2)$$

其中， ω_t^{true} 为时刻 t 的真实角速度， b_g 为陀螺仪零偏误差， n_g 为测量噪声。角速度信号能够刻画人体肢体在运动过程中的旋转动态变化，与加速度信息相结合，可以更全面地表征人体运动的时序特征。

2.1.2 WiFi 信道状态信息

WiFi 感知通过分析无线信号在传播过程中受到人体运动扰动而产生的信道变化，实现对人体行为的非接触式感知，具有部署成本低、环境适应性强等优势^[20-21]。现代 WiFi 系统通常采用正交频分复用（Orthogonal Frequency Division Multiplexing, OFDM）技术进行数据传输。在 OFDM 系统中，高速数据流被划分为多个子载波并行传输，从

而能够有效应对复杂无线信道带来的频率选择性衰落。WiFi CSI 是物理层对无线信号在发射端与接收端之间传播特性的细粒度刻画，用于描述不同子载波上的信道频率响应。对于第 k 个子载波，接收信号 Y_k 与发送信号 X_k 之间的关系可以表示为：

$$Y_k = H_k X_k + N_k \quad (2-3)$$

其中， H_k 为该子载波上的复数信道增益，即 CSI； N_k 为高斯白噪声。

WiFi CSI 通常以复数形式表示，可以分解为幅度和相位：

$$H_k = |H_k| e^{j\angle H_k} \quad (2-4)$$

其中，幅度 $|H_k|$ 表示信号在该子载波上的能量衰减，相位 $\angle H_k$ 则反映了传播时延与路径变化等信息。与仅提供粗粒度接收功率信息的接收信号强度指示相比，WiFi CSI 能够提供更细粒度的子载波级信道信息，因此更适合用于人体活动识别、定位和环境感知等任务^[20-21]。需要指出的是，实际采集到的相位信息通常会受到硬件时钟偏移和载波频偏等因素的影响，因此往往需要经过预处理或校准后才能稳定用于建模。

在室内环境中，无线信号通常通过多条路径传播，包括来自墙壁、地面、家具以及人体的反射路径。根据多径传播模型，时变信道频率响应可以表示为：

$$H(f, t) = \sum_{p=1}^P \alpha_p(t) e^{-j2\pi f \tau_p(t)} \quad (2-5)$$

其中， P 表示传播路径数量， $\alpha_p(t)$ 为第 p 条路径的衰减系数， $\tau_p(t)$ 为对应的传播时延。当人体在 WiFi 覆盖区域内运动时，会改变部分传播路径的长度和反射特性，从而引起 $\alpha_p(t)$ 与 $\tau_p(t)$ 的变化。这种变化会进一步反映在 WiFi CSI 幅度和相位的时序波动中，使得 WiFi CSI 能够表征人体运动对无线传播环境造成的扰动。

因此，通过对 WiFi CSI 序列进行时序建模，可以从无线信号变化中提取与人体运动相关的判别特征。但基于 WiFi CSI 的方法的性能通常会受到环境布局、设备部署方式以及数据划分策略的影响，尤其在跨场景或跨受试者设置下，对模型泛化能力提出了更高要求^[20]。

2.2 深度学习时序建模网络

2.2.1 Transformer

Transformer 是当前序列建模中最具代表性的网络结构之一，其核心思想是利用自注意力机制直接建模序列中任意位置之间的依赖关系，而不依赖循环结构进行逐步状态传递^[15]。相比循环神经网络 (RNN) 或长短期记忆网络 (LSTM)，Transformer 更易于并行计算，并且在长距离依赖建模方面具有明显优势，因此已被广泛用于自然语言

处理、语音、视觉以及多种时序建模任务中。

Transformer 的核心计算单元为缩放点积注意力。给定输入序列的特征表示，模型首先通过线性映射将其转换为查询向量 (Query, Q)、键向量 (Key, K) 和值向量 (Value, V)。注意力输出可以表示为：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2-6)$$

其中， d_k 为键向量的维度，缩放因子 $\sqrt{d_k}$ 用于缓解点积过大带来的训练不稳定问题。该过程通过计算序列中不同位置之间的相似度，自适应地聚合全局上下文信息。

为了增强模型对不同表示子空间的建模能力，Transformer 进一步引入多头注意力机制。其计算形式如下：

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O \quad (2-7)$$

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V) \quad (2-8)$$

其中， W_i^Q 、 W_i^K 、 W_i^V 和 W^O 为可学习参数矩阵。多头注意力使模型能够在不同特征子空间中并行捕捉序列内部的相关性，从而提升表示能力。

由于自注意力机制本身不显式包含顺序信息，因此 Transformer 通常通过位置编码引入时序位置信息。常用的正弦—余弦位置编码形式如下：

$$PE_{(pos, 2i)} = \sin(pos/10000^{2i/d_{model}}) \quad (2-9)$$

$$PE_{(pos, 2i+1)} = \cos(pos/10000^{2i/d_{model}}) \quad (2-10)$$

通过将位置编码与输入特征相加，模型能够感知时间顺序，从而实现对时序数据的有效建模。

Transformer 模型结构如图2-1 (a) 所示。对于人体感知任务，Transformer 能够较好地建模较长时间范围内的动作演化过程，尤其适用于需要捕获全局时间依赖关系的场景。然而，自注意力机制的时间和空间复杂度通常随序列长度呈二次增长，因此当输入为高采样率、多传感器的长时序数据时，其计算成本和显存开销可能较高^[15-16,22]。

2.2.2 Mamba

尽管 Transformer 在长序列建模中表现出较强能力，但其自注意力计算复杂度通常随序列长度呈二次增长，这在处理高采样率传感器产生的长时序数据时会带来较高的计算与存储开销。为提高长序列建模效率，近年来基于状态空间模型 (State Space Model, SSM) 的序列建模方法受到广泛关注，其中 Mamba 是一类具有代表性的选择性状态空间结构^[16,22]。




图 2-1 Transformer 与 Mamba 时序建模结构示意图

状态空间模型通过引入隐状态描述输入序列的动态演化过程。在离散时间形式下，其基本表达形式为：

$$h_t = Ah_{t-1} + Bx_t \quad (2-11)$$

$$y_t = Ch_t \quad (2-12)$$

其中， x_t 表示输入序列， h_t 表示系统隐状态， y_t 为输出序列， A 、 B 和 C 为模型参数矩阵。通过递归更新隐状态，状态空间模型能够在较低复杂度下建模较长范围的时间依赖。

传统 SSM 通常采用固定参数进行状态更新，这会限制模型对复杂输入模式的适应能力。**Mamba** 通过引入选择性机制，使部分状态更新参数能够随输入动态变化，从而根据当前输入内容选择性地保留、更新或遗忘历史信息^[16]。这一设计使其在保持线性时间复杂度的同时，增强了对内容相关信息的建模能力。

与基于自注意力的模型相比，**Mamba** 在处理长序列时通常具有更高的效率，并能够在较低开销下维持较强的长依赖建模能力。进一步地，近期工作从结构状态空间对偶的角度分析了 Transformer 与 SSM 之间的联系，并提出了更高效的 **Mamba-2** 结构，说明该类方法在长序列建模中具有较好的发展潜力^[22]。

Mamba 模型结构如图2-1 (b) 所示。对于人体活动识别这类长时序传感器建模任务, Mamba 能够在兼顾建模能力与计算效率的前提下提取序列特征, 因此适合作为多模态人体活动识别中的时序编码模块之一。

2.3 多模态特征对齐与融合

在人体感知任务中, 不同类型的传感器通常从不同角度反映人体运动信息。例如, IMU 能够直接记录人体肢体运动过程中的加速度和角速度变化, 反映人体运动的局部动力学特征; 而基于 WiFi CSI 的感知方法则通过分析 CSI 的变化, 捕捉人体运动对无线传播环境产生的扰动, 从而获得环境层面的感知信息。相比单一模态传感器, 多模态传感数据能够从不同维度描述人体行为状态, 为人体活动识别任务提供更丰富的信息来源^[23]。

然而, 不同模态传感数据在物理属性、数据分布以及特征表达方式上通常存在明显差异, 直接进行特征拼接或简单融合往往难以充分利用多模态信息。一方面, 模态之间的分布差异可能导致特征空间不一致, 从而影响模型的表征能力; 另一方面, 不同模态所包含的信息具有互补性, 如果能够有效建立模态之间的关联关系, 则有助于提升模型对人体行为的表达能力。

因此, 在多模态人体活动识别任务中, 通常需要同时解决模态对齐与模态融合两个问题。模态对齐旨在将来自不同传感器的特征映射到统一的语义空间, 从而减少模态之间的分布差异, 使模型能够学习到更稳定的共享表示; 模态融合则通过建立不同模态特征之间的交互关系, 充分利用各模态所包含的互补信息, 从而提升模型的整体感知能力。基于这一思路, 本节将介绍实现多模态特征对齐与融合的相关方法, 包括用于学习跨模态共享表示的对比学习, 以及用于建模模态间特征交互关系的交叉注意力机制。

2.3.1 对比学习

在人体活动识别任务中, IMU 主要表征人体局部运动产生的动力学变化, 而 WiFi CSI 刻画的是人体运动对无线传播环境所引起的信道扰动。由于两种模态在感知机理、采样形式及统计分布上存在显著差异, 若直接进行特征融合, 容易导致模态间语义不一致, 从而影响融合表示的判别能力。因此, 在多模态特征融合之前, 有必要先对不同模态的特征进行语义对齐, 以减小异构模态之间的表示偏差。

针对上述问题, 对比学习为跨模态特征对齐提供了一种有效途径。其核心思想是通过拉近正样本对之间的距离、拉远负样本对之间的距离, 从而学习具有判别性的特征表示。该机制已被广泛应用于跨模态表示学习, 并在构建共享语义空间方面表现出良好效果^[24-25]。在本文场景中, 来自同一时间窗口且语义一致的 IMU 片段与 WiFi CSI 片段构成跨模态正样本对, 而来自不同样本或不同动作片段的跨模态组合则作为负样本对。其基本原理如图 2-2所示: 通过对批内样本两两计算相似度, 使语义对应的样本对在相似度矩阵中具有更高响应, 而不匹配样本对则保持较低相似度。




图 2-2 对比学习原理示意图

在具体实现上，设 IMU 模态输入为 x_i^I ，WiFi CSI 模态输入为 x_i^W ，其中 i 表示第 i 个样本。经过各自编码网络后，可得到对应的特征表示：

$$u_i = f_{IMU}(x_i^I), \quad v_i = f_{WiFi}(x_i^W) \quad (2-13)$$

其中， $f_{IMU}(\cdot)$ 和 $f_{WiFi}(\cdot)$ 分别表示 IMU 模态与 WiFi CSI 模态的特征提取函数。为保证相似度计算的稳定性，通常对特征向量进行归一化处理，使其分布于单位超球面上。

基于上述特征表示，可以构建跨模态相似度度量。对于 IMU 样本 i 与 WiFi CSI 样本 j ，其余弦相似度定义为：

$$S_{ij} = \frac{u_i^T v_j}{\|u_i\| \|v_j\|} \quad (2-14)$$

在一个包含 N 个样本的训练批次中，进一步构建 IMU 特征与 WiFi CSI 特征之间的相似度矩阵 $S \in \mathbb{R}^{N \times N}$ 。其中，对角线元素对应语义匹配的正样本对，非对角线元素对应不匹配的负样本对。基于该相似度结构，本文采用双向跨模态对比学习 (Bidirectional Cross-Modal Contrastive Learning, BCMCL) 损失对模型进行优化，可同时约束两个模态方向上的对齐关系。

对于 IMU 到 WiFi 方向，其损失定义为：

$$L_i^{I \rightarrow W} = -\log \frac{\exp(S_{ii}/\tau)}{\sum_{k=1}^N \exp(S_{ik}/\tau)} \quad (2-15)$$

其中， τ 为温度系数，用于调节相似度分布的平滑程度。

类似地，WiFi CSI 到 IMU 方向的损失可表示为：

$$L_i^{W \rightarrow I} = -\log \frac{\exp(S_{ii}/\tau)}{\sum_{k=1}^N \exp(S_{ki}/\tau)} \quad (2-16)$$

最终，对比学习损失由两个方向的损失共同构成：

$$L_{\text{BCMCL}} = \frac{1}{2N} \sum_{i=1}^N \left(L_i^{I \rightarrow W} + L_i^{W \rightarrow I} \right) \quad (2-17)$$

通过最小化上述损失，模型能够将语义一致的 IMU 与 WiFi CSI 样本映射到相邻的特征区域，同时拉开不匹配样本之间的距离，从而实现跨模态特征对齐。经过该约束后，不同模态的特征表示在共享语义空间中具有更高一致性，为后续跨模态特征融合与人体活动识别提供了更加稳定且具有判别性的表示基础^[24-25]。

2.3.2 交叉注意力机制

尽管对比学习能够将 IMU 与 WiFi CSI 特征对齐到统一的语义空间，但该过程主要关注整体表示的一致性，并未显式刻画不同模态之间的细粒度交互关系。在人体活动识别任务中，IMU 信号主要反映人体局部的动力学变化，而 WiFi CSI 则侧重刻画人体运动对空间传播环境所产生的整体扰动，两种模态在信息表达上具有显著的互补性。因此，在完成模态特征对齐之后，仍有必要进一步引入跨模态交互机制，以充分挖掘不同模态之间的关联信息，从而实现更有效的特征融合^[23]。

交叉注意力机制（Cross-Attention Mechanism）是一类常见的多模态特征融合方法，其基本思想是利用一个模态的特征作为查询（Query），从另一模态的特征中检索与之最相关的信息。与自注意力机制不同，交叉注意力中的查询向量与键值向量来自不同模态，因此能够显式建立模态间依赖关系。设经过编码网络提取后的 IMU 特征序列为 $X_I \in \mathbb{R}^{L_I \times d}$ ，WiFi CSI 特征序列为 $X_W \in \mathbb{R}^{L_W \times d}$ ，其中 L_I 与 L_W 分别表示两个模态的序列长度， d 表示特征维度。首先通过线性映射生成查询、键和值向量：

$$Q_I = X_I W_Q, \quad K_W = X_W W_K, \quad V_W = X_W W_V \quad (2-18)$$

其中， W_Q 、 W_K 和 W_V 为可学习的线性映射矩阵。

随后，通过缩放点积注意力计算 IMU 特征对 WiFi CSI 特征的关注程度：

$$O_{I \leftarrow W} = \text{softmax} \left(\frac{Q_I K_W^T}{\sqrt{d_k}} \right) V_W \quad (2-19)$$

其中， d_k 表示键向量的维度。该过程通过相似度矩阵刻画 IMU 时间步与 WiFi CSI 时间步之间的相关性，再利用注意力权重对 WiFi CSI 特征进行加权汇聚，从而得到融合后的表示 $O_{I \leftarrow W}$ 。

通过该机制，模型能够根据一个模态的当前特征状态，从另一模态中自适应选择最有助于判别的信息。在实际应用中，也可以进一步构建反向注意力，即利用 WiFi CSI 特征作为查询，从 IMU 特征中获取相关信息，从而形成双向跨模态交互结构。相比简

单拼接，交叉注意力更有利于捕捉模态间的局部对应关系与互补模式，因此在多模态融合任务中得到了广泛应用^[23]。

2.4 自回归建模机制

在时序数据建模任务中，数据在时间维度上通常具有显著的依赖关系，即当前时刻的状态往往由历史状态所决定。人体运动序列同样具有这一连续性特征，例如在行走、转身或摆臂等动作中，人体关节的运动轨迹在相邻时间步之间通常呈现出较强的相关性。因此，在人体运动建模过程中，可以充分利用历史状态对未来状态进行推断。

自回归建模机制是一种经典的时序建模方法，其核心思想是利用历史观测序列对当前或未来状态进行预测。在实际应用中，若直接使用完整历史序列作为输入，将带来较高的计算开销，并且随着序列长度增加，模型的推理效率会显著下降。为此，通常引入长度为 L 的固定滑动窗口，仅利用最近的历史信息进行建模，在保证时序依赖建模能力的同时有效控制计算复杂度，即：

$$x_t = f(x_{t-L}, x_{t-L+1}, \dots, x_{t-1}) \quad (2-20)$$

其中， $f(\cdot)$ 表示时间依赖关系的建模函数。

在序列生成阶段，自回归模型通过递归方式逐步预测未来序列。在给定初始历史窗口 $\{x_{t-L}, \dots, x_t\}$ 的条件下，首先预测下一时刻状态：

$$\hat{x}_{t+1} = f_\theta(x_{t-L+1}, \dots, x_t) \quad (2-21)$$

随后，将预测结果纳入输入窗口并移除最早的历史元素，形成新的长度为 L 的输入序列，从而继续预测后续状态：

$$\hat{x}_{t+k} = f_\theta(\hat{x}_{t+k-L}, \dots, \hat{x}_{t+k-1}) \quad (2-22)$$

该基于滑动窗口的递归预测机制使得模型在生成新序列元素时无需重复输入完整历史数据，从而显著提升推理效率并降低存储开销，同时保证了时序建模的连续性。

2.5 本章小结

本章围绕本文方法设计涉及的关键理论与技术展开介绍。首先，阐述了 IMU 与 WiFi CSI 两类传感器的基本感知原理，并分析了二者在人体行为感知中的信息特点与互补性。随后，介绍了 Transformer 与 Mamba 两类时序建模网络。在此基础上，进一步介绍了多模态特征对齐与融合方法，包括对比学习和交叉注意力机制，为后续人体活动识别模型的设计提供理论支撑。最后，介绍了自回归建模机制的基本思想，为后续人体姿态重构与预测方法提供建模依据。

3 基于多模态对齐与融合的人体活动识别

本章围绕复杂室内环境下的多模态人体活动识别问题展开。第 3.1 节分析联合使用 IMU 与 WiFi CSI 进行建模的必要性；第 3.2 节介绍实验数据集及其构建过程，包括数据采集硬件、场景设置与样本构建方法；第 3.3 节详细说明本文提出的 WIHAR 方法，重点介绍双分支时序编码、跨模态特征对齐、跨模态特征融合以及分类模块；第 3.4 节给出实验设置与结果分析，从整体性能、方法对比、结构设计、模态贡献、关键模块消融以及跨受试者泛化等角度验证所提方法的有效性；第 3.5 节对本章工作进行总结。

3.1 问题描述

人体活动识别 (Human Activity Recognition, HAR) 是智能感知中的基础任务，在智慧医疗、养老监护、安防监控和智能家居等场景中具有重要应用价值。近年来，随着可穿戴传感器、无线感知技术以及深度学习方法的发展，HAR 在识别精度和应用范围上均取得了明显进展。然而，在真实室内环境中构建兼具准确性、鲁棒性和可部署性的人体活动识别系统，仍然面临若干挑战。

首先，视觉感知方法在光照充足且遮挡较少的条件下通常能够取得较好的识别效果，但其性能高度依赖成像质量与视角条件。在夜间、弱光或存在遮挡的环境中，人体外观特征和关键点信息容易退化，从而影响识别稳定性。同时，持续视频采集还会带来较为突出的隐私问题，因此在卧室、书房等敏感场景中受到一定限制。相比之下，非视觉感知方式在隐私保护和环境适应性方面更具优势，因而逐渐成为人体活动识别研究的重要方向。

其次，单一非视觉模态虽然规避了视觉感知方案的部分问题，但仍存在各自的局限性。IMU 能够直接采集人体局部运动产生的加速度与角速度信息，对细粒度动作变化较为敏感，但其感知范围受佩戴位置限制，对环境信息的刻画较弱；此外，低成本 MEMS 器件在长期采集中还可能受到零偏漂移和佩戴偏差的影响。WiFi CSI 则通过刻画人体运动引起的无线传播变化实现非接触感知，具有覆盖范围较大、部署灵活等优点，但其特征分布容易受到环境布局、多径传播和传感器部署方式变化的影响。因此，IMU 与 WiFi CSI 模态在感知机理、数据分布和优势信息上具有明显差异，若仅采用简单拼接，往往难以充分利用两种模态之间的互补性。

针对上述问题，本文提出一种基于多模态对齐与融合的人体活动识别方法 WIHAR。该方法利用 IMU 与 WiFi CSI 在感知机理上的互补性，首先通过双分支时序编码器分别提取两种模态的时序特征，再通过双向跨模态对比学习在 IMU 到 WiFi CSI 与 WiFi CSI 到 IMU 两个方向上约束特征对齐，然后通过交叉注意力实现模态间信息交互，最终完成人体活动识别。

3.2 方法描述

3.2.1 整体方法框架

为充分利用 IMU 与 WiFi CSI 在人体活动识别中的互补信息，本文提出一种基于多模态对齐与融合的人体活动识别方法 WIHAR。该方法以同步采集的 IMU 与 WiFi CSI 时序数据为输入，通过特征编码、跨模态语义对齐以及多模态特征融合，实现对人体活动的准确识别。整体框架如图 3-1 所示。




图 3-1 WIHAR 方法整体流程图

模型输入样本按照第 3.2.2 节所述的样本构建策略构建，其中 IMU 与 WiFi CSI 数据在时间维度上保持同步，并作为多模态输入送入特征提取网络。

在特征编码阶段，两种模态数据分别输入独立的 Mamba 编码器，以提取各自的时序特征表示。考虑到 IMU 与 WiFi CSI 在感知机理和统计特性上的差异，模型在训练过程中引入双向跨模态对比学习约束，在 IMU 到 WiFi CSI 与 WiFi CSI 到 IMU 两个方向上约束同一样本的模态特征对齐，从而增强不同模态表示之间的语义一致性。在此基础上，通过交叉注意力机制建模模态间的细粒度交互关系，以获得更加充分的多模态融合特征。

在分类阶段，模型在融合特征上构建人体活动识别分类头。模型的总体损失函数由人体活动分类损失与双向跨模态对比学习损失共同组成，其具体定义见第 3.3.2.5 节。

3.2.2 WIHAR 模型

在上一节介绍整体方法框架的基础上，本节进一步讲解 WIHAR 模型的具体实现。模型整体架构如图 3-2 所示，主要包括时序特征提取、跨模态特征对齐、跨模态特征融合以及分类模块四个部分。下面分别介绍各模块的结构与实现方法。




图 3-2 WIHAR 模型架构图

1) Mamba 时序特征提取

IMU 与 WiFi CSI 均属于时序信号，因此需要通过时序建模方法提取其中的时序特征。本文采用 Mamba 序列模型作为时序特征提取器，对两种模态的输入序列分别进行编码。

设 IMU 和 WiFi CSI 模态的输入序列分别为

$$X_I \in \mathbb{R}^{B \times T \times C_I}, \quad X_W \in \mathbb{R}^{B \times T \times C_W}, \quad (3-1)$$

其中， B 表示批大小， T 表示时间序列长度， C_I 与 C_W 分别表示 IMU 与 WiFi CSI 信号的特征维度。

在模型中，两种模态分别通过独立的 Mamba 编码器进行时序特征提取：

$$F_I = E_I(X_I), \quad F_W = E_W(X_W), \quad (3-2)$$

其中， $E_I(\cdot)$ 与 $E_W(\cdot)$ 表示对应模态的 Mamba 编码器。经过编码后，可获得两种模态的高层时序特征表示：

$$F_I, F_W \in \mathbb{R}^{B \times T \times D}, \quad (3-3)$$

其中， D 表示特征维度。

在实现过程中，Mamba 编码器由输入线性映射层与多层 Mamba 序列建模模块构成。输入序列首先通过线性映射投影至统一的特征空间，然后通过多层 Mamba 结构对时间序列进行动态建模，从而获得包含长期时序依赖信息的特征表示。为了保留完整的时间结构信息，本文在该阶段不对时序特征进行时间池化，而是保留完整的时间维度特征表示，供后续跨模态对齐与融合模块使用。

2) 跨模态特征对齐

如第 2.3 节所述，对比学习能够在共享语义空间中实现跨模态特征对齐。基于该思想，本文在 WIHAR 模型中引入双向跨模态对比学习 (Bidirectional Cross-Modal Contrastive Learning, BCMCL) 约束，以减小 IMU 与 WiFi CSI 特征之间的分布偏差。与第二章对跨模态对齐原理的通用描述不同，本文在特征层进行对齐：首先利用 Mamba 编码器分别提取 IMU 与 WiFi CSI 的时序特征表示，然后在样本级别构建跨模态对比关系。设编码后的时序特征为

$$F_I, F_W \in \mathbb{R}^{B \times T \times D}, \quad (3-4)$$

其中， B 表示批大小， T 表示时间序列长度， D 表示特征维度。为获得样本级的全局表示，本文对时间维度进行平均池化：

$$f_I = \text{MeanPool}_T(F_I), \quad f_W = \text{MeanPool}_T(F_W), \quad (3-5)$$

并对特征进行 L_2 归一化：

$$\tilde{f}_I = \frac{f_I}{\|f_I\|_2}, \quad \tilde{f}_W = \frac{f_W}{\|f_W\|_2}. \quad (3-6)$$

在此基础上，构建批内跨模态相似度矩阵：

$$S = \frac{\tilde{f}_I \tilde{f}_W^T}{\tau}, \quad (3-7)$$

其中 $S \in \mathbb{R}^{B \times B}$ ， τ 为温度系数。

进一步采用双向跨模态对比学习损失进行优化，其形式定义为：

$$L_{\text{BCMCL}} = -\frac{1}{2B} \sum_{i=1}^B \left(\log \frac{\exp(S_{ii})}{\sum_{j=1}^B \exp(S_{ij})} + \log \frac{\exp(S_{ii})}{\sum_{j=1}^B \exp(S_{ji})} \right). \quad (3-8)$$

通过在特征层引入该对比约束，模型能够在训练过程中逐步对齐 IMU 与 WiFi CSI 的全局表示，从而为后续跨模态特征融合提供更加一致的语义基础。

3) 跨模态特征融合

完成跨模态特征对齐后，IMU 与 WiFi CSI 特征在整体语义空间中已具有较好的一致性，但二者仍保留了不同的信息侧重点。IMU 更擅长刻画人体局部运动的动力学变化，而 WiFi CSI 对人体运动引起的空间传播环境整体扰动更为敏感。为进一步利用两种模态的互补信息，本文采用交叉注意力机制进行跨模态特征融合。

设经过 Mamba 编码器得到的 IMU 与 WiFi CSI 时序特征分别为

$$F_I, F_W \in \mathbb{R}^{B \times T \times D}, \quad (3-9)$$

其中， B 表示批大小， T 表示时间序列长度， D 表示特征维度。本文以 IMU 特征作为查询 (Query)，以 WiFi CSI 特征作为键 (Key) 和值 (Value)，构造跨模态注意力：

$$Q = F_I W_Q, \quad K = F_W W_K, \quad V = F_W W_V, \quad (3-10)$$

其中， $W_Q \in \mathbb{R}^{D \times d_k}$ 、 $W_K \in \mathbb{R}^{D \times d_k}$ 、 $W_V \in \mathbb{R}^{D \times D}$ 为可学习的线性映射矩阵。

随后通过缩放点积注意力计算跨模态特征交互：

$$A = \text{Softmax} \left(\frac{QK^\top}{\sqrt{d_k}} \right) V. \quad (3-11)$$

该过程能够根据 IMU 特征在不同时间步上的状态，自适应地从 WiFi CSI 特征中选择更相关的信息，从而增强融合表示。为提高训练稳定性并保留原始特征，本文进一步引入残差连接与层归一化：

$$Z = \text{LayerNorm}(F_I + A), \quad (3-12)$$

其中 $Z \in \mathbb{R}^{B \times T \times D}$ 表示融合后的跨模态时序特征。

最后，通过对时间维度进行平均池化获得融合后的全局特征表示：

$$z = \text{MeanPool}_T(Z), \quad (3-13)$$

其中 $z \in \mathbb{R}^{B \times D}$ 表示最终的多模态融合特征。该特征同时融合了 IMU 与 WiFi CSI 两种模态的信息，并作为后续活动识别分类模块的输入。

4) 分类模块

设融合后的多模态特征表示为

$$z \in \mathbb{R}^{B \times D}, \quad (3-14)$$

其中 B 表示批大小, D 表示特征维度。

在此基础上, 本文为人体活动识别任务构建分类器。该分类器由两层全连接网络构成, 并结合非线性激活函数与 Dropout 层进行特征变换。人体活动识别任务经 Softmax 归一化后的预测概率分布可表示为

$$\hat{y}_a = \text{Softmax}(f_a(z)). \quad (3-15)$$

其中, $f_a(\cdot)$ 表示人体活动分类器, $\hat{y}_a$ 表示预测类别的概率分布。

5) 损失函数

为了同时优化人体活动识别任务分类性能以及跨模态特征对齐效果, 本文采用联合损失函数对模型进行训练。具体而言, 模型执行人体活动识别分类任务, 并引入双向跨模态对比学习损失以增强不同模态特征的一致性。

对于人体活动识别分类任务, 定义其交叉熵损失如下:

$$L_a = - \sum_{c=1}^{C_a} w_c y_a^{(c)} \log \hat{y}_a^{(c)}. \quad (3-16)$$

其中, L_a 表示人体活动识别任务的损失函数, w_c 表示第 c 类的类别权重, 用于缓解类别不平衡问题。

在此基础上, 结合双向跨模态对比学习损失 L_{BCMCL} , 模型的整体优化目标定义为:

$$L = L_a + \alpha L_{\text{BCMCL}}. \quad (3-17)$$

其中, α 为非负权重系数, 用于平衡人体活动识别任务与跨模态对齐任务在整体优化中的贡献。 C_a 表示活动类别数; $y_a^{(c)}$ 和 $\hat{y}_a^{(c)}$ 分别表示真实标签的独热编码和模型预测的类别概率。

通过上述联合优化方式, 模型能够在共享特征空间中学习更加一致且具有判别性的多模态表示, 并兼顾跨模态特征对齐与人体活动识别任务的优化目标, 从而提升整体识别性能。

3.2.3 基于类别原型的跨受试者适配策略

尽管 WIHAR 模型在训练受试者数据上能够取得较好的识别效果, 但在实际部署过程中, 模型往往需要面对未参与训练的新受试者。由于不同受试者在身体结构、动作习惯以及传感器佩戴方式等方面存在差异, 同一活动在不同个体上的多模态信号分布可能并不一致, 从而导致模型在跨受试者场景下出现性能下降。如何缓解由个体差异引起的特征分布偏移, 使模型在未见受试者上仍保持稳定识别能力, 是多模态人体活动识别中的关键问题之一。

针对上述问题, 本文提出一种基于类别原型的跨受试者适配策略, 通过“类别原型

约束”和“参数高效微调”两个环节提升模型对目标受试者的适应能力。前者旨在从类别语义层面约束不同受试者之间的特征表示，使同类活动在共享特征空间中保持更高一致性；后者则在少量标注样本条件下，以较低参数更新代价实现对目标受试者分布的快速适配。两者相互配合，使模型既能够保留源受试者数据中学到的稳定判别知识，又能够针对新受试者的个体特征进行适度调整。

具体而言，在源阶段训练完成后，首先利用源受试者训练数据构建各活动类别的原型表示。设融合特征空间中的样本表示为 z_i ，则类别 c 的原型向量定义为该类别所有样本特征的均值：

$$p_c = \frac{1}{N_c} \sum_{i=1}^{N_c} z_i, \quad (3-18)$$

其中， N_c 表示类别 c 的样本数量。该原型向量刻画了源受试者数据中对应活动类别的中心语义位置，可作为后续目标受试者适配时的类别参照。

在目标受试者适配阶段，首先引入类别原型约束，以减小目标受试者特征与源受试者类别原型之间的分布差异。对于目标受试者样本的融合特征表示 z ，本文采用余弦相似度定义类别原型约束损失：

$$L_{proto} = 1 - \cos(z, p_c), \quad (3-19)$$

其中， $\cos(\cdot, \cdot)$ 表示余弦相似度函数， p_c 为对应类别的源域原型。通过最小化该损失，可以促使目标受试者样本向其所属类别的原型中心靠拢，从而增强不同受试者之间同类活动特征表示的一致性，降低个体差异带来的分布偏移。

仅依赖类别原型约束仍不足以充分适应目标受试者的个体特征分布。考虑到目标阶段通常只能获得少量标注样本，若直接对整个网络进行微调，容易引发过拟合，并破坏模型在源阶段学到的稳定表示。为此，本文进一步引入参数高效微调策略，如图 3-3 所示，在冻结主干网络参数的基础上，仅更新轻量化 Adapter 模块及分类层参数，以较小的训练代价实现对目标受试者的快速适配。

具体而言，设融合后的输入特征表示为 $z \in \mathbb{R}^d$ ，其中 d 表示特征维度， r 表示降维系数。Adapter 模块首先对输入特征进行层归一化，然后通过下投影、非线性激活、随机失活以及上投影生成增量特征，其过程可表示为

$$\Delta z = W_{up} \text{Dropout}(\text{ReLU}(W_{down} \text{LayerNorm}(z) + b_{down})) + b_{up}, \quad \Delta z \in \mathbb{R}^d, \quad (3-20)$$

其中， $W_{down} \in \mathbb{R}^{\frac{d}{r} \times d}$ 和 $b_{down} \in \mathbb{R}^{\frac{d}{r}}$ 分别表示下投影层的权重与偏置， $W_{up} \in \mathbb{R}^{d \times \frac{d}{r}}$ 和 $b_{up} \in \mathbb{R}^d$ 分别表示上投影层的权重与偏置。最终，Adapter 模块通过残差连接输出适配后的特征表示：

$$z' = z + \Delta z. \quad (3-21)$$




图 3-3 基于瓶颈残差结构的 Adapter 模块示意图

上述结构本质上是一种带有预归一化的瓶颈残差适配模块，通过在低维子空间中学习增量表示，实现对目标受试者特征分布的高效修正。由于其仅在低维子空间内学习增量表示，因此参数量远小于直接微调整个主干网络。进一步地，本文对上投影层参数采用零初始化，即初始时刻满足 $W_{up} = 0$, $b_{up} = 0$ ，从而使得训练初期有 $\Delta z \approx 0$, $z' \approx z$ 。这意味着 Adapter 在微调开始时不会显著扰动源阶段已经学到的稳定特征表示，而是随着目标受试者数据的引入，逐步学习针对个体差异的补偿项。因此，该结构既能够保留原有主干网络的判别能力，又能够在少量样本条件下实现对目标受试者分布的快速修正。

综合来看，类别原型约束和参数高效微调分别从“类别语义约束”和“个体分布适配”两个层面缓解跨受试者偏移问题。前者通过源域原型为目标受试者提供稳定的类别参照，后者通过少量参数更新实现对新受试者特征分布的快速修正。在两种机制的协同作用下，模型能够在仅使用少量目标受试者标注样本的条件下完成有效适配，从而提升多模态人体活动识别系统在跨受试者场景中的泛化性能。

3.3 实验与结果分析

3.3.1 实验设置

本研究所有实验均在 Linux 服务器环境下完成。实验平台运行 Ubuntu 24.04.2 LTS 操作系统，服务器配备 Intel Xeon Gold 6530 处理器和 251 GB 系统内存，并搭载 4 块 NVIDIA GeForce RTX 4090 GPU 用于深度学习模型训练。在软件环境方面，实验基于 Python 3.8.20 实现，深度学习框架采用 PyTorch 2.0.1，并结合 CUDA 11.7 实现 GPU 加速计算。

在模型训练过程中，采用 Adam 优化器对网络参数进行更新，初始学习率设置为 1×10^{-4} ，权重衰减系数为 1×10^{-4} 。模型最大训练轮数设置为 300，早停轮数设置为 30，批大小设置为 512。本文采用滑动窗口方式对原始数据进行分割，将连续时间序列数据转换为模型输入样本，其中，窗口长度设置为 1 s，滑动步长设置为 0.5 s。

3.3.2 评价指标

为了全面地评估所提出的人体活动识别模型,本文在总体准确率之外,进一步引入宏平均精确率 (Macro-Precision)、宏平均召回率 (Macro-Recall)、宏平均 F1 值 (Macro-F1) 以及逐类别 F1 值 (Per-class F1),并结合混淆矩阵对模型预测结果进行分析。准确率用于衡量模型在测试集上的整体分类性能;宏平均指标用于反映模型在类别层面的均衡识别能力;逐类别 F1 值用于观察模型在不同活动类别上的细粒度判别表现;混淆矩阵则用于分析类别之间的具体混淆关系。

1) 准确率

准确率是分类任务中最常用的评价指标之一,其定义为被模型正确分类的样本数占测试样本总数的比例。设测试集中共有 N 个样本,其中被模型正确分类的样本数记为 N_{correct} ,则准确率定义为

$$\text{Accuracy} = \frac{N_{\text{correct}}}{N}. \quad (3-22)$$

其中, N_{correct} 表示预测标签与真实标签一致的样本数量。该指标能够直观反映模型在测试集上的整体分类性能,数值越高,说明模型总体识别效果越好。

2) 宏平均指标与逐类别 F1

设分类任务包含 C 个类别。对于第 c 类,记真阳性、假阳性和假阴性样本数量分别为 TP_c 、 FP_c 和 FN_c ,则该类的精确率、召回率和 F1 值分别定义为

$$P_c = \frac{TP_c}{TP_c + FP_c}, \quad R_c = \frac{TP_c}{TP_c + FN_c}, \quad F1_c = \frac{2P_c R_c}{P_c + R_c}. \quad (3-23)$$

其中, P_c 表示第 c 类的精确率, R_c 表示第 c 类的召回率, $F1_c$ 表示第 c 类的 F1 值。在具体实现中,当 $TP_c + FP_c = 0$ 或 $TP_c + FN_c = 0$ 时,相应的精确率或召回率记为 0;当 $P_c + R_c = 0$ 时,对应的 $F1_c$ 亦记为 0。为避免不同宏平均定义带来的歧义,本文采用先逐类计算 F1,再对各类别取算术平均的 Macro-F1 定义。

在此基础上,宏平均精确率、宏平均召回率与宏平均 F1 值分别定义为

$$\text{Macro-Precision} = \frac{1}{C} \sum_{c=1}^C P_c, \quad \text{Macro-Recall} = \frac{1}{C} \sum_{c=1}^C R_c, \quad (3-24)$$

$$\text{Macro-F1} = \frac{1}{C} \sum_{c=1}^C F1_c. \quad (3-25)$$

与准确率相比,宏平均指标对每个类别赋予相同权重,因此能够在类别分布不均条件下更客观地反映模型的整体识别能力,避免高频类别对总体指标的过度主导。与此同时,由各类别 $F1_c$ 共同构成的 Per-class F1 结果可以进一步揭示模型在不同活动类别上的识别差异,便于分析哪些动作类别更易被正确识别,哪些类别仍存在较明显的

区分困难。

3) 混淆矩阵

准确率能够反映模型整体分类性能，但难以揭示不同类别之间的具体误判情况。为了进一步分析模型在各类别上的识别表现，本文采用混淆矩阵对预测结果进行统计分析。

设分类任务包含 C 个类别，则混淆矩阵 M 为一个 $C \times C$ 的矩阵，其中第 i 行第 j 列元素 M_{ij} 表示真实类别为 i 且被预测为类别 j 的样本数量。由此，混淆矩阵能够统计模型在各类别上的预测分布情况，并反映不同类别之间的混淆关系。

由于不同类别的样本数量可能存在差异，本文进一步对混淆矩阵按行进行归一化处理，使每一行元素之和为 1。归一化后的矩阵元素定义为

$$\tilde{M}_{ij} = \frac{M_{ij}}{\sum_{k=1}^C M_{ik}}. \quad (3-26)$$

其中，当 $\sum_{k=1}^C M_{ik} = 0$ 时，将该行归一化结果记为 0。归一化混淆矩阵能够反映真实类别为 i 的样本在各预测类别中的分布情况。其中，对角线元素表示各类别被正确识别的比例，而非对角线元素则反映不同类别之间的混淆程度。

由于本文活动类别数量较多，若直接在图中标注保留两位小数的归一化结果，部分数值在视觉上不够直观。因此，在混淆矩阵可视化时，本文将归一化矩阵元素乘以 100，以百分数形式进行展示，即

$$M_{ij}^{(\%)} = 100 \times \tilde{M}_{ij}. \quad (3-27)$$

其中， $M_{ij}^{(\%)}$ 表示以百分数形式展示的混淆矩阵元素。在可视化标注时，本文将其以整数形式显示，以提高结果呈现的直观性。需要说明的是，该处理仅改变数值的显示形式，不影响混淆矩阵本身所反映的类别预测分布关系。通过结合准确率、宏平均指标、逐类别 F1 值以及混淆矩阵，可以更加全面地评估模型在整体性能、类别均衡性和细粒度类别区分能力上的表现。

3.3.3 数据集与划分策略

1) 数据集

本文实验采用 XRFV2 数据集。该数据集面向室内连续人体活动理解任务，包含 WiFi CSI 数据与 IMU 数据，能够较好地反映真实生活环境中的日常活动过程。该数据集采集于餐厅、书房和卧室 3 个典型室内场景。每个场景均部署 1 个发射器和 3 个接收器组成的 WiFi 系统，以约 200 packets/s 的速率采集 CSI 数据，并采用 WiFi CSI Tool 从 30 个 OFDM 子载波中提取幅度与相位信息，单个时间步的 CSI 特征维度为 540。与此同时，志愿者均佩戴 5 个 IMU 设备，包括双手表、双手机和一副智能眼镜。每个设备均记录三轴加速度与三轴角速度数据，因此 IMU 数据可表示为 $T \times 5 \times 6$ 的时序形

式。该数据集共包含 16 名志愿者、30 类日常活动，总时长约 16 小时。

在此基础上，本文进一步对 XRFV2 数据集的活动类别分布进行了统计分析。如图 3-4 所示，各活动类别在总时长和样本数量上存在一定差异：部分高频活动占比较高，而部分活动样本相对较少，呈现出较为明显的长尾分布特征。该分布特性容易导致模型在训练过程中偏向高频类别，从而削弱对低频类别的识别能力，并影响模型的泛化性能。因此，在基于该数据集开展实验时，需要采取相应措施以缓解类别不平衡问题带来的影响。




图 3-4 活动时长分布

2) 划分策略

为系统评估所提出方法在不同应用条件下的性能与泛化能力，本文采用了三种数据集划分策略，分别对应同分布条件、跨受试者条件以及跨场景条件。

在同分布条件下，采用标准随机划分方式，将完整数据集按照 80% 与 20% 的比例划分为训练集与测试集。具体划分方式如图 3-5 所示，各类活动数据在训练集与测试集中均有分布，且训练与测试样本来源于相同的受试者与采集场景，仅在样本层面进行随机划分。因此，训练集与测试集在统计分布上保持一致，该实验条件主要用于评估模型在理想情况下的性能表现，可视为方法性能的上限参考。

在跨受试者条件下，采用留一受试者策略进行数据划分，其划分方式如图 3-6 所示。具体而言，在每一轮实验中，从全部受试者中选择一名受试者作为测试对象，其余受试者的数据用于模型训练。该划分方式保证训练集与测试集在受试者层面完全不重叠，从而引入由个体差异带来的分布偏移。由于不同受试者在运动习惯、身体结构及传感器佩戴方式等方面存在差异，该实验条件能够有效评估模型在未见受试者条件下的泛化能力。




图 3-5 标准数据集划分




图 3-6 跨受试者数据集划分

在跨场景条件下，采用留一场景策略进行数据划分，其划分方式如图 3-7 所示。具体而言，在每一轮实验中，选取一个场景作为测试环境，其余场景的数据用于模型训练。该策略使训练集与测试集在场景层面完全分离，从而引入由空间布局、遮挡关系及无线信号传播特性差异所带来的分布偏移。尤其对于 WiFi CSI 数据而言，环境变化会显著影响信道特性，因此该实验条件能够有效评估模型在复杂环境变化下的鲁棒性。

3.3.4 方法对比实验

为系统评估 WIHAR 在多模态人体活动识别任务中的性能，本文选取了三种具有代表性的 HAR 方法作为对比基线：Attend and Discriminate (AAD)^[26]、TinyHAR^[27]以及 HARMamba^[2]。考虑到这些方法主要面向单模态输入，而本文任务使用的是 IMU 与 WiFi CSI 构成的异构双模态数据，实验中对所有基线都进行了统一适配：将两种模态在通道维进行拼接，并在相同的数据划分、滑动窗口设置和评价指标下重新训练。因而，本节比较的重点不是复现原论文在各自数据集上的最好成绩，而是在统一实验条件下考察不同方法的相对建模能力。

各方法在 XRFV2 数据集上的识别结果如表 3-1所示。WIHAR 取得了 96.06% 的最高准确率，明显优于所有对比方法。其中，最强基线 HARMamba 的准确率为 92.10%，AAD 和 TinyHAR 分别为 91.72% 和 89.71%。也就是说，WIHAR 相较于 HARMamba、




图 3-7 跨场景数据集划分

AAD 和 TinyHAR 分别提升了 3.96、4.34 和 6.35 个百分点。由于所有方法采用相同输入和训练配置，上述提升更能说明：在双模态场景下，仅靠直接拼接输入并不足以充分发挥 IMU 与 WiFi CSI 的互补性，而显式的跨模态对齐与融合是性能提升的关键来源。

表 3-1 方法对比实验结果

方法	准确率	宏平均 F1	宏平均精确率	宏平均召回率
AAD ^[26]	91.11	90.96	90.64	91.53
TinyHAR ^[27]	87.70	87.48	87.51	88.18
HARMamba ^[2]	90.82	90.40	91.19	89.84
PatchHAR	91.36	91.33	91.20	91.58
PatchTST	90.26	90.21	90.27	90.33
LightHART	90.01	89.58	89.74	89.57
ModernTCN	89.14	88.69	89.06	88.80
DecomposeWHAR	91.66	90.95	91.22	90.81
WIHAR (Ours)	95.81	95.29	95.48	95.13

为了进一步观察训练过程中的动态表现，图 3-8 给出了各方法在测试集上的准确率随训练轮数的变化曲线。可以看到，WIHAR 在训练前期便迅速提升到较高水平，并在后续阶段保持更平稳的收敛趋势；相比之下，其余基线虽然也能逐步收敛，但收敛速度更慢、波动更明显。这说明 WIHAR 不仅最终精度更高，训练过程也更稳定。对于需要多次重训练或后续迁移适配的模型而言，这种稳定性同样具有实际价值。

图 3-9 进一步给出了 WIHAR 在测试集上的归一化混淆矩阵。整体上，对角线区域占优，说明模型已经能够较好地地区分大多数动作类别；少量误判主要集中在动作模式相近的类别之间，这与真实场景中相似动作本身存在较大重叠有关。结合表 3-1 和图 3-8 可以认为，WIHAR 的优势并不只体现在单一总体指标上，而是在整体精度、训练稳定性和细粒度类别区分能力上都表现更好。




图 3-8 各方法活动识别准确率随训练轮数变化曲线

3.3.5 模型架构与训练策略实验

1) 骨干网络选择实验

为了评估不同时序建模结构对人体活动识别性能的影响，本文将双分支编码器中的主干网络分别替换为 ResNet18、LSTM、GRU、Transformer 和 Mamba，并保持其余网络结构、训练轮数和优化参数一致。这样可以保证不同结果主要反映时序建模能力差异，而不是来自训练细节或参数设置的变化。实验结果如表 3-2所示。

表 3-2 骨干网络选择实验结果

骨干网络	活动识别准确率
ResNet18	88.44%
Mamba	96.06%
LSTM	91.43%
GRU	92.90%
Transformer	95.06%

从表 3-2可以看到，各类骨干网络的表现差异较为清晰。ResNet18 的活动识别准确率仅为 88.44%，说明单纯依赖局部卷积堆叠，难以充分建模跨时间步的长程依赖。将骨干替换为循环结构后，LSTM 和 GRU 的准确率分别提升到 91.43% 和 92.90%，表明显式时序建模确实能够改善识别效果。进一步采用 Transformer 后，准确率提升到 95.06%，说明自注意力在捕获长距离动作依赖方面更具优势。本文采用的 Mamba 取得了最高的 96.06%，相比 Transformer 进一步提升 1.00 个百分点，相比 GRU 和 LSTM 分别提升 3.16 和 4.63 个百分点。

综合来看，随着时序建模能力增强，模型性能呈现出较稳定的提升趋势，而 Mamba 在当前任务中取得了最佳平衡：既能有效建模长时序动态，又能保持较好的训练稳定




图 3-9 人体活动识别任务的归一化混淆矩阵

性。因此，本文在后续实验中选择 Mamba 作为默认时序编码骨干。

2) 特征融合策略对比实验

为了分析性能提升究竟来自“双模态输入”本身，还是来自更有效的模态交互方式，本文进一步比较了两种融合策略：一种是直接在特征维进行拼接，另一种是采用交叉注意力建立显式的跨模态信息交互。除融合模块外，其余网络结构与训练参数均保持一致。实验结果如表 3-3 所示。3-3 所示。

表 3-3 显示，两种融合方式之间存在非常明显的性能差距：交叉注意力达到 96.06%，而简单拼接仅为 79.83%，二者相差 16.28 个百分点。这个差距已经不是“边际优化”，而是说明融合策略本身决定了多模态信息能否真正被模型利用。对于 IMU 与 WiFi CSI 这类异构模态而言，直接拼接会把两种统计性质差异较大的特征机械地堆在一起，模

表 3-3 融合策略实验结果

模态融合策略	活动识别准确率
拼接	79.83%
交叉注意力	96.06%

型需要在后续层中自行学习对应关系，难度较高；而交叉注意力能够显式建模“一个模态应该从另一个模态中关注什么”，因此更容易形成稳定且具有判别性的联合表示。

因此，本文最终采用交叉注意力作为默认融合方式。该实验也从侧面说明，WIHAR 的优势并不只是多加了一路输入，而是建立在“先对齐、再交互”的融合思路之上。

3) 类别权重消融实验

在人体活动识别任务中，不同活动类别的样本规模往往存在差异。若在训练过程中对各类别赋予相同的重要性，模型容易受到高频类别的主导，从而影响对低频类别的识别效果。图 3-4 展示了各活动类别对应的数据时长分布，可以观察到类别间存在明显的不均衡现象。例如，第 29 类的数据时长仅约 1 分钟，而第 24 类约为 124 分钟，类别间最大时长差异超过两个数量级。这种显著的不均衡分布可能导致模型在训练过程中更倾向于高频类别，从而削弱对低频类别的判别能力。基于上述观察，本文在活动识别分支的损失函数中引入类别权重，以缓解类别不均衡对模型训练的影响。

为实现这一目标，本文采用基于类别规模倒数的加权策略。设训练集中第 c 类的数据时长为 n_c ，则首先定义初始权重为：

$$w'_c = \frac{1}{n_c}. \quad (3-28)$$

进一步地，为避免权重尺度对整体损失幅值产生影响，对权重进行归一化处理，使其平均值为 1：

$$w_c = \frac{w'_c}{\sum_{k=1}^{C_a} w'_k} \times C_a, \quad (3-29)$$

其中 C_a 表示活动类别总数。

在此基础上，带类别权重的活动识别损失函数可表示为：

$$L_a = - \sum_{c=1}^{C_a} w_c y_a^{(c)} \log \hat{y}_a^{(c)}, \quad (3-30)$$

其中 $y_a^{(c)}$ 为真实标签的独热编码， $\hat{y}_a^{(c)}$ 为模型预测的类别概率。该权重设计能够对样本量较少的类别赋予更大的损失贡献，引导模型在训练过程中更加关注低频类别样本。

在上述设置下，本文设计了是否引入类别权重的消融实验，其结果如表 3-4 所示。在活动识别分支中引入类别权重后，活动识别准确率由 94.76% 提升至 96.06%，提升了 1.30 个百分点。该结果表明，在类别分布不均衡的条件下，引入类别权重能够在优化

过程中对不同类别样本进行差异化约束，从而缓解模型对高频类别的偏置。

表 3-4 类别权重消融实验结果

使用权重	活动识别准确率
是	96.06%
否	94.76%

4) 对比学习消融实验

双向跨模态对比学习的作用，在于先在 IMU 到 WiFi CSI 与 WiFi CSI 到 IMU 两个方向上约束共享语义空间中的特征对齐，再进行后续融合。为了验证这一设计是否必要，本文移除该模块，其余网络结构和训练参数保持不变，仅保留监督分类损失重新训练模型。实验结果如表 3-5 所示。

表 3-5 双向跨模态对比学习消融实验结果

使用双向跨模态对比学习	活动识别准确率
是	96.06%
否	94.06%

移除双向跨模态对比学习后，活动识别准确率由 96.06% 下降到 94.06%，下降了 2.00 个百分点。考虑到这里并未改变主干网络容量，也没有引入额外噪声源，因此性能下降可以直接归因于跨模态对齐能力的减弱。换句话说，交叉注意力虽然能够实现模态间信息交互，但如果缺少双向跨模态对比学习提供的前置语义约束，IMU 与 WiFi CSI 之间仍然可能处于“可交互但不对齐”的状态，融合结果自然难以稳定。

3.3.6 样本构建与数据处理实验

1) 样本构建实验

对于时序人体活动识别任务而言，窗口长度和滑动步长并不是简单的数据预处理超参数，而是会直接影响“一个样本包含多少动作信息”以及“相邻样本之间是否足够密集”。因此，本实验的目的，是在识别精度、样本密度和系统响应速度之间找到更合适的平衡点。实验中，本文枚举不同的窗口长度与滑动步长组合，其余训练设置保持不变，结果如图 3-10 所示。

从图 3-10 可以看出，窗口长度和滑动步长对性能的影响都很明显，但二者作用方式不同。首先，在步长固定为 0.5 s 时，随着窗口长度从 1.0 s 增加到 3.0 s，活动识别准确率由 96.06% 逐步提升至 99.79%。这说明更长的时间窗口能够覆盖更完整的动作过程，从而为模型提供更充分的时序上下文。其次，在窗口长度固定为 3.0 s 时，随着步长从 0.5 s 增大到 3.0 s，准确率整体由 99.79% 下降到 93.21%。这表明较小步长带来的高重叠采样有助于提升样本密度，使模型更容易学习到稳定的动作边界和判别模式。

不过，本文并未直接选择精度最高的 3.0 s/0.5 s 组合作为默认设置。原因在于，该组合虽然能够进一步提高准确率，但也会显著增加观测时延、输入长度和训练开销；对于需要较快响应的人体活动感知系统，过长窗口还可能弱化对动作起止边界的敏感性。




图 3-10 样本构建实验结果

相比之下，1.0 s/0.5 s 已经能够达到 96.06% 的准确率，同时具有更低的时延和更好的实时性。基于“精度足够高且响应更及时”的考虑，本文最终将窗口长度设为 1.0 s、滑动步长设为 0.5 s，并以此作为后续实验的默认配置。

2) 数据标准化实验

在多模态人体活动识别任务中，IMU 数据与 WiFi CSI 数据在量纲范围和统计分布上存在差异，因此数据标准化可能影响模型训练过程。为分析标准化策略对模型识别性能的作用，本文选取两种设置进行对比：一是不对输入数据进行标准化处理；二是同时对 IMU 数据和 WiFi CSI 数据进行按通道 Z-score 标准化。实验结果如表 3-6 所示。

设输入样本表示为 $X \in \mathbb{R}^{B \times T \times C}$ ，其中 B 表示批大小， T 表示时间长度， C 表示通道数。按通道 Z-score 标准化的计算方式为

$$\mu_c = \frac{1}{BT} \sum_{b=1}^B \sum_{t=1}^T X_{b,t,c}, \quad (3-31)$$

$$\sigma_c = \sqrt{\frac{1}{BT} \sum_{b=1}^B \sum_{t=1}^T (X_{b,t,c} - \mu_c)^2}, \quad (3-32)$$

$$\hat{X}_{b,t,c} = \frac{X_{b,t,c} - \mu_c}{\sigma_c}, \quad (3-33)$$

其中 μ_c 和 σ_c 分别表示第 c 个通道的均值与标准差， $\hat{X}_{b,t,c}$ 表示标准化后的数据。

表 3-6 数据标准化实验结果

标准化设置	活动识别准确率
不使用标准化	96.06%
按通道 Z-score 标准化	96.43%

从表 3-6可以看出, 按通道 Z-score 标准化后, 活动识别准确率由 96.06% 提升至 96.43%, 这说明标准化在整体上有助于提升训练稳定性。

但结合归一化混淆矩阵进一步分析可以发现, 采用该标准化策略后, 模型在活动识别任务中出现了较明显的类别聚集现象, 即大量样本被集中预测为少数几个类别, 如图 3-11所示。这意味着总体准确率的提升并未完全转化为更均衡的类别判别能力。考虑到本研究中的活动类别分布并不完全均衡, 若仅依据总体准确率进行判断, 容易掩盖部分类别上的性能退化。

因此, 本文在确定默认实验设置时, 不仅考虑总体准确率, 还综合考察混淆矩阵所反映的类别区分能力。综合来看, 按通道 Z-score 标准化虽然能够带来轻微的精度提升, 但会削弱模型对不同活动类别的细粒度区分能力, 因此本文后续实验不采用该标准化策略。

3.3.7 模态和传感器消融实验

为了进一步分析不同传感模态在多模态人体活动识别任务中的作用, 本节从模态层面与传感器层面两个角度对模型进行分析。首先通过模态消融实验研究 IMU 与 WiFi CSI 信号在人体活动识别中的贡献, 其次通过传感器消融实验分析不同传感器对模型性能的影响。

1) 模态消融实验

为了评估不同传感模态对识别性能的影响, 本文分别使用 IMU 数据、WiFi CSI 数据以及两者融合数据进行实验。同时, 为了分析不同 WiFi CSI 表示方式对模型性能的影响, 本文进一步比较了原始 WiFi CSI、WiFi CSI 幅度信息以及 WiFi CSI 相位信息三种表示方式。实验结果如表 3-7所示。

表 3-7 模态消融实验结果

模态 1	模态 2	活动识别准确率
IMU	-	92.96%
WiFi CSI	-	87.96%
WiFi CSI 幅度	-	87.75%
WiFi CSI 相位	-	84.85%
IMU	WiFi CSI	96.06%
IMU	WiFi CSI 幅度	95.68%
IMU	WiFi CSI 相位	94.65%

从表 3-7可以看出, 不同传感模态对人体活动识别性能的贡献存在明显差异。仅使用 IMU 数据时, 人体活动识别准确率达到 92.96%, 明显高于仅使用 WiFi CSI 数据的




图 3-11 采用按通道 Z-score 标准化后的活动识别归一化混淆矩阵

87.96%。这说明 IMU 能够直接捕获人体运动产生的惯性变化信息，因此在活动识别任务中具有较强的判别能力。

进一步比较不同 WiFi CSI 表示方式可以发现，直接使用原始 WiFi CSI 信息能够取得最佳整体性能，而仅使用幅度或相位信息时模型性能略有下降。这说明幅度与相位信息共同包含了更完整的信道特征，能够为模型提供更丰富的环境感知信息。

在多模态融合情况下，IMU 与 WiFi CSI 数据结合能够显著提升识别性能。其中，IMU 与 WiFi CSI 融合后在活动识别任务上的准确率达到 96.06%，相比单独使用 IMU 提升约 3.10 个百分点。这表明 IMU 与 WiFi CSI 模态之间具有明显互补性，通过多模态融合能够获得更完整的人体活动特征表示。

2) 传感器消融实验

为了进一步分析不同传感器对模型性能的影响, 本文在完整系统基础上逐一移除不同 IMU 传感器以及 WiFi CSI 接收节点, 并重新训练模型进行测试。实验结果如表 3-8 所示。

表 3-8 传感器消融实验结果

传感器	传感器编号	活动识别准确率
-	-	96.06%
IMU	0	94.86%
IMU	1	95.67%
IMU	2	94.79%
IMU	3	95.34%
IMU	4	95.65%
WiFi CSI	0	95.53%
WiFi CSI	1	94.80%
WiFi CSI	2	94.79%

从表 3-8 可以看出, 当移除任意一个传感器后, 人体活动识别准确率均出现一定程度下降。例如, 当移除 IMU 传感器 0 时, 活动识别准确率下降至 94.86%; 当移除 WiFi CSI 接收节点 1 或 2 时, 活动识别准确率下降至约 94.8%。

总体来看, 无论移除 IMU 传感器还是 WiFi CSI 节点, 活动识别准确率都会出现下降, 说明两类传感器都对活动识别任务提供了有效信息。

此外, 各传感器被移除后的性能下降幅度整体较为接近, 说明不同传感器在系统中均提供了有效信息。即使缺失单个传感器, 模型仍能够保持较高的识别准确率, 这也表明所构建的多模态感知系统具有一定的鲁棒性。

3.3.8 跨受试者泛化实验

在实际人体活动识别应用中, 模型往往需要推广到未参与训练的新受试者。由于不同受试者在身体结构、动作习惯以及传感器佩戴方式等方面存在差异, 传感数据的统计特性可能发生变化, 从而导致模型在跨受试者场景下的识别性能下降。因此, 本节通过跨受试者实验评估所提出方法在新受试者上的泛化能力, 并进一步分析少样本条件下适配策略的效果。

在实验设置中, 首先利用训练受试者的数据完成源阶段模型训练, 并基于训练数据计算各类别的原型表示。在目标受试者阶段, 将每一位未参与训练的志愿者依次视为目标受试者, 并逐步增加用于适配的标注样本数量。适配过程中冻结主干网络参数, 仅更新轻量化 Adapter 模块及分类层参数, 从而实现少样本条件下的快速适配。

图 3-12 给出了不同目标受试者在未进行适配时的初始活动识别准确率, 可以看出不同受试者之间存在较明显的性能差异, 这也进一步说明跨受试者分布偏移问题的存在。

图 3-13 展示了不同目标受试者在适配数据时长逐渐增加时的活动识别准确率变化。




图 3-12 跨受试者活动识别准确率

横轴表示用于适配的目标受试者数据时长（单位：s），纵轴表示模型在目标受试者上的活动识别准确率。从图中可以看出，当不使用目标受试者数据进行适配时，模型在不同受试者上的识别准确率存在明显差异，最低约为 56%，最高约为 86%，平均准确率约为 72.57%。随着适配数据时长增加，各受试者的识别准确率整体呈持续上升趋势。当适配数据时长增加到 30–50 s 时，大多数受试者的准确率已提升至 80% 以上；当适配数据时长增加到 100 s 左右时，平均准确率约为 87%；当适配数据时长增加到 120 s 时，平均准确率可进一步提升至约 90.99%。与此同时，不同受试者之间的性能差异也逐步缩小，说明所提出的跨受试者适配策略能够在一定程度上缓解个体间的分布偏移问题。




图 3-13 少样本适配条件下的跨受试者活动识别准确率变化

综合来看，通过类别原型约束与参数高效微调相结合的方式，模型能够在较少标注样本条件下完成对目标受试者的快速适配，并显著提升跨受试者场景下的人体活动识别性能。这表明该策略在低标注成本条件下具有较好的应用潜力和实际价值。

3.4 本章小结

本章围绕多模态人体活动识别任务，基于 XRFV2 数据集提出了融合 IMU 与 WiFi CSI 信息的 WIHAR 方法，并对其关键模块和跨受试者适配策略进行了系统分析。该方法通过双分支 Mamba 编码器提取两种模态的时序特征，在此基础上利用双向跨模态对比学习缩小异构特征之间的语义差异，并通过交叉注意力实现模态间信息交互，最终完成人体活动识别。实验结果表明，所提方法在整体性能、关键结构设计、模态协同效果和跨受试者适配能力等方面均取得了较好的结果，说明多模态对齐与融合能够有效提升复杂室内环境下的人体活动识别性能。

4 基于自回归建模机制的人体姿态重构与预测

本章围绕基于自回归建模机制的人体姿态重构与预测问题展开研究。第 4.1 节首先对任务背景与研究动机进行说明，分析现有基于 IMU 的人体姿态重构方法主要聚焦于当前姿态重构，而对未来姿态预测关注相对较少。第 4.2 节介绍实验数据集及样本构建方式，包括姿态数据的获取、IMU 与姿态序列的时间对齐、预处理与样本划分方法。第 4.3 节对本文提出的 AIPose 方法进行详细说明，给出整体框架，并介绍模型结构及其自回归预测机制。第 4.4 节通过实验对所提方法进行评估，从方法对比、参数分析、模型消融以及泛化能力等方面分析模型性能。最后，第 4.5 节对本章研究内容进行总结。

4.1 问题描述

人体姿态能够较为细致地描述人体各关键部位之间的空间关系及其随时间变化的运动过程，因此在人机交互、虚拟现实、运动分析、康复辅助以及远程行为监测等场景中具有重要应用价值。然而，在保证隐私性、可部署性和实时性的前提下准确重构人体姿态，并进一步建模人体运动的未来变化，仍然是人体感知研究中的一个关键问题。

现有基于图像或视频的视觉方法能够直接从图像中检测人体关键点，因此在理想条件下通常可以获得较高精度的姿态估计结果。但在真实场景中，这类方法仍然受到光照、遮挡、视角以及隐私问题的限制，尤其是在卧室等隐私敏感环境中，持续视频采集往往不适合作为长期部署方案。因此，在保证人体运动表达能力的同时，探索更加隐私友好且便于部署的非视觉感知方式具有实际意义。

相比视觉方法，基于 IMU 的感知方案不依赖光照条件，对遮挡不敏感，且设备部署较为灵活，因此在可穿戴人体感知系统中受到广泛关注。IMU 能够高频采集人体局部运动的加速度与角速度信息，并以时序信号形式反映人体运动的动态变化。近年来，多项工作已尝试利用 IMU 重构人体姿态，这些方法推动了基于 IMU 的人体姿态重构的发展，也说明仅依赖少量可穿戴传感器进行姿态建模具有可行性。

不过，现有多数方法主要关注根据一段 IMU 观测序列重构对应时间范围内的人体姿态，即学习 IMU 信号与当前姿态之间的映射关系。对于未来姿态预测，这类方法通常缺少显式建模。事实上，人体运动具有明显的时间连续性和动态演化特征，当前姿态不仅反映人体的即时状态，也蕴含着未来运动变化的重要线索。如果仅关注当前姿态重构，而忽略人体运动在时间维度上的发展趋势，则难以完整刻画人体运动过程，也会限制系统在预测与交互场景中的应用能力。

例如，在运动训练分析、动作反馈或智能交互系统中，系统不仅需要理解人体当前姿态，还需要对未来一段时间内的运动趋势进行短时预测，以便提前做出响应。因此，相比仅执行姿态重构的建模方式，能够同时实现当前姿态重构与未来姿态预测的模型更具应用价值。然而，在基于 IMU 的人体姿态研究中，针对未来姿态预测的系统性研

究仍然相对有限。

针对上述问题，本文提出一种基于自回归建模机制的人体姿态重构与预测方法 AIPose。该方法以历史 IMU 序列作为输入，首先重构对应时间段内的人体二维关键点姿态序列；随后，通过 IMU 预测模块生成未来时间段的 IMU 序列，并与当前观测序列尾部进行拼接，构造新的输入序列以预测未来姿态。通过这一自回归建模过程，模型不仅能够完成当前时间段的人体姿态重构，还能够进一步推演未来时间段的人体姿态变化，从而在统一框架下实现“当前重构 + 未来预测”的联合建模。

4.2 方法描述

4.2.1 整体方法框架

为实现基于 IMU 的人体姿态重构与短时预测，本文提出一种基于自回归建模机制的人体姿态重构与预测方法 AIPose。该方法以历史 IMU 时序信号为输入，在统一框架下同时完成当前姿态重构与未来姿态预测。整体方法流程如图 4-1 所示。




图 4-1 人体姿态重构与预测方法整体流程

AIPose 的输入为一段连续的 IMU 观测序列。首先，模型利用时序特征提取模块对输入信号进行编码，得到能够表征人体运动状态的高层时序特征。在此基础上，模型分为两个相互关联的分支：一条分支用于恢复当前时间窗口内的人体姿态，另一条分支用于预测未来时间段的 IMU 变化。对于当前姿态重构分支，模型直接根据历史 IMU 观测提取到的时序特征，输出当前时间范围内的人体二维关键点序列。该分支的作用是根据已有观测恢复人体当前的运动状态，为后续预测提供姿态层面的结构约束。对于未来预测分支，模型并不直接从当前特征中生成未来姿态，而是先预测未来一段时间内的 IMU 序列，再将预测得到的未来 IMU 与当前观测序列尾部进行拼接，构成扩展

的时序输入。随后，模型基于这一扩展输入进一步预测未来姿态。这样的设计使未来姿态预测仍然建立在 IMU 动态演化过程之上，从而保持了“先建模运动，再预测姿态”的思路。换言之，AIPose 将未来姿态预测分解为“未来 IMU 预测”和“基于扩展 IMU 的姿态预测”两个步骤，并通过自回归建模机制将两者连接起来。

在训练阶段，AIPose 采用联合优化方式，同时对当前姿态重构、未来 IMU 预测以及未来姿态预测三个任务进行监督。通过这种多任务训练策略，模型既能够学习 IMU 与当前姿态之间的映射关系，也能够学习人体运动在时间维度上的连续演化规律。

在推理阶段，模型只需输入当前时刻之前的 IMU 观测序列，即可先恢复当前姿态，再进一步生成未来短时姿态序列。因而，AIPose 不仅能够描述人体当前的运动状态，还能够对其后续变化趋势进行短时推演。

4.2.2 AIPose 模型

在上述整体方法框架的基础上，本文构建了 AIPose 模型，用于实现基于自回归建模机制的人体姿态重构与预测。该模型以 IMU 时序数据为输入，通过共享的时序特征表示同时支持当前姿态重构与未来姿态预测两个任务。模型的整体结构如图 4-2 所示。




图 4-2 AIPose 模型架构图

AIPose 主要由 IMU 时序特征提取模块、姿态重构模块、IMU 时序预测模块以及自回归姿态预测机制组成，并通过联合损失函数进行优化。各模块在同一建模框架下协同工作，使模型能够从当前观测序列出发，实现对未来姿态的连续建模。

下面将对各个组成模块的具体结构与实现方式进行说明。

1) IMU 时序特征提取模块

根据第 4.2.2 节构建的输入样本, 设输入 IMU 序列为

$$\mathbf{X}_{\text{input}} \in \mathbb{R}^{B \times T \times C},$$

其中 B 表示批次大小, T 表示时间窗口长度, $C = 30$ 表示 IMU 通道数。在此基础上, 通过 ResNet 对输入序列进行时序特征提取, 得到对应的特征表示

$$\mathbf{F} = E(\mathbf{X}_{\text{input}}),$$

其中 $E(\cdot)$ 表示基于 ResNet 的映射函数。该结构利用一维卷积提取 IMU 信号中的局部动态变化, 并通过残差连接增强特征表达的稳定性。得到的特征表示 $\mathbf{F}$ 作为统一的中间表示, 将同时用于当前姿态重构与未来 IMU 预测。

2) 姿态重构模块

在获得 IMU 特征表示 $\mathbf{F}$ 后, 首先对当前时间窗口内的人体姿态序列进行建模, 其映射关系为

$$\mathbf{P}_{\text{rec}} = f_{\text{rec}}(\mathbf{F}).$$

通过全连接层将特征向量映射到姿态空间, 并重构为具有时间结构的关键点序列。设姿态重构窗口长度为 L_{rec} , 关键点数量为 K , 则输出形式为

$$\mathbf{P}_{\text{rec}} \in \mathbb{R}^{B \times L_{\text{rec}} \times K \times 2}.$$

为保证输出数值稳定并与第 4.2.2 节中的归一化空间保持一致, 重构结果通过 $\tanh$ 函数约束在 $(-1, 1)$ 范围内。该模块实现了从 IMU 特征到当前姿态序列的重构, 同时为后续姿态预测提供结构先验。

3) IMU 时序预测模块

在完成当前姿态重构的同时, 模型进一步基于特征表示 $\mathbf{F}$ 对未来时间段的 IMU 序列进行建模, 其映射关系为

$$\mathbf{X}_{\text{future}} = G(\mathbf{F}),$$

其中 $G(\cdot)$ 表示预测映射函数。本文采用 Transformer 对特征进行时序建模, 以学习 IMU 信号在时间维度上的动态演化规律, 从而实现对未来 IMU 序列的预测。设未来时间窗口长度与姿态预测窗口对应, 则预测结果为

$$\mathbf{X}_{\text{future}} \in \mathbb{R}^{B \times T_{\text{future}} \times C}.$$

预测得到的未来 IMU 序列将与当前 IMU 序列的尾部观测共同作为后续自回归姿态预测的输入，用于实现从当前观测到未来姿态的连续建模。

4) 自回归姿态预测机制

在获得未来 IMU 序列 $\mathbf{X}_{\text{future}}$ 后，为实现未来姿态建模，本文引入自回归姿态预测机制。该机制通过将当前观测信息与预测得到的未来 IMU 序列进行组合，构建扩展时序输入，从而完成对未来姿态的预测。

具体而言，从输入 IMU 序列 $\mathbf{X}_{\text{input}}$ 中截取与预测窗口相邻的尾部序列，并与预测得到的未来 IMU 序列进行拼接，得到扩展序列

$$\mathbf{X}_{\text{extended}} = \text{Concat}(\mathbf{X}_{\text{tail}}, \mathbf{X}_{\text{future}}),$$

其中 $\mathbf{X}_{\text{tail}}$ 表示当前观测序列中与预测阶段相邻的时间片段。通过该方式，将真实观测信息与模型预测信息统一到同一时间序列中。

在此基础上，将扩展后的 IMU 序列再次输入 ResNet 进行特征提取，得到对应的未来时序特征表示

$$\mathbf{F}_{\text{future}} = E(\mathbf{X}_{\text{extended}}).$$

随后，通过姿态预测映射函数对未来姿态进行建模，其过程可表示为

$$\mathbf{P}_{\text{pred}} = f_{\text{pred}}(\mathbf{F}_{\text{future}}),$$

其中 $\mathbf{P}_{\text{pred}}$ 表示未来时间窗口内的人体姿态序列。

通过上述过程，模型能够在当前观测基础上，结合预测得到的 IMU 动态信息，对未来姿态进行建模，实现从当前状态到未来状态的连续预测。

5) 损失函数

为实现当前姿态重构、未来 IMU 预测以及未来姿态预测的联合优化，本文采用多任务学习策略构建整体损失函数。设当前姿态重构结果、未来 IMU 预测结果及未来姿态预测结果分别为 $\mathbf{P}_{\text{rec}}$ 、 $\mathbf{X}_{\text{future}}$ 和 $\mathbf{P}_{\text{pred}}$ ，对应的真实值分别为 $\mathbf{P}_{\text{rec}}^*$ 、 $\mathbf{X}_{\text{future}}^*$ 和 $\mathbf{P}_{\text{pred}}^*$ ，则整体损失函数定义为

$$\mathcal{L} = \alpha \|\mathbf{P}_{\text{rec}} - \mathbf{P}_{\text{rec}}^*\|_1 + \beta \|\mathbf{X}_{\text{future}} - \mathbf{X}_{\text{future}}^*\|_1 + \gamma \|\mathbf{P}_{\text{pred}} - \mathbf{P}_{\text{pred}}^*\|_1,$$

其中 α 、 β 和 γ 为权重系数，用于平衡不同子任务对模型训练的影响。

通过上述联合优化，模型在学习当前姿态重构的同时，能够建模 IMU 时序动态，并进一步提升未来姿态预测的准确性。

4.3 实验与结果分析

4.3.1 实验设置

本章实验在与第三章一致的硬件与软件环境下进行。

在模型训练过程中，采用 Adam 优化器对网络参数进行更新，初始学习率设置为 1×10^{-3} ，训练轮数为 200，批大小为 256。损失函数采用 L1 损失，并对姿态重构、IMU 序列预测以及未来姿态预测三个子任务分别赋予权重系数 $\alpha = 1$ 、 $\beta = 1$ 和 $\gamma = 1$ 。

在数据构建方面，采用滑动窗口方式对原始时序数据进行划分。IMU 输入窗口长度 L_{input} 为 4s，姿态重构窗口长度 L_{rec} 为 1s，姿态预测窗口长度 L_{pred} 为 1s，滑动步长设置为 1s。数据按预设方案划分为训练集与测试集，测试集仅用于最终评估。

在模型结构设置中，IMU 时序特征提取模块采用 ResNet18 结构，IMU 时序预测模块采用 Transformer 结构，其隐藏层维度为 128，层数为 2，注意力头数为 4，Dropout 率为 0.1。人体关键点数量设置为 25，输出为二维坐标形式。

4.3.2 评价指标

为全面地评估模型在人体姿态重构与预测任务中的性能，本文采用平均关节位置误差 (Mean Per Joint Position Error, MPJPE)、关键点正确率 (Percentage of Correct Keypoints, PCK) 以及逐关节平均位置误差 (Per-joint MPJPE) 作为评价指标。MPJPE 用于从整体误差角度衡量预测结果与真实姿态之间的平均偏差；PCK 用于统计预测关键点落入容忍范围内的比例；Per-joint MPJPE 则用于分析不同关节部位上的误差分布，从而更细致地刻画模型性能。

设预测姿态序列为 $\hat{\mathbf{P}} \in \mathbb{R}^{B \times T \times K \times 2}$ ，真实姿态序列为 $\mathbf{P}$ ，其中 B 表示批大小， T 表示时间长度， K 表示关键点数量。

1) MPJPE

MPJPE 定义为

$$\text{MPJPE} = \frac{1}{BTK} \sum_{b=1}^B \sum_{t=1}^T \sum_{k=1}^K \|\hat{p}_{b,t,k} - p_{b,t,k}\|_2. \quad (4-1)$$

其中， $\|\cdot\|_2$ 表示欧氏距离。该指标用于衡量预测关键点与真实关键点之间在图像平面中的平均欧氏距离。由于本文在反归一化后恢复到原始图像坐标系进行计算，因此 MPJPE 的单位为像素 (px)；数值越小表示模型预测精度越高。

2) PCK

PCK 用于衡量预测关键点是否足够接近真实位置。设关键点判定阈值为 δ_{PCK} ，则 PCK 定义为

$$\text{PCK}(\delta_{\text{PCK}}) = \frac{\left| \left\{ (b, t, k) \mid \|\hat{p}_{b,t,k} - p_{b,t,k}\|_2 \leq \delta_{\text{PCK}} \right\} \right|}{BTK}. \quad (4-2)$$

其中, δ_{PCK} 为在原始图像坐标系下设定的关键点判定阈值, 单位为像素 (px)。当预测关键点与真实关键点之间的欧氏距离不超过 δ_{PCK} 时, 认为该关键点预测正确。与 MPJPE 更关注平均误差不同, PCK 从命中率角度补充反映模型的关键点定位能力, 数值越大表示模型性能越好。

3) Per-joint MPJPE

为进一步分析不同身体部位上的误差分布, 本文对每个关键点分别计算平均关节位置误差。对于第 k 个关键点, 其 Per-joint MPJPE 定义为

$$\text{MPJPE}^{(k)} = \frac{1}{BT} \sum_{b=1}^B \sum_{t=1}^T \|\hat{p}_{b,t,k} - p_{b,t,k}\|_2, \quad k = 1, 2, \dots, K. \quad (4-3)$$

该指标能够反映模型在不同关节部位上的误差差异。例如, 躯干、肩部、肘部与腕部等关键点在运动幅度、遮挡情况和可辨识性上往往存在差异, 因此其预测误差也可能不同。通过分析 Per-joint MPJPE, 可以更细致地评估模型对不同关节的建模能力, 并为后续模型改进提供依据。

需要说明的是, 由于模型输出的姿态坐标在归一化空间中表示, 因此在计算上述指标之前, 需要将预测结果与真实值映射回同一坐标尺度。具体而言, 先对模型输出进行截断处理, 将其限制在 $(-0.9999, 0.9999)$ 范围内, 以避免后续反变换时出现数值不稳定; 随后通过反双曲正切函数 $\text{atanh}(\cdot)$ 将数据从 $\tanh$ 空间映射回连续空间, 并结合样本对应的尺度因子恢复关键点坐标, 最终计算 MPJPE、PCK 与 Per-joint MPJPE。

在具体实验中, 可分别对当前姿态重构结果与未来姿态预测结果计算上述指标, 从整体误差、关键点命中率以及关节级误差分布三个角度评估模型性能。

4.3.3 数据集与样本构建

1) 数据集

本章实验同样基于 XRFV2 数据集开展。关于 IMU 数据的采集设备、佩戴位置及原始数据结构, 第三章已进行了详细介绍, 因此本节主要在此基础上补充人体姿态数据的构建过程。

XRFV2 在采集 IMU 数据的同时, 使用 Azure Kinect 对受试者的动作过程进行同步视频记录, 视频分辨率为 720P, 帧率为 15 fps。基于这些 RGB 视频, 本文进一步构建与 IMU 时间同步的人体二维姿态序列, 为后续的人体姿态重构与预测任务提供监督信号。具体而言, 本文采用 OpenPose 算法^[28]对视频进行逐帧处理, 从每一帧图像中提取人体关键点位置。OpenPose 基于 Body25 人体模型, 可检测包括头部、躯干及四肢在内的 25 个关键点, 其关键点定义如图 4-3 所示。

然而, 直接由 OpenPose 提取的二维关键点序列仍存在一定噪声。受遮挡、视角变化及图像质量波动等因素影响, 部分关键点在个别帧中可能无法被稳定检测; 同时, 不同受试者在身高、体型以及与摄像机相对位置上的差异, 也会导致姿态关键点在图像坐标系中的位置与尺度存在明显变化。这些因素都会影响后续模型对姿态时序模式的




图 4-3 OpenPose 25 点模型

学习。为此，本文对原始姿态序列进行了进一步处理：对于置信度为零的关键点，采用时间上相邻的最近有效关键点进行填补，以保证姿态序列在时间维度上的连续性；同时，为减弱个体差异及拍摄尺度差异的影响，对关键点坐标进行中心化与归一化处理，即以躯干中心关键点 **MidHip** 作为参考点进行平移，并以左右肩关键点之间的欧氏距离作为尺度因子进行归一化，具体形式为

$$\hat{p}_{i,k} = \tanh\left(\frac{p_{i,k} - p_{i,c}}{\|p_{i,l} - p_{i,r}\|_2}\right), \quad (4-4)$$

其中， $p_{i,k}$ 表示第 i 帧中第 k 个关键点的二维坐标， $p_{i,c}$ 表示该帧的躯干中心关键点坐标， $p_{i,l}$ 与 $p_{i,r}$ 分别表示左肩与右肩关键点坐标， $\|p_{i,l} - p_{i,r}\|_2$ 表示肩宽尺度因子。当肩宽小于阈值 ϵ 时，将其截断为 ϵ 以避免数值不稳定。图 4-4 展示了姿态处理前后的可视化结果。可以看出，经过关键点填补、中心化与归一化处理后，不同样本的人体姿态在坐标范围和尺度上更加一致，有助于后续模型学习稳定的姿态表示。

2) 样本构建与划分策略

为了构建适用于人体姿态重构与预测任务的训练样本，本文需要从连续采集的 IMU 序列与姿态序列中提取时间对齐的片段。由于 IMU 与姿态数据的采样频率不同，因此在样本构建时，首先基于统一时间轴建立二者之间的对应关系，再按照固定时间窗口从连续序列中截取样本。设 IMU 时间序列为

$$\mathbf{X} = \{x_1, x_2, \dots, x_T\}, \quad x_t \in \mathbb{R}^C, \quad (4-5)$$




图 4-4 姿态中心化归一化示意图

其中， C 表示 IMU 通道数。本文使用 5 个 IMU 设备，每个设备包含三轴加速度与三轴角速度，共 6 个通道，因此 $C = 30$ 。设人体姿态序列为

$$\mathbf{P} = \{p_1, p_2, \dots, p_N\}, \quad p_i \in \mathbb{R}^{K \times 2}, \quad (4-6)$$

其中， $K = 25$ 表示人体关键点数量。

图 ?? 给出了样本构建过程的时间结构示意图。对于任一样本，其参考时刻 t 表示该样本时间窗口的结束时刻。以该时刻为参照，本文从连续序列中分别截取当前 IMU 输入序列、未来 IMU 监督序列、当前姿态监督序列以及未来姿态监督序列，从而构建用于姿态重构与预测的监督样本。

设 IMU 采样频率为 f_{imu} ，姿态数据帧率为 f_{pose} ，当前 IMU 输入窗口长度为 L_{input} ，当前姿态重构窗口长度为 L_{rec} ，以及未来姿态预测窗口长度 L_{pred} ，三个窗口长度均以秒为单位。在此基础上，样本中各部分定义如下：

$$\mathbf{X}_{\text{input}} = \mathbf{X} \left[(t - (L_{\text{input}} + L_{\text{rec}}))f_{\text{imu}} : (t - L_{\text{rec}})f_{\text{imu}} \right], \quad (4-7)$$

$$\mathbf{X}_{\text{future}} = \mathbf{X}[(t - L_{\text{rec}})f_{\text{imu}} : tf_{\text{imu}}], \quad (4-8)$$

$$\mathbf{P}_{\text{rec}} = \mathbf{P}[(t - (L_{\text{rec}} + L_{\text{pred}}))f_{\text{pose}} : (t - L_{\text{pred}})f_{\text{pose}}], \quad (4-9)$$

$$\mathbf{P}_{\text{pred}} = \mathbf{P}[(t - L_{\text{pred}})f_{\text{pose}} : tf_{\text{pose}}], \quad (4-10)$$

$$\mathcal{S} = \{\mathbf{X}_{\text{input}}, \mathbf{X}_{\text{future}}, \mathbf{P}_{\text{rec}}, \mathbf{P}_{\text{pred}}\}. \quad (4-11)$$

其中, $\mathbf{X}_{\text{input}}$ 表示当前 IMU 输入序列, 用于提供姿态重构与预测的先验信息; $\mathbf{X}_{\text{future}}$ 表示与未来姿态预测阶段对应的 IMU 序列; $\mathbf{P}_{\text{rec}}$ 表示当前人体姿态序列, 用于当前姿态重构任务; $\mathbf{P}_{\text{pred}}$ 表示未来人体姿态序列, 用于未来姿态预测任务。由此, 一个完整样本由上述四个部分共同构成。

在数据集划分策略方面, 本章采用与第三章一致的同分布和跨受试者划分方式, 而不再采用跨场景划分方式。这是因为不同场景中的摄像机视角、人体活动区域以及姿态空间分布存在显著差异, 若直接进行跨场景划分, 将引入较强的分布偏移, 使实验结果更多反映场景差异, 而非模型本身的姿态建模能力。因此, 本章重点关注同分布与跨受试者条件下的人体姿态重构与预测性能。

4.3.4 方法对比实验

为了评估 AIPOSE 在基于 IMU 的人体姿态建模任务中的性能, 本文选取了近年来具有代表性的惯性人体姿态方法作为对比对象, 包括 PIP^[7]、TIP^[8]、IMUPoser^[9]、DynaIP^[11]、ASIP^[12]以及 MobilePoser^[10]。

需要说明的是, 所选基线大多原本面向三维人体姿态估计或不同设备配置下的稀疏 IMU 建模任务, 且未针对未来姿态预测进行专门设计。为在统一实验设置下进行比较, 本文将“当前姿态重构”作为所有方法共享的对比任务, 保留各基线核心时序建模模块, 仅将输出层替换为与本文一致的二维关键点回归头, 并统一采用相同的数据划分、训练轮数、优化器和评价指标进行重新训练。因此, 本节比较的重点并非复现原文在其原始任务上的最优结果, 而是考察不同时序建模策略在当前 XRFV2 二维关键点建模任务中的相对表现。

从表 4-1 可以看出, AIPOSE 在当前姿态重构任务上取得了最低的 MPJPE, 重构误差为 47.8203, 明显优于所有对比方法。对比方法中, 表现最好的 PIP 重构 MPJPE 为 67.6973, AIPOSE 较其进一步降低了 19.8770。与 ASIP、TIP 和 DynaIP 相比, AIPOSE 的误差分别降低了 23.1295、25.3064 和 27.6074; 相较于 IMUPoser 和 MobilePoser, 优势更加明显。说明在本文任务设置下, AIPOSE 能够更有效地利用 IMU 时序信息完成人体姿态重构。除当前姿态重构外, AIPOSE 的未来姿态预测 MPJPE 为 54.1138。该结果表明, AIPOSE 不仅能够较准确地重构当前人体姿态, 还能够基于历史 IMU 观测, 在统一

框架下实现当前姿态重构与未来姿态预测。

表 4-1 不同方法在当前姿态重构任务中的对比结果

Method	MPJPE (px)	PCK@5px (%)	PCK@10px (%)	PCK@20px (%)
PIP ^[7]	66.9574	14.41	23.11	38.13
TIP ^[8]	72.0478	13.63	21.66	35.91
IMUPoser ^[9]	92.7077	9.27	14.62	24.92
DynaIP ^[11]	76.1834	13.02	20.25	33.07
ASIP ^[12]	70.9250	14.14	22.13	35.83
MobilePoser ^[10]	96.5019	9.01	14.01	23.64
AIPOSE (Ours)	52.2019	16.13	26.86	44.55




图 4-5 不同方法在当前姿态重构任务中各关键点的 MPJPE

为了进一步观察不同方法在训练过程中的表现，图 4-6 给出了各方法在测试集上的姿态重构 MPJPE 随训练轮数变化的曲线。可以看出，AIPOSE 在训练早期即表现出较快的误差下降速度，整体收敛过程也较为平稳，进一步说明 AIPOSE 在当前姿态重构任务上具有较好的训练稳定性。

4.3.5 骨干网络选择实验

为分析不同时序建模结构对模型性能的影响，本文对 IMU 时序预测模块中的骨干网络进行对比实验。

在实验中，固定 IMU 时序特征提取模块为 ResNet 结构，并分别采用 Transformer、LSTM、GRU 以及 Mamba 作为 IMU 时序预测模块的骨干网络，其余训练参数保持一




图 4-6 不同方法在当前姿态重构任务中的 MPJPE

致。分别计算不同结构下的姿态重构误差与姿态预测误差。

实验结果如图 4-7 所示，从图中可以看出，不同时序建模结构对模型性能具有明显影响。其中，采用 Transformer 结构时，模型在姿态重构与姿态预测任务上均取得最优结果；GRU 与 LSTM 次之，而 Mamba 结构的性能明显低于其他方法。该结果表明，在当前任务设置下，Transformer 更适合用于未来 IMU 序列建模。

4.3.6 样本构建与数据处理实验

1) 样本构建实验

为分析 IMU 输入序列长度对模型性能的影响，本文设置不同长度的 IMU 观测窗口进行对比实验。在实验中，保持模型结构及其他训练参数不变，仅调整输入 IMU 序列长度，并分别计算对应的姿态重构误差与姿态预测误差。

实验结果如图 4-8 所示，从图中可以看出，随着 IMU 输入长度增加，模型误差整体呈下降趋势。当输入长度由 1s 增加到 4s 时，姿态重构误差和姿态预测误差均明显下降，说明适当延长观测窗口有助于模型获得更充分的时序信息。继续增大输入长度时，模型性能仍有提升，但改进幅度相对减小，同时会带来更长的观测时延和更高的计算开销。

2) 数据标准化实验

为分析数据标准化策略对模型性能的影响，本文设计标准化实验，分别考察 IMU 数据与姿态数据的统计标准化对模型性能的影响。

需要说明的是，第 4.2.2 节中的姿态中心化与尺度归一化属于样本构建阶段的基础预处理，而本节讨论的“数据标准化”是指在此基础上，是否进一步对 IMU 输入和姿




图 4-7 骨干网络选择实验结果

态目标进行统计意义上的标准化处理。因此，两者含义不同。

在实验中，模型结构及训练参数保持一致，仅调整输入数据的预处理方式。具体而言，分别设置 IMU 数据与姿态数据是否进行标准化处理，形成四种组合情况，并在各设置下计算模型的姿态重构误差与姿态预测误差。

实验结果如图 4-9 所示，从图中可以看出，数据标准化策略对模型性能具有明显影响。相比不进行标准化处理，对 IMU 数据进行标准化能够有效降低模型误差，说明统一 IMU 数据的数值分布有助于提升时序特征建模的稳定性。当仅对姿态数据进行标准化时，模型性能反而出现明显下降，这说明单独改变目标空间的数值分布并不能直接提升学习效果，反而可能增加映射学习的难度。当同时对 IMU 数据与姿态数据进行标准化处理时，模型取得最佳性能，说明在当前任务设置下，输入空间与目标空间采用更一致的数值尺度，有助于模型建立稳定映射关系。

4.3.7 传感器消融实验

为分析不同 IMU 传感器对模型性能的贡献，本文设计传感器消融实验。通过在输入数据中去除部分传感器数据，观察模型在姿态重构与姿态预测任务上的性能变化，从而评估各传感器的重要性。

在实验中，模型结构及训练参数保持不变，仅对输入 IMU 数据进行调整。原始设置包含 5 个 IMU 传感器（编号为 0 至 4），分别移除单个或多个传感器后重新进行模型评估。

实验结果如图 4-10 所示，从图中可以看出，当不移除任何传感器时，模型性能最为稳定。移除单个传感器后，整体误差均有所上升，但不同传感器对性能的影响程度




图 4-8 样本构建实验结果

存在差异。其中，移除编号为 0 的传感器时，姿态重构与预测误差均出现较明显增加，说明该传感器在模型建模过程中具有较高的重要性。相比之下，移除编号为 2 或 4 的传感器对模型性能影响相对较小，表明部分传感器之间可能存在一定的信息冗余。当同时移除多个传感器（如 2 和 4）时，模型性能下降更加明显，说明多传感器信息融合对于姿态建模具有重要作用。




图 4-10 传感器消融实验结果




图 4-9 数据标准化实验结果

总体来看，不同 IMU 设备在人体姿态建模中发挥的作用并不完全相同，其中部分关键传感器对模型性能影响更为显著。该结果表明，合理的传感器配置对于提升模型性能具有重要意义。

4.3.8 泛化实验

为评估所提出模型在不同数据分布下的泛化能力，本文设计跨场景与跨受试者实验。两组实验均采用留一法评估方式，即在训练阶段使用除目标测试集之外的数据进行训练，并在测试阶段仅在未参与训练的数据上进行评估。

通过该设置，可以较好地模拟模型在未知环境或未知用户条件下的实际应用性能，从而更加全面地评估模型的泛化能力。

1) 跨场景实验

为分析模型在不同环境条件下的泛化能力，本文采用留一场景法进行实验。具体而言，每次选取一个场景作为测试集，其余场景数据用于训练，从而评估模型在未见场景上的表现。

实验结果如表 4-2 所示，从表中可以看出，模型在不同测试场景下的性能存在一定差异。其中，在“餐厅”与“书房”场景下模型表现相对较好，而在“卧室”场景下误差明显较高。这说明环境变化会对模型性能产生较大影响，不同场景中的空间布局、动作分布以及采集条件差异，都可能影响 IMU 与姿态之间的映射关系。

表 4-2 跨场景实验模型性能

ID	当前姿态重构				未来姿态预测			
	MPJPE	PCK@5	PCK@10	PCK@20	MPJPE	PCK@5	PCK@10	PCK@20
0	204.38	4.26	5.98	9.25	227.20	4.33	6.04	9.26
1	149.23	3.59	5.29	9.48	157.64	3.62	5.33	9.57
2	140.34	3.82	5.78	9.88	144.85	4.04	5.97	10.03
Mean	164.65	3.89	5.68	9.54	176.57	4.00	5.78	9.62

总体来看, 尽管跨场景条件下模型性能有所下降, 但仍能够保持一定的姿态重构与预测能力, 说明所提出方法具备一定的跨环境泛化能力。

2) 跨受试者实验

为进一步评估模型在不同个体之间的泛化能力, 本文采用留一受试者法进行实验。具体而言, 每次选取一名志愿者作为测试对象, 其余志愿者数据用于训练, 从而评估模型在未见受试者上的表现。

实验结果如表 4-3 所示, 从表中可以看出, 模型在不同受试者上的性能存在一定波动, 但整体误差范围相对稳定。部分受试者 (如编号 2、12) 对应的误差较低, 而个别受试者 (如编号 4) 误差相对较高, 这可能与个体运动模式差异、体型差异或传感器佩戴方式差异有关。

表 4-3 跨受试者实验模型性能

ID	当前姿态重构				未来姿态预测			
	MPJPE	PCK@5	PCK@10	PCK@20	MPJPE	PCK@5	PCK@10	PCK@20
1	106.06	5.53	9.12	15.23	113.27	5.56	9.15	15.38
2	89.85	7.74	12.25	21.41	94.82	8.05	12.44	21.02
3	108.81	6.02	9.45	16.59	112.94	6.20	9.55	16.53
4	126.74	5.25	7.57	12.41	138.22	5.48	7.84	12.65
5	104.77	7.44	11.77	20.06	113.25	7.44	11.74	19.88
6	96.79	6.35	11.02	19.67	102.72	6.51	11.07	19.55
7	110.76	7.11	11.54	20.42	120.40	7.69	12.22	21.04
8	116.00	8.04	11.14	17.70	124.32	8.58	11.58	17.96
9	95.69	4.64	9.38	18.19	101.93	4.84	9.65	18.36
10	98.37	7.82	11.81	19.00	104.05	8.00	11.88	18.84
11	104.81	6.72	10.50	17.71	113.36	6.97	10.82	18.00
12	87.90	7.75	12.53	21.09	94.47	7.96	12.64	20.97
13	92.30	6.47	11.33	20.02	99.47	6.76	11.50	19.80
14	105.48	7.25	11.24	19.04	112.43	7.34	11.13	18.50
15	118.60	5.94	10.32	18.35	127.34	6.45	10.59	18.27
Mean	104.19	6.67	10.73	18.46	111.53	6.92	10.92	18.45

总体而言，模型在跨受试者条件下能够保持相对稳定的性能，说明其在不同个体之间具有一定的泛化能力。但与同分布测试相比，跨受试者实验仍存在明显性能下降，这也说明个体差异仍是影响 IMU 姿态建模稳定性的关键因素之一。

4.3.9 长时姿态预测实验

为分析模型在时间维度上的预测性能变化，本文对不同时间区间内的姿态误差进行统计，从而评估模型在当前重构与未来预测任务中的表现差异。具体而言，以当前时间点为参考，将时间轴划分为多个连续区间，并分别计算各区间内的平均 MPJPE。其中，区间 $[-1, 0)$ 表示当前时间窗口内的姿态重构结果，其余区间 $[0, +\infty)$ 表示未来时间范围内的姿态预测结果。

实验结果如图 4-11 所示，从图中可以看出，在当前时间窗口内（即区间 $[-1, 0)$ ），模型能够获得较低误差，说明基于 IMU 特征进行姿态重构具有较高精度。随着时间进入未来预测阶段（ $t \geq 0$ ），模型误差随预测时间增加而逐步上升。在较短预测区间内，误差增长相对平缓；而在更远时间范围内，误差增长速度明显加快。这表明随着预测步长增加，误差会逐渐累积，模型对长期运动变化的刻画能力受到一定限制。




图 4-11 长时姿态预测实验结果

总体来看，模型在当前姿态重构任务中表现较为稳定，在短期预测范围内仍具有较好的精度，但在中长期预测中性能逐渐下降。该结果说明，所提出方法更适合短时姿态预测场景，同时也表明预测长度对模型性能具有显著影响。

4.4 本章小结

本章围绕 AIPose 模型，从任务定义、数据构建、模型设计和实验分析等方面展开研究。所提出方法以 IMU 时序信号为输入，在统一框架下同时完成当前姿态重构与未来短时姿态预测，并通过自回归建模机制实现从当前观测到未来姿态的连续建模。实验结果表明，AIPose 在当前姿态重构任务上优于多种代表性惯性姿态方法，同时具备未来姿态预测能力；IMU 观测窗口长度、时序预测骨干网络、传感器配置以及数据标准化策略都会对模型性能产生明显影响。泛化实验进一步表明，模型在跨场景与跨受试者条件下仍具有一定稳定性，但环境变化和个体差异依然会带来性能下降。总体而言，本章验证了基于 IMU 的人体姿态重构与短时预测的可行性，也说明未来姿态建模能够为人体运动理解提供更完整的时间信息。

5 结论与展望

5.1 结论

本文围绕基于非视觉传感器的人体行为感知问题，针对多模态人体活动识别中的异构特征对齐与融合、跨受试者场景下的泛化能力，以及基于 IMU 的人体姿态重构与预测开展研究，主要结论如下。

首先，在人体活动识别任务中，本文提出了基于多模态特征对齐与融合的人体活动识别方法 WIHAR。该方法分别对 IMU 与 WiFi CSI 时序数据进行特征建模，通过双向跨模态对比学习缩小两种模态之间的语义差异，并利用交叉注意力机制实现模态间的信息交互与融合。在此基础上，结合基于类别原型的跨受试者适配策略，对跨受试者场景下的分布偏移问题进行了缓解。实验结果表明，WIHAR 在 XRFV2 数据集上的活动识别准确率达到 96.06%。在跨受试者实验中，模型在未适配时的平均识别准确率为 72.57%，在引入少量目标受试者样本进行适配后可提升至 90.99%。这些结果说明，IMU 与 WiFi CSI 在人体活动感知中具有较强的互补性，合理的跨模态对齐与融合策略以及跨受试者适配机制能够有效提升复杂室内环境下的人体活动识别性能。

其次，在人体姿态重构与预测任务中，本文提出了基于自回归建模机制的方法 AIPose。该方法仅使用 IMU 数据作为输入，通过 IMU 特征提取、当前姿态重构和未来 IMU 预测等模块构建统一建模框架，在完成当前人体姿态重构的同时，对未来短时姿态变化进行预测。实验结果表明，在关键点坐标空间中，AIPose 在 XRFV2 数据集上的当前姿态重构平均关节位置误差为 47.82，未来姿态预测平均关节位置误差为 54.11。相关结果表明，基于 IMU 的自回归建模不仅能够较准确地完成当前人体姿态重构，也能够对未来短时运动变化进行有效建模。

总体来看，本文分别从多模态特征对齐与融合、跨受试者少样本适配以及人体运动时序建模三个方面，对基于非视觉传感器的人体行为感知问题进行了研究。研究结果表明，基于 IMU 与 WiFi CSI 的多模态方法能够较好支持室内环境下的人体活动识别，而基于 IMU 的自回归建模方法也为人体姿态重构与短时预测提供了可行思路。上述工作从活动语义理解与姿态动态建模两个层面，为非视觉人体感知研究提供了补充。

5.2 展望

尽管本文取得了较为完整的阶段性结果，但仍有若干问题值得进一步研究。

首先，本文提出的活动识别方法在同受试者设置下的测试中表现较好，但在跨受试者场景下仍存在明显性能下降，说明模型对个体差异和环境变化仍较为敏感。后续可进一步研究更加稳定的跨域表征学习方法，例如结合自监督预训练、域泛化或无监督适配策略，减少模型对目标受试者标注数据的依赖，并提升模型在新受试者和新场

景下的直接泛化能力。

其次，本文的人体姿态方法已经能够实现较好的当前重构和短时预测，但随着预测时间增长，误差仍会逐步累积。后续可以从两个方面继续完善：一方面，可引入更强的时序约束与人体结构约束，以提升长时间预测的稳定性；另一方面，可探索更加合理的姿态表示方式与监督形式，以增强模型对复杂运动过程的表达能力。

最后，本文两个任务分别侧重于多模态活动识别和基于 IMU 的姿态建模，尚未在统一框架下实现更深层的联合建模。后续可以探索将活动语义信息与姿态变化过程进行协同建模，进一步挖掘不同任务之间的互补关系。同时，在实际部署层面，还需要围绕传感器数量、佩戴方式、系统实时性以及长期使用稳定性开展更系统的评估，以提高方法在智慧康养、人机交互和居家监测等场景中的应用可行性。

致 谢

值此论文落稿之际，谨向所有支持和帮助过我的人致以最诚挚的谢意。

回首往事，感叹时光飞逝。虽然深知自己仍有许多不完善之处，但前方的道路已然清晰。我将带着这份感恩与期许，在未来的职业道路上更加努力，不断完善自我，追求卓越。

参考文献

- [1] Miao S, Chen L, Hu R. Spatial-temporal masked autoencoder for multi-device wearable human activity recognition[J]. Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies, 2024, 7(4): 1-25.
- [2] Li S, Zhu T, Duan F, et al. HARMamba: Efficient and lightweight wearable sensor human activity recognition based on bidirectional mamba[J]. IEEE Internet of Things Journal, 2024, 12(3): 2373-2384.
- [3] Gao Z, Wang Y, Chen J, et al. MMTSA: Multi-modal temporal segment attention network for efficient human activity recognition[J]. Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies, 2023, 7(3): 1-26.
- [4] Hong Z, Li Z, Zhong S, et al. Crosshar: Generalizing cross-dataset human activity recognition via hierarchical self-supervised pretraining[J]. Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies, 2024, 8(2): 1-26.
- [5] Dai G, Xu H, Yoon H, et al. ContrastSense: Domain-invariant contrastive learning for in-the-wild wearable sensing[J]. Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies, 2024, 8(4): 1-32.
- [6] Zhu G, Zhao D, Li C, et al. MASTER: A multi-modal foundation model for human activity recognition[J]. Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies, 2025, 9(3): 1-26.
- [7] Yi X, Zhou Y, Habermann M, et al. Physical inertial poser (pip): Physics-aware real-time human motion tracking from sparse inertial sensors[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 13167-13178.
- [8] Jiang Y, Ye Y, Gopinath D, et al. Transformer inertial poser: Real-time human motion reconstruction from sparse imus with simultaneous terrain generation[C]//SIGGRAPH Asia 2022 Conference Papers. 2022: 1-9.
- [9] Mollyn V, Arakawa R, Goel M, et al. Imuposer: Full-body pose estimation using imus in phones, watches, and earbuds[C]//Proceedings of the 2023 CHI Conference on Human Factors in Computing Systems. 2023: 1-12.
- [10] Xu V, Gao C, Hoffmann H, et al. Mobileposer: Real-time full-body pose estimation and 3d human translation from imus in mobile consumer devices[C]//Proceedings of the 37th Annual ACM Symposium on User Interface Software and Technology. 2024: 1-11.
- [11] Zhang Y, Xia S, Chu L, et al. Dynamic inertial poser (dynaip): Part-based motion dynamics learning for enhanced human pose estimation with sparse inertial sensors[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 1889-1899.
- [12] Wu Y, Wang C, Yin L, et al. Accurate and steady inertial pose estimation through sequence structure learning and modulation[J]. Advances in Neural Information Processing Systems, 2024, 37: 42468-42493.
- [13] Van Wouwe T, Lee S, Falisse A, et al. Diffusionposer: Real-time human motion reconstruction from

- arbitrary sparse sensors using autoregressive diffusion[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 2513-2523.
- [14] Chen L H, Zhang J, Li Y, et al. Humanmac: Masked motion completion for human motion prediction [C]//Proceedings of the IEEE/CVF international conference on computer vision. 2023: 9544-9555.
- [15] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [16] Gu A, Dao T. Mamba: Linear-time sequence modeling with selective state spaces[C]//First conference on language modeling. 2024.
- [17] Sepahvand M, Meqdad M N, Abdali-Mohammadi F. State-of-the-art in human activity recognition based on inertial measurement unit sensors: survey and applications[J]. International Journal of Computers and Applications, 2025, 47(1): 1-16.
- [18] Contoli C, Freschi V, Lattanzi E. Energy-aware human activity recognition for wearable devices: A comprehensive review[J]. Pervasive and Mobile Computing, 2024, 104: 101976.
- [19] Alarfaj M, Al Madini A, Alsafran A, et al. Wearable sensors based on artificial intelligence models for human activity recognition[J]. Frontiers in artificial intelligence, 2024, 7: 1424190.
- [20] Varga D. Mitigating data leakage in a wifi csi benchmark for human action recognition[J]. Sensors, 2024, 24(24): 8201.
- [21] Quy T D, Lin C Y, Shih T K. Enhanced human activity recognition using wi-fi sensing: Leveraging phase and amplitude with attention mechanisms[J]. Sensors, 2025, 25(4): 1038.
- [22] Dao T, Gu A. Transformers are ssms: Generalized models and efficient algorithms through structured state space duality[J]. arXiv preprint arXiv:2405.21060, 2024.
- [23] Ni J, Tang H, Haque S T, et al. A survey on multimodal wearable sensor-based human action recognition[J]. arXiv preprint arXiv:2404.15349, 2024.
- [24] Radford A, Kim J W, Hallacy C, et al. Learning transferable visual models from natural language supervision[C]//International conference on machine learning. 2021: 8748-8763.
- [25] Choi H, Beedu A, Essa I. Multimodal contrastive learning with hard negative sampling for human activity recognition[J]. arXiv preprint arXiv:2309.01262, 2023.
- [26] Abedin A, Ehsanpour M, Shi Q, et al. Attend and discriminate: Beyond the state-of-the-art for human activity recognition using wearable sensors[J]. Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies, 2021, 5(1): 1-22.
- [27] Zhou Y, Zhao H, Huang Y, et al. Tinyhar: A lightweight deep learning model designed for human activity recognition[C]//Proceedings of the 2022 ACM International Symposium on Wearable Computers. 2022: 89-93.
- [28] Cao Z, Hidalgo G, Simon T, et al. Openpose: Realtime multi-person 2d pose estimation using part affinity fields[J]. IEEE transactions on pattern analysis and machine intelligence, 2019, 43(1): 172-186.

攻读学位期间取得的研究成果

答辩委员会会议决议

答辩委员会表决，一致同意通过论文答辩，并建议授邢立豹软件工程专业工程硕士学位。

常规评阅人名单

本学位论文共接受 7 位专家评阅，其中常规评阅人 5 名，名单如下：

朱利	教授	西安交通大学
徐亦飞	副教授	西安交通大学

学位论文独创性声明 (1)

本人声明：所呈交的学位论文系在导师指导下本人独立完成的研究成果。文中依法引用他人的成果，均已做出明确标注或得到许可。论文内容未包含法律意义上已属于他人的任何形式的研究成果，也不包含本人已用于其他学位申请的论文或成果。

本人如违反上述声明，愿意承担以下责任和后果：

1. 交回学校授予的学位证书；
2. 学校可在相关媒体上对作者本人的行为进行通报；
3. 本人按照学校规定的方式，对因不当取得学位给学校造成的名誉损害，进行公开道歉。
4. 本人负责因论文成果不实产生的法律纠纷。

论文作者 (签名)： 日期： 年 月 日

学位论文独创性声明 (2)

本人声明：研究生 所提交的本篇学位论文已经本人审阅，确系在本人指导下由该生独立完成的研究成果。

本人如违反上述声明，愿意承担以下责任和后果：

1. 学校可在相关媒体上对本人的失察行为进行通报；
2. 本人按照学校规定的方式，对因失察给学校造成的名誉损害，进行公开道歉。
3. 本人接受学校按照有关规定做出的任何处理。

指导教师 (签名)： 日期： 年 月 日

学位论文知识产权权属声明

我们声明，我们提交的学位论文及相关的职务作品，知识产权归属学校。学校享有以任何方式发表、复制、公开阅览、借阅以及申请专利等权利。学位论文作者离校后，或学位论文导师因故离校后，发表或使用学位论文或与该论文直接相关的学术论文或成果时，署名单位仍然为西安交通大学。

论文作者 (签名)： 日期： 年 月 日

指导教师 (签名)： 日期： 年 月 日

(本声明的版权归西安交通大学所有，未经许可，任何单位及任何个人不得擅自使用)