

西安交通大学

硕士学位论文

面向非视觉人体感知的人体活动识别与姿态重构算法研究

学位申请人：邢立豹

指导教师：王飞 副教授

类别（领域）：工程硕士（软件工程）

2026 年 04 月

**Research on Human Activity Recognition and Pose
Reconstruction Algorithms for Non-Visual Human Sensing**

A thesis submitted to
Xi'an Jiaotong University
in partial fulfillment of the requirements
for the degree of
Master of Engineering

By
Libao Xing
Supervisor: Associate Prof. Fei Wang
Master of Engineering (Software Engineering)
April 2026

硕士学位论文答辩委员会

面向非视觉人体感知的人体活动识别与姿态重构算法研究

答辩人：邢立豹

答辩委员会委员：

西安交通大学教授：朱利 (注：主席)

西安交通大学副教授：徐亦飞

答辩时间：2026 年 05 月 06 日

答辩地点：西安交通大学创新港鸿理楼 4-3202

摘要

随着智能穿戴设备与人工智能技术的发展，基于非视觉传感器的人体运动状态建模已成为智能感知领域的重要研究方向。相较于传统视觉方法，非视觉感知具有隐私友好、部署灵活和环境适应性强等优势。惯性测量单元（Inertial Measurement Unit, IMU）可连续采集人体运动中的加速度与角速度等动力学信息，WiFi 信号中的信道状态信息（Channel State Information, CSI）则能够反映人体运动对无线传播环境的扰动。然而，现有方法在多模态特征融合、跨受试者泛化以及未来状态预测等方面仍存在不足。为此，本文围绕人体活动识别与人体姿态重构两个任务展开研究，由活动语义识别进一步延伸至运动状态建模与预测。

在人体活动识别任务中，针对 IMU 与 WiFi CSI 在信号形式与特征分布上存在显著差异，导致多模态特征难以有效融合，以及跨受试者泛化能力不足的问题，本文提出一种基于多模态对齐与融合的人体活动识别方法 **WIHAR**。该方法首先利用双分支时序编码网络提取 IMU 与 WiFi CSI 的模态特征，在此基础上引入跨模态双向对比学习策略，通过构建批内跨模态相似度矩阵，将两种模态映射到统一语义空间，从而减小异构模态之间的表示偏差；随后通过交叉注意力机制实现模态间的细粒度特征交互，提升融合特征的判别能力。进一步地，针对跨受试者场景下模型性能下降的问题，本文设计了一种基于类别原型的跨受试者适配策略，通过源域类别原型引导目标域特征向共享语义空间聚合，从而提升模型对新受试者的适应能力。实验结果表明，在 **XRFBV2** 数据集上，**WIHAR** 的人体活动识别准确率达到 95.81%；在跨受试者设置下，通过少量目标受试者数据微调，模型平均准确率可由 72.57% 提升至 90.99%。

在人体姿态重构任务中，针对现有方法主要关注当前姿态重构、缺乏未来姿态预测能力的问题，本文提出一种基于自回归建模机制的人体姿态重构与预测方法 **AIPose**。该方法以 IMU 序列为输入，构建由 IMU 特征提取模块、姿态重构模块、IMU 预测模块以及自回归建模机制组成的统一建模框架：使用当前 IMU 序列进行当前人体姿态重构的同时预测未来 IMU 序列，并通过自回归方式将 IMU 预测序列用于未来姿态重构，从而实现未来姿态预测。实验结果表明，**AIPose** 在 **XRFBV2** 数据集上的当前姿态重构平均关节位置误差为 52.20 px，未来姿态预测平均关节位置误差为 57.36 px。

综上，本文分别提出了面向人体活动识别的 **WIHAR** 方法和面向姿态重构与预测的 **AIPose** 方法，为复杂室内环境下隐私友好、可部署的非视觉人体感知提供了可行的技术路径。

关键词：活动识别；姿态重构与预测；多模态融合；跨模态对齐；自回归建模

论文类型：应用研究

ABSTRACT

With the development of intelligent wearable devices and artificial intelligence technologies, human motion state modeling based on non-visual sensors has become an important research direction in intelligent sensing. Compared with traditional vision-based methods, non-visual sensing is more privacy-preserving, more flexible in deployment, and more adaptable to environmental changes. Inertial Measurement Units (IMUs) can continuously capture dynamic information such as acceleration and angular velocity during human motion, while Channel State Information (CSI) in WiFi signals can reflect disturbances caused by human motion in the wireless propagation environment. However, existing methods still suffer from limitations in multimodal feature fusion, cross-subject generalization, and future state prediction. To address these issues, this thesis investigates two tasks, namely human activity recognition and human pose reconstruction, and further extends activity semantic recognition to human motion state modeling and prediction.

For the human activity recognition task, to address the significant differences in signal forms and feature distributions between IMU and WiFi CSI, which hinder effective multimodal fusion, as well as the limited cross-subject generalization ability, a multimodal alignment and fusion-based method, termed WIHAR, is proposed. Specifically, a dual-branch temporal encoding network is first employed to extract modality-specific features from IMU and WiFi CSI. Then, a bidirectional cross-modal contrastive learning strategy is introduced to map the two modalities into a shared semantic space by constructing a batch-wise cross-modal similarity matrix, thereby reducing the representation gap between heterogeneous modalities. Subsequently, a cross-attention mechanism is applied to enable fine-grained feature interaction across modalities, enhancing the discriminative capability of the fused representation. Furthermore, to mitigate performance degradation in cross-subject scenarios, a prototype-based cross-subject adaptation strategy is designed, where source-domain class prototypes guide target-domain features toward the shared semantic space, improving adaptability to unseen subjects. Experimental results show that WIHAR achieves an accuracy of 95.81% on the XRFV2 dataset. Under cross-subject settings, the average accuracy can be improved from 72.57% to 90.99% with a small amount of target-subject data for fine-tuning.

For the human pose reconstruction task, to overcome the limitation that existing methods mainly focus on current pose reconstruction while lacking the ability to predict future poses, an autoregressive modeling-based method, named AIPose, is proposed for both pose reconstruction and prediction. Taking IMU sequences as input, AIPose establishes a unified modeling

framework composed of an IMU feature extraction module, a pose reconstruction module, an IMU prediction module, and an autoregressive modeling mechanism. Specifically, the current IMU sequence is used to reconstruct the current human pose while simultaneously predicting the future IMU sequence, and the predicted IMU sequence is further utilized in an autoregressive manner for future pose reconstruction, thereby enabling future pose prediction. Experimental results show that, on the XRFV2 dataset, AIPose achieves a Mean Per Joint Position Error of 52.20 px for current pose reconstruction and 57.36 px for future pose prediction.

Overall, this thesis proposes WIHAR and AIPose for activity recognition and pose reconstruction and prediction in non-visual human sensing, providing a feasible technical path toward privacy-preserving and deployable human sensing systems in complex indoor environments.

KEY WORDS: Activity recognition; Pose reconstruction and prediction; Multimodal fusion; Cross-modal alignment; Autoregressive modeling

TYPE OF THESIS: Application Research

目 录

摘 要.....	I
ABSTRACT	III
1 绪论	1
1.1 选题意义与应用背景	1
1.2 国内外研究现状分析	2
1.2.1 人体活动识别方法研究现状.....	2
1.2.2 人体姿态重构方法研究现状.....	3
1.3 论文的主要研究内容	4
1.4 论文的组织结构	5
2 相关理论与技术.....	7
2.1 传感器	7
2.1.1 惯性测量单元.....	7
2.1.2 WiFi 信道状态信息.....	8
2.2 深度学习时序建模网络	9
2.2.1 Transformer.....	9
2.2.2 Mamba	10
2.3 多模态特征对齐与融合	11
2.3.1 对比学习.....	11
2.3.2 交叉注意力机制.....	13
2.4 自回归建模机制	13
2.5 本章小结	14
3 基于多模态对齐与融合的人体活动识别.....	15
3.1 问题描述	15
3.2 方法描述	16
3.2.1 整体方法框架.....	16
3.2.2 WIHAR 模型.....	17
3.2.3 基于类别原型的跨受试者适配策略.....	23
3.3 实验与结果分析	25
3.3.1 实验设置.....	25
3.3.2 数据集与划分策略.....	25
3.3.3 评价指标.....	27
3.3.4 方法对比实验.....	28
3.3.5 模型架构与训练策略实验.....	30

3.3.6 样本构建实验.....	33
3.3.7 模态和设备消融实验.....	34
3.3.8 跨受试者泛化实验.....	35
3.4 本章小结	37
4 基于自回归建模机制的人体姿态重构与预测	38
4.1 问题描述	38
4.2 方法描述	39
4.2.1 整体方法框架.....	39
4.2.2 AIPose 模型	40
4.3 实验与结果分析	44
4.3.1 实验设置.....	44
4.3.2 数据集与样本构建.....	44
4.3.3 评价指标.....	48
4.3.4 方法对比实验.....	50
4.3.5 骨干网络选择实验.....	54
4.3.6 样本构建与数据处理实验.....	55
4.3.7 设备消融实验.....	57
4.3.8 泛化实验.....	58
4.3.9 长时姿态预测实验.....	59
4.4 本章小结	60
5 总结和展望	61
5.1 总结	61
5.2 展望	62
致谢.....	63
参考文献.....	64
攻读学位期间取得的研究成果.....	69
答辩委员会会议决议.....	70
常规评阅人名单.....	71
声明	

CONTENTS

ABSTRACT (Chinese).....	I
ABSTRACT (English)	III
1 Introduction	1
1.1 Research Significance and Application Background	1
1.2 Related Work.....	2
1.2.1 Research on Human Activity Recognition	2
1.2.2 Research on Human Pose Reconstruction	3
1.3 Main Research Content	4
1.4 Organization of the Thesis	5
2 Related Theories and Techniques	7
2.1 Sensors.....	7
2.1.1 Inertial Measurement Unit.....	7
2.1.2 WiFi Channel State Information	8
2.2 Deep Learning Sequence Modeling Networks	9
2.2.1 Transformer.....	9
2.2.2 Mamba	10
2.3 Multimodal Feature Alignment and Fusion.....	11
2.3.1 Contrastive Learning	11
2.3.2 Cross-Attention Mechanism	13
2.4 Autoregressive Modeling Mechanism	13
2.5 Summary	14
3 Human Activity Recognition Based on Multimodal Alignment and Fusion.....	15
3.1 Problem Description	15
3.2 Method Description	16
3.2.1 Overall Framework	16
3.2.2 WIHAR Model	17
3.2.3 Class-Prototype-Based Cross-Subject Adaptation Strategy	23
3.3 Experimental Results and Analysis	25
3.3.1 Experimental Settings	25
3.3.2 Dataset and Splitting Strategy	25
3.3.3 Evaluation Metrics.....	27
3.3.4 Method Comparison Experiments	28
3.3.5 Model Architecture and Training Strategy Experiments	30

3.3.6 Sample Construction Experiments	33
3.3.7 Modality and Device Ablation Experiments	34
3.3.8 Cross-subject Generalization Experiments	35
3.4 Summary	37
4 Autoregressive Human Pose Reconstruction and Prediction	38
4.1 Problem Description	38
4.2 Method Description	39
4.2.1 Overall Framework	39
4.2.2 AIPose Model	40
4.3 Experimental Results and Analysis	44
4.3.1 Experimental Settings	44
4.3.2 Dataset and Sample Construction	44
4.3.3 Evaluation Metrics	48
4.3.4 Method Comparison Experiments	50
4.3.5 Backbone Network Comparison Experiments	54
4.3.6 Sample Construction and Data Processing Experiments	55
4.3.7 Device Ablation Experiments	57
4.3.8 Generalization Experiments	58
4.3.9 Long-term Pose Prediction Experiments	59
4.4 Summary	60
5 Summary and Future Work	61
5.1 Summary	61
5.2 Future Work	62
Acknowledgements	63
References	64
Achievements	69
Decision of Defense Committee	70
General Reviewers List	71
Declarations	

1 绪论

1.1 选题意义与应用背景

人体行为感知是智能计算与人机交互领域的重要研究方向，其目标是通过传感设备获取人体运动信息，并对人体活动类别、姿态状态及其变化过程进行识别与理解。在智慧康养、智能家居、人机交互和虚拟现实等应用场景中，系统往往需要实时获取人体活动或姿态信息，以支撑行为监测、健康评估和交互控制。因此，如何实现稳定、可靠且可部署的人体行为感知，已成为智能感知领域的重要研究问题。

传统的人体行为感知研究多依赖视觉传感器，如 RGB 相机或深度相机。视觉方法在活动识别和姿态重构任务中取得了显著进展，但在实际部署中仍受到隐私保护、光照条件和环境遮挡等因素的限制。例如，在家庭、医疗或公共场所等场景中，持续使用摄像设备可能引发隐私风险；在弱光或复杂遮挡环境下，视觉方法的感知性能也可能明显下降。因此，越来越多研究开始探索利用非视觉传感器实现人体行为感知。

在众多非视觉感知技术中，惯性测量单元 (Inertial Measurement Unit, IMU) 与 WiFi 信道状态信息 (Channel State Information, CSI) 是两类具有代表性的传感模态。其中，IMU 能够直接测量人体运动过程中的加速度和角速度信息，因而广泛应用于人体活动识别、步态分析和人体姿态估计等任务；WiFi CSI 则利用人体运动对无线信号传播环境造成的扰动，通过分析信道变化推断人体行为，在非接触式活动感知中表现出较高潜力。与视觉传感器相比，这两类感知方式具有隐私友好、部署灵活和成本可控等优势，因此在实际应用中具有重要价值。

尽管近年来相关研究取得了一定进展，但针对本文关注的两类任务，现有非视觉人体感知方法仍面临三个突出问题。第一，IMU 与 WiFi CSI 在数据形式和物理机理上存在显著差异，两种模态之间的特征分布差异较大，导致多模态信息难以有效融合，从而影响活动识别性能。第二，在人体活动识别任务中，不同个体之间的运动习惯和动作执行方式存在差异，模型在跨受试者场景下往往出现明显性能下降。第三，在基于 IMU 的人体姿态重构任务中，现有研究大多关注于当前时刻的姿态重构，而对未来姿态缺乏显式预测能力，这会限制系统在实时交互和预测控制等场景中的应用价值。

针对上述问题，本文围绕人体活动识别与人体姿态重构两个任务展开研究。在人体活动识别任务中，本文主要关注 IMU 与 WiFi CSI 之间的异构特征对齐与融合问题，并探索跨受试者场景下的少样本适配方法，以提升模型的泛化能力。在人体姿态重构任务中，本文进一步研究如何引入自回归建模机制，在完成当前姿态重构的基础上实现未来姿态预测。

1.2 国内外研究现状分析

1.2.1 人体活动识别方法研究现状

人体活动识别 (Human Activity Recognition, HAR) 旨在对人体动作类别进行判别, 是智能感知、智慧康养、智能家居和人机交互中的基础研究问题。随着可穿戴传感器、无线射频感知技术和深度学习方法的发展, HAR 已逐渐从依赖视觉输入的场景扩展到面向隐私友好和长期部署需求的非视觉感知范式。现有 HAR 方法大致可分为基于视觉的方法、基于可穿戴惯性传感器的方法、基于无线射频信号的方法, 以及面向多源信息协同的多模态方法。基于视觉的方法通常利用 RGB 视频、深度图像或人体关键点序列对动作演化过程进行建模, 在公开数据集上能够取得较高识别精度, 但其对光照变化、视角偏移和人体遮挡较为敏感, 同时在家庭、卧室和康养等隐私敏感环境中存在持续部署受限的问题, 因此非视觉 HAR 方法逐渐成为研究重点。

在非视觉 HAR 研究中, 基于可穿戴惯性传感器的方法是核心技术路线之一。IMU 能够直接测量人体局部运动产生的加速度和角速度信息, 因此对细粒度动作变化具有较强敏感性。随着深度学习在时序建模中的广泛应用, 卷积网络、循环网络、Transformer 以及状态空间模型等结构被逐步引入惯性 HAR 任务, 推动识别性能持续提升。进一步地, 相关研究已从纯监督识别拓展到自监督表征学习、轻量化部署和少样本迁移等方向。例如, Spatial-Temporal Masked Autoencoder 通过掩码重建学习多设备可穿戴数据的时空表示, HARMamba 则将双向选择性状态空间模型引入可穿戴 HAR, 在长时序建模效率和识别精度之间取得了较好平衡; 近期综述和实证研究也表明, 可穿戴 HAR 正持续向高效推理和少样本迁移等方向发展^[1-7]。这说明, 面向真实部署场景的可穿戴 HAR 研究, 已不再仅关注识别精度本身, 而是越来越强调表征学习能力、推理效率与跨用户迁移能力的统一优化。

除可穿戴惯性传感器外, 基于无线射频信号的人体活动识别方法也受到持续关注。这类方法利用人体运动对无线传播环境造成的扰动, 通过分析 WiFi CSI 等射频信号中的幅值、相位或时频特征, 实现非接触式行为识别。与可穿戴方法相比, WiFi 感知无需用户主动佩戴设备, 具有隐私友好、部署灵活和成本较低等优点, 因此在智能家居、环境感知和被动监测等场景中具有较高应用潜力。近年来, 该方向不断出现新的公开数据资源与模型设计方法, 并逐渐引入 Transformer、多用户场景建模等技术^[8-12]。然而, 无线信号在传播过程中易受多径效应、设备摆放方式、环境布局变化以及时间漂移等因素影响, 模型的鲁棒性和跨场景泛化能力仍受到限制^[13]。

为了同时利用不同模态的互补优势, 多模态 HAR 逐渐成为研究热点。相关工作表明, 视觉、IMU、音频、压力和射频等多源信号能够从不同角度刻画人体活动, 从而提升识别鲁棒性与语义完整性。例如, MMTSA 通过多模态时序分段注意力机制联合建模不同模态信息; 近期关于可穿戴数据融合、多模态 lifelog 融合和多设备相关性建模等研究也表明, 多模态 HAR 已逐渐从“多源信息叠加”走向“统一表示学习与

深层融合^[14-18]。与此同时，跨数据集、跨场景和跨受试者泛化问题也日益受到重视。CrossHAR、ContrastSense 和 MASTER 等工作分别从自监督预训练、域不变表征和基础模型角度提升模型的迁移能力^[19-21]；在此基础上，少样本迁移、元学习增强、小样本个性化适配、零样本识别以及语言模型引导语义对齐等方向也不断发展^[6-7,22-25]。综上，现有研究虽已取得较大进展，但在异构模态统一语义空间构建、对齐后的细粒度交互建模，以及新受试者少样本适配方面仍存在不足。因此，围绕 IMU 与 WiFi CSI 的异构双模态人体活动识别，进一步研究跨模态特征对齐、深度融合及跨受试者泛化方法，具有明确的研究价值，这也构成了本文开展相关研究的主要动机。

1.2.2 人体姿态重构方法研究现状

人体姿态重构旨在根据传感器采集的人体运动观测信息，恢复人体关节位置、骨骼拓扑关系或连续运动轨迹，在虚拟现实、人机交互、运动分析和康复评估等场景中具有重要应用价值。就本文关注的主流技术路线而言，现有方法主要包括基于视觉的方法和基于惯性传感器的方法。随着可穿戴设备与深度学习技术的发展，人体姿态重构研究正逐渐从依赖高质量视觉设备或高密度惯导配置的实验室方案，转向面向消费级设备、稀疏传感器配置以及实时交互场景的实用化方向。基于视觉传感器的方法通常利用单目、双目或多目摄像机采集人体图像，通过关键点检测、三维骨架回归或人体网格恢复等方式估计人体姿态，在三维姿态估计和动作理解任务中已取得显著进展，但其对光照、遮挡和背景变化较为敏感，同时在家庭、医疗和办公等隐私敏感场景中存在部署限制，因此研究者开始更加关注基于非视觉信号的人体姿态重构方法。

在非视觉姿态建模中，基于 IMU 的人体姿态重构是一条重要研究路线。IMU 能够连续测量人体运动过程中的加速度和角速度信息，通过在人体关键部位布置若干惯性传感器，可以获取人体运动的时序观测信号，并进一步估计人体姿态。早期方法通常依赖运动学建模和骨骼约束，对传感器安装位置和人体模型假设较为敏感；随着深度学习的发展，越来越多研究开始通过神经网络学习 IMU 信号与人体姿态之间的映射关系，从而提升了姿态重构的精度与稳定性^[26-27]。与此同时，近年来相关研究还逐步将惯性姿态建模拓展到远程人体运动监测、行为约束下的运动学估计等更贴近实际应用的场景，说明该方向正在由单纯的姿态恢复走向更完整的运动状态理解^[28-30]。

近三年来，基于 IMU 的人体姿态重构研究主要呈现出三个趋势。第一，研究对象正从高密度专用惯导系统转向消费级设备与稀疏传感器配置。IMUPoser 和 MobilePoser 分别面向低成本日常设备场景与移动消费设备场景开展人体姿态估计研究，体现出该方向向实时交互系统持续靠近^[31-32]；与此同时，松散佩戴条件下的惯性运动捕捉以及结合超宽带测距信息的人体运动跟踪，也进一步拓展了稀疏传感姿态建模的应用边界^[33-34]。第二，姿态估计算法正从简单的时序回归逐步走向更强调动力学建模和结构建模的范式。DynaIP 通过部位级运动动力学学习增强稀疏惯性条件下的人体姿态估计能力，Accurate and Steady Inertial Pose Estimation 进一步说明，序列结构学习与调制机制对提升惯性姿态估计的精度和稳定性具有重要作用^[35-36]。第三，生成式建模方法开

始进入稀疏 IMU 人体运动重构任务。DiffusionPoser 将扩散建模机制引入任意稀疏传感器配置下的人体运动重构，并进一步推动该方向向更弱约束和更真实佩戴条件下的人体运动建模发展^[33,37]。这表明，人体姿态重构正在从确定性的当前姿态回归，逐渐走向同时考虑时序一致性、动态先验和分布建模能力的统一框架。

另一方面，现有多数 IMU 姿态方法仍主要聚焦于当前时刻或给定历史窗口内的姿态恢复，而对未来运动趋势的显式建模相对不足。然而，在虚拟现实、远程交互和运动预测等应用中，系统通常不仅需要恢复当前姿态，还需要在一定程度上预测未来人体运动状态，以降低系统延迟并提升交互连续性。近年来，人体运动预测研究已从传统的确定性回归逐步拓展到扰动鲁棒预测、多模态感知预测、在线自适应预测、长时行为预测以及扩散式生成预测等多种范式^[38-46]。这些研究为基于 IMU 的姿态重构与预测一体化建模提供了新的思路，也进一步凸显了未来状态建模在实时交互系统中的研究价值。综上，现有基于 IMU 的人体姿态重构研究虽已在重构精度、稀疏配置适应性和实时性能方面取得较大进展，但多数方法仍主要关注当前姿态恢复，对未来人体运动趋势缺乏显式建模。因此，进一步研究能够在统一框架下同时实现当前姿态重构与未来姿态预测的方法，具有重要的理论意义和应用价值，这也构成了本文研究基于 IMU 的人体姿态重构与预测方法的主要动机。

1.3 论文的主要研究内容

针对现有非视觉人体感知方法在多模态特征融合、跨受试者泛化以及未来运动状态建模等方面存在的不足，本文围绕人体活动识别和人体姿态重构与预测两个核心任务展开研究，构建了面向非视觉人体感知的整体研究框架。其中，人体活动识别部分主要面向 IMU 与 WiFi CSI 异构双模态数据的表示学习与跨受试者泛化问题，重点解决多模态特征对齐、融合以及新受试者适配等关键问题；人体姿态重构与预测部分则主要面向基于 IMU 信号的人体运动状态建模问题，重点解决当前姿态重构与未来姿态预测的统一建模问题。两部分研究内容分别从活动语义识别和运动状态建模两个层面展开，共同服务于复杂真实场景下非视觉人体感知系统准确性和鲁棒性的提升。

首先，在人体活动识别任务中，本文围绕 IMU 与 WiFi CSI 的多模态协同建模展开研究。由于两类传感数据在信号形式、统计分布和物理机理上存在明显差异，直接进行特征拼接往往难以充分挖掘其互补信息。针对这一问题，本文提出一种基于多模态对齐与融合的人体活动识别方法 WIHAR。该方法主要包括时序特征提取、跨模态特征对齐、跨模态特征融合以及跨受试者适配四个关键部分。具体而言，首先利用双分支时序编码结构分别提取 IMU 与 WiFi CSI 的高层特征表示；随后，通过跨模态双向对比学习策略，在 IMU 到 WiFi CSI 与 WiFi CSI 到 IMU 两个方向上约束特征对齐，将两类异构特征映射到统一语义空间；在此基础上，引入交叉注意力机制建模模态间的细粒度交互关系，以增强多模态融合表示的判别能力；进一步地，针对跨受试者场景下模型性能下降的问题，本文设计了一种基于类别原型的跨受试者适配策略，通过类别语

义约束与参数高效微调相结合的方式，实现对目标受试者的快速适配，从而缓解不同个体之间的特征分布偏移，提高模型在未见受试者条件下的泛化能力。

其次，在人体姿态重构与预测任务中，本文围绕基于 IMU 信号的人体运动时序建模展开研究。现有基于惯性传感器的人体姿态方法通常主要关注当前姿态重构，而对未来姿态缺乏显式建模能力，因而难以完整描述人体运动的时间演化过程。针对这一问题，本文提出一种基于自回归建模机制的人体姿态重构与预测方法 AIPose。该方法主要包括 IMU 特征提取模块、姿态重构模块、未来 IMU 序列预测模块以及自回归建模机制四个组成部分。具体而言，模型首先对输入 IMU 序列进行时序特征提取，获得表征当前运动状态的高层表示；然后，一方面基于该表示重构当前时间窗口内的人体姿态序列，另一方面预测未来时间段内的 IMU 序列；在此基础上，将预测得到的未来 IMU 序列与当前时刻附近的真实 IMU 观测进行拼接，构造扩展 IMU 序列，并进一步输入姿态预测分支，以实现未来姿态预测。通过这种“先预测未来 IMU，再预测未来姿态”的自回归建模方式，AIPose 在统一框架下实现了当前姿态重构与未来姿态预测的协同优化，从而增强了模型对人体运动连续演化过程的建模能力。

综上，本文围绕非视觉人体感知中的两个关键任务，分别从异构多模态表示学习与人体运动时序建模两个层面开展研究，提出了 WIHAR 与 AIPose 两种方法。前者面向人体活动识别任务，重点提升多模态融合效果与跨受试者泛化能力；后者面向人体姿态重构与预测任务，重点提升基于 IMU 的人体运动状态建模能力。两部分研究内容相互补充，共同为基于可穿戴传感器和无线信号的非视觉人体感知研究提供了较为系统的方法支撑。

1.4 论文的组织结构

本文共分为五章，组织结构如图 1-1 所示，各章节的主要内容如下。

第一章，绪论。本章首先介绍论文的选题意义与应用背景，随后分别梳理人体活动识别和人体姿态重构领域的国内外研究现状；在此基础上，进一步明确本文的主要研究内容，并对全文的组织结构进行说明。

第二章，相关理论与技术。本章主要介绍本文研究所涉及的基础理论与关键技术，包括 IMU 和 WiFi CSI 的基本感知原理，Transformer^[47] 与 Mamba^[48] 两种时序建模网络，多模态特征对齐与融合方法中的对比学习和交叉注意力机制，以及自回归建模机制，为后续章节的方法设计与实验分析提供理论基础。

第三章，基于多模态对齐与融合的人体活动识别。本章围绕复杂室内环境下的人体活动识别问题展开研究。首先对研究问题进行描述；随后介绍所提出的 WIHAR 方法，包括整体方法框架、WIHAR 模型以及基于类别原型的跨受试者适配策略；最后通过实验与结果分析，从实验设置、数据集与划分策略、评价指标、方法对比、模型架构与训练策略、样本构建、模态和设备消融以及跨受试者泛化等方面，对所提出方法进行系统评估。




图 1-1 论文组织结构

第四章，基于自回归建模机制的人体姿态重构与预测。本章围绕基于 IMU 的人体姿态重构与未来姿态预测问题展开研究。首先对研究问题进行描述；随后介绍所提出的 AIPose 方法，包括整体方法框架与 AIPose 模型；最后通过实验与结果分析，从实验设置、数据集与样本构建、评价指标、方法对比、骨干网络选择、样本构建与数据处理、设备消融、泛化实验以及长时姿态预测等方面，对所提出方法进行系统评估。

第五章，总结和展望。本章对全文研究工作进行总结，归纳本文在人体活动识别以及人体姿态重构与预测两个方面的主要研究成果，并在此基础上分析本文仍存在的不足，对未来可能的研究方向进行展望。

2 相关理论与技术

本章介绍本文研究涉及的相关理论与关键技术，为后续方法设计提供必要的理论支撑。首先介绍 IMU 与 WiFi CSI 两类传感器的基本感知原理。随后介绍 Transformer 与 Mamba 两种时序建模网络。在此基础上，进一步介绍多模态特征对齐与融合方法，包括对比学习与交叉注意力机制。最后介绍自回归建模机制的基本思想，为后续人体姿态重构与预测方法奠定基础。

2.1 传感器

2.1.1 惯性测量单元

IMU 是非视觉人体感知中最常用的可穿戴传感器之一，通常由三轴加速度计和三轴陀螺仪构成，用于测量载体在三维空间中的线性加速度与角速度信息，其基本结构如图 2-1 所示。相较于视觉传感器，IMU 主要刻画人体局部运动状态，对遮挡及环境光照变化具有较强的鲁棒性。然而，其感知能力受限于传感器的佩戴位置，同时在跨受试者泛化、佩戴偏差以及长期积分漂移等方面仍面临一定挑战。目前，IMU 已广泛应用于人体活动识别、步态分析、远程运动监测、跌倒风险评估以及人体姿态重构等任务中^[28-29,49]。




图 2-1 IMU 结构示意图

在加速度测量方面，加速度计输出的是载体坐标系下的比力，即线性加速度扣除重力加速度后再经坐标变换得到的观测量。设时刻 t 的加速度计观测值为 a_t ，其测量模型可表示为：

$$a_t = C_n^b(a_n - g_n) + b_a + n_a \quad (2-1)$$

其中， C_n^b 表示从导航坐标系到载体坐标系的旋转矩阵， a_n 为导航坐标系下的线性加速度， g_n 为导航坐标系下的重力加速度向量， b_a 为加速度计零偏误差， n_a 为测量噪声。

陀螺仪用于测量载体的角速度信息，其观测模型可表示为：

$$\omega_t = \omega_t^{\text{true}} + b_g + n_g \quad (2-2)$$

其中, ω_t^{true} 为时刻 t 的真实角速度, b_g 为陀螺仪零偏误差, n_g 为测量噪声。角速度信号能够刻画人体肢体在运动过程中的旋转动态变化, 与加速度信息相结合, 可以更全面地表征人体运动的时序特征。

2.1.2 WiFi 信道状态信息

WiFi 感知通过分析无线信号在传播过程中受到人体运动扰动而产生的信道变化, 实现对人体行为的非接触式感知, 具有部署成本低、环境适应性强等优势。近年来, 该方向一方面不断出现新的高质量公开数据资源与基准数据集, 如 EHUNAM、面向 80 MHz WiFi 信道的人体感知 CSI 数据集以及 WiMANS; 另一方面, 基于深度学习与注意力机制的 WiFi CSI 行为建模方法也在持续发展^[8-12]。多用户、复杂环境和更标准化的数据构建, 正在推动 WiFi 感知研究走向更系统的实验范式。

现代 WiFi 系统通常采用正交频分复用 (Orthogonal Frequency Division Multiplexing, OFDM) 技术进行数据传输。在 OFDM 系统中, 高速数据流被划分为多个子载波并行传输, 从而能够有效应对复杂无线信道带来的频率选择性衰落。WiFi CSI 是物理层对无线信号在发射端与接收端之间传播特性的细粒度刻画, 用于描述不同子载波上的信道频率响应。对于第 k 个子载波, 接收信号 Y_k 与发送信号 X_k 之间的关系可以表示为:

$$Y_k = H_k X_k + N_k \quad (2-3)$$

其中, H_k 为该子载波上的复数信道增益, 即 CSI; N_k 为高斯白噪声。

WiFi CSI 通常以复数形式表示, 可以分解为幅度和相位:

$$H_k = |H_k| e^{j\angle H_k} \quad (2-4)$$

其中, 幅度 $|H_k|$ 表示信号在该子载波上的能量衰减, 相位 $\angle H_k$ 则反映了传播时延与路径变化等信息。与仅提供粗粒度接收功率信息的接收信号强度指示 (Received Signal Strength Indicator, RSSI) 相比, WiFi CSI 能够提供更细粒度的子载波级信道信息, 因此更适合用于人体活动识别、定位和环境感知等任务^[50-51]。需要指出的是, 实际采集到的相位信息通常会受到硬件时钟偏移和载波频偏等因素的影响, 因此往往需要经过预处理或校准后才能稳定用于建模。

在室内环境中, 无线信号通常通过多条路径传播, 包括来自墙壁、地面、家具以及人体的反射路径。根据多径传播模型, 时变信道频率响应可以表示为:

$$H(f, t) = \sum_{p=1}^P \alpha_p(t) e^{-j2\pi f \tau_p(t)} \quad (2-5)$$

其中, P 表示传播路径数量, $\alpha_p(t)$ 为第 p 条路径的衰减系数, $\tau_p(t)$ 为对应的传播时延。当人体在 WiFi 覆盖区域内运动时, 会改变部分传播路径的长度和反射特性, 从而引起

$\alpha_p(t)$ 与 $\tau_p(t)$ 的变化。这种变化会进一步反映在 WiFi CSI 幅度和相位的时序波动中，使得 WiFi CSI 能够表征人体运动对无线传播环境造成的扰动。

因此，通过对 WiFi CSI 序列进行时序建模，可以从无线信号变化中提取与人体运动相关的判别特征。但基于 WiFi CSI 的感知方法性能通常会受到环境布局、设备部署方式、数据采集协议以及时间漂移等因素的影响，尤其在跨场景、跨时间或跨受试者设置下，对模型泛化能力提出了更高要求^[13]。

2.2 深度学习时序建模网络

2.2.1 Transformer

Transformer 是当前序列建模中最具代表性的网络结构之一，其核心思想是利用自注意力机制直接建模序列中任意位置之间的依赖关系，而不依赖循环结构进行逐步状态传递^[47]。相比循环神经网络 (RNN) 或长短期记忆网络 (LSTM)，Transformer 更易于并行计算，并且在长距离依赖建模方面具有明显优势，因此已被广泛用于自然语言处理、语音、视觉以及多种时序建模任务中。

Transformer 的核心计算单元为缩放点积注意力。给定输入序列的特征表示，模型首先通过线性映射将其转换为查询向量 (Query, Q)、键向量 (Key, K) 和值向量 (Value, V)。注意力输出可以表示为：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2-6)$$

其中， d_k 为键向量的维度，缩放因子 $\sqrt{d_k}$ 用于缓解点积过大带来的训练不稳定问题。该过程通过计算序列中不同位置之间的相似度，自适应地聚合全局上下文信息。

为了增强模型对不同表示子空间的建模能力，Transformer 进一步引入多头注意力机制。其计算形式如下：

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O \quad (2-7)$$

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V) \quad (2-8)$$

其中， W_i^Q 、 W_i^K 、 W_i^V 和 W^O 为可学习参数矩阵。多头注意力使模型能够在不同特征子空间中并行捕捉序列内部的相关性，从而提升表示能力。

由于自注意力机制本身不显式包含顺序信息，因此 Transformer 通常通过位置编码引入时序位置信息。常用的正弦—余弦位置编码形式如下：

$$\text{PE}(\text{pos}, 2i) = \sin\left(\text{pos}/10000^{2i/d_{\text{model}}}\right) \quad (2-9)$$

$$PE(pos, 2i + 1) = \cos \left(pos/10000^{2i/d_{model}} \right) \quad (2-10)$$

通过将位置编码与输入特征相加，模型能够感知时间顺序，从而实现对时序数据的有效建模。Transformer 模型结构如图 2-2所示。




图 2-2 Transformer 模型架构图

2.2.2 Mamba

Mamba 是一种基于状态空间模型（State Space Model, SSM）的序列建模结构，能够通过递归方式对历史信息进行压缩表示，并建模序列中的时间依赖关系^[48]。对于传感器数据这类具有明显时序特征的输入，Mamba 能够在较高建模效率下提取时序特征，因此适用于长时序信号建模任务。

状态空间模型通过引入隐状态描述输入序列随时间的动态演化过程。在离散时间形式下，其基本表达为

$$h_t = Ah_{t-1} + Bx_t \quad (2-11)$$

$$y_t = Ch_t \quad (2-12)$$

其中， x_t 表示时刻 t 的输入， h_t 表示系统隐状态， y_t 表示输出， A 、 B 和 C 为模型参数矩阵。该结构通过递归更新隐状态，对历史信息进行持续累积，从而能够刻画长范围

的时间依赖。

在传统状态空间模型中，状态更新过程通常依赖固定参数，因此对不同输入内容的自适应能力相对有限。Mamba 在状态空间建模中引入了选择性机制，使部分状态更新参数能够随当前输入动态变化，从而根据输入内容选择性地保留、更新或遗忘历史信息^[48]。这一设计增强了模型对关键信息的提取能力，使其在长时序建模任务中兼具效率与表达能力。Mamba 模型结构如图 2-3 所示。




图 2-3 Mamba 模型架构图

2.3 多模态特征对齐与融合

在人体感知任务中，不同类型的传感器通常从不同角度反映人体运动信息。例如，IMU 能够直接记录人体肢体运动过程中的加速度和角速度变化，反映人体运动的局部动力学特征；而 WiFi CSI 则通过分析无线信号变化，刻画人体运动对传播环境造成的扰动，从而提供环境层面的感知信息。相比单一模态，多模态传感数据能够从不同维度描述人体行为状态，因此在人体活动识别任务中具有重要价值^[15-17,52]。

然而，不同模态在物理属性、数据分布和特征表达方式上通常存在明显差异，若仅采用特征拼接或简单融合，往往难以充分发挥多模态协同建模的优势。因此，在多模态人体活动识别任务中，通常需要同时解决模态对齐与模态融合两个问题。模态对齐旨在将不同传感器的特征映射到统一语义空间，以减小模态间分布差异并学习稳定的共享表示；模态融合则进一步建模不同模态之间的交互关系，以充分利用其互补信息，提升模型的整体感知能力。基于这一思路，本节将介绍实现多模态特征对齐与融合的相关方法，包括用于学习跨模态共享表示的对比学习，以及用于建模模态间特征交互关系的交叉注意力机制。

2.3.1 对比学习

在人体活动识别任务中，IMU 与 WiFi CSI 在感知机理和特征分布上存在明显差异，若直接进行特征融合，容易导致模态间语义不一致，从而影响融合表示的判别能力。因

此，在融合之前，有必要先对不同模态的特征进行语义对齐。

针对上述问题，对比学习为跨模态特征对齐提供了一种有效途径。其核心思想是通过拉近正样本对之间的距离、拉远负样本对之间的距离，从而学习具有判别性的特征表示。该机制已被广泛应用于跨模态表示学习，并在构建共享语义空间方面表现出良好效果^[53-56]。在本文场景中，来自同一时间窗口且语义一致的 IMU 片段与 WiFi CSI 片段构成跨模态正样本对，而来自不同样本或不同动作片段的跨模态组合则作为负样本对。

在具体实现上，设 IMU 模态输入为 x_i^I ，WiFi CSI 模态输入为 x_i^W ，其中 i 表示第 i 个样本。经过各自编码网络后，可得到对应的特征表示：

$$u_i = f_{IMU}(x_i^I), \quad v_i = f_{WiFi}(x_i^W) \quad (2-13)$$

其中， $f_{IMU}(\cdot)$ 和 $f_{WiFi}(\cdot)$ 分别表示 IMU 模态与 WiFi CSI 模态的特征提取函数。为保证相似度计算的稳定性，通常对特征向量进行归一化处理，使其分布于单位超球面上。

基于上述特征表示，可以构建跨模态相似度度量。对于 IMU 样本 i 与 WiFi CSI 样本 j ，其余弦相似度定义为：

$$S_{ij} = \frac{u_i^T v_j}{\|u_i\| \|v_j\|} \quad (2-14)$$

在一个包含 N 个样本的训练批次中，进一步构建 IMU 特征与 WiFi CSI 特征之间的相似度矩阵 $S \in \mathbb{R}^{N \times N}$ 。其中，对角线元素对应语义匹配的正样本对，非对角线元素对应不匹配的负样本对。基于该相似度结构，本文采用跨模态双向对比学习（Bidirectional Cross-Modal Contrastive Learning, BCMCL）损失对模型进行优化，可同时约束两个模态方向上的对齐关系。

对于 IMU 到 WiFi 方向，其损失定义为：

$$L_i^{I \rightarrow W} = -\log \frac{\exp(S_{ii}/\tau)}{\sum_{k=1}^N \exp(S_{ik}/\tau)} \quad (2-15)$$

其中， τ 为温度系数，用于调节相似度分布的平滑程度。

类似地，WiFi CSI 到 IMU 方向的损失可表示为：

$$L_i^{W \rightarrow I} = -\log \frac{\exp(S_{ii}/\tau)}{\sum_{k=1}^N \exp(S_{ki}/\tau)} \quad (2-16)$$

最终，对比学习损失由两个方向的损失共同构成：

$$L_{BCMCL} = \frac{1}{2N} \sum_{i=1}^N \left(L_i^{I \rightarrow W} + L_i^{W \rightarrow I} \right) \quad (2-17)$$

通过最小化上述损失，模型能够将语义一致的 IMU 与 WiFi CSI 样本映射到相邻的特征区域，同时拉开不匹配样本之间的距离，从而实现跨模态特征对齐。经过该约束后，不同模态的特征表示在共享语义空间中具有更高一致性，为后续跨模态特征融合与人体活动识别提供了更加稳定且具有判别性的表示基础^[54-56]。

2.3.2 交叉注意力机制

尽管对比学习能够将 IMU 与 WiFi CSI 特征对齐到统一的语义空间，但其主要关注整体表示的一致性，尚未显式刻画不同模态之间的细粒度交互关系。因此，在完成模态对齐之后，仍有必要进一步引入跨模态交互机制，以实现更有效的特征融合^[16-17,52]。

交叉注意力机制（Cross-Attention Mechanism）是一类常见的多模态特征融合方法，其基本思想是利用一个模态的特征作为查询（Query），从另一模态的特征中检索与之最相关的信息。与自注意力机制不同，交叉注意力中的查询向量与键值向量来自不同模态，因此能够显式建立模态间依赖关系。设经过编码网络提取后的 IMU 特征序列为 $X_I \in \mathbb{R}^{L_I \times d}$ ，WiFi CSI 特征序列为 $X_W \in \mathbb{R}^{L_W \times d}$ ，其中 L_I 与 L_W 分别表示两个模态的序列长度， d 表示特征维度。首先通过线性映射生成查询、键和值向量：

$$Q_I = X_I W_Q, \quad K_W = X_W W_K, \quad V_W = X_W W_V \quad (2-18)$$

其中， $W_Q \in \mathbb{R}^{d \times d_k}$ 、 $W_K \in \mathbb{R}^{d \times d_k}$ 和 $W_V \in \mathbb{R}^{d \times d_v}$ 为可学习的线性映射矩阵。

随后，通过缩放点积注意力计算 IMU 特征对 WiFi CSI 特征的注意程度：

$$O_{I \leftarrow W} = \text{softmax} \left(\frac{Q_I K_W^T}{\sqrt{d_k}} \right) V_W \quad (2-19)$$

其中， d_k 表示键向量的维度。该过程通过相似度矩阵刻画 IMU 时间步与 WiFi CSI 时间步之间的相关性，再利用注意力权重对 WiFi CSI 特征进行加权汇聚，从而得到融合后的表示 $O_{I \leftarrow W} \in \mathbb{R}^{L_I \times d_v}$ 。

通过该机制，模型能够根据一个模态的当前特征状态，从另一模态中自适应选择最有助于判别的信息。在实际应用中，也可以进一步构建反向注意力，即利用 WiFi CSI 特征作为查询，从 IMU 特征中获取相关信息，从而形成双向跨模态交互结构。相比简单拼接，交叉注意力更有利于捕捉模态间的局部对应关系与互补模式，因此在多模态融合任务中得到了广泛应用^[16,52]。

2.4 自回归建模机制

人体运动序列具有明显的时间连续性，即当前时刻的运动状态通常与前一阶段的姿态和运动趋势密切相关。例如，在行走、转身或摆臂等动作中，人体关节轨迹在相邻时间步之间通常呈现较强相关性。因此，在人体运动建模中，可以利用历史观测对未来状态进行推断。

自回归建模机制的核心思想是利用最近一段历史观测序列预测下一时刻或后续时刻的状态。为兼顾时序建模能力与计算效率，通常采用长度为 L 的固定滑动窗口，仅利用最近的历史信息进行建模。对于一步预测问题，其基本形式可写为：

$$\hat{x}_{t+1} = f_{\theta}(x_{t-L+1}, x_{t-L+2}, \dots, x_t) \quad (2-20)$$

其中， $f_{\theta}(\cdot)$ 表示带参数 θ 的时间依赖建模函数。

在多步预测阶段，自回归模型采用递归方式逐步生成未来序列。为统一表示真实观测与已生成结果，记

$$\tilde{x}_{\tau} = \begin{cases} x_{\tau}, & \tau \leq t, \\ \hat{x}_{\tau}, & \tau > t, \end{cases} \quad (2-21)$$

则第 k 步预测可表示为

$$\hat{x}_{t+k} = f_{\theta}(\tilde{x}_{t+k-L}, \tilde{x}_{t+k-L+1}, \dots, \tilde{x}_{t+k-1}), \quad k \geq 2. \quad (2-22)$$

该递归预测方式能够在保持时间连续性的同时，仅依赖最近长度为 L 的历史窗口完成后续状态生成。

2.5 本章小结

本章围绕本文方法设计涉及的关键理论与技术展开介绍。首先，阐述了 IMU 与 WiFi CSI 两类传感器的基本感知原理，并分析了二者在人体行为感知中的信息特点与互补性。随后，介绍了 Transformer 与 Mamba 两类时序建模网络。在此基础上，进一步介绍了多模态特征对齐与融合方法，包括对比学习和交叉注意力机制，为后续人体活动识别模型的设计提供理论支撑。最后，介绍了自回归建模机制的基本思想，为后续人体姿态重构与预测方法提供建模依据。

3 基于多模态对齐与融合的人体活动识别

本章围绕复杂室内环境下的多模态人体活动识别问题展开。第 3.1 节进行问题描述，分析研究背景、现实挑战与研究动机；第 3.2 节介绍本文提出的 WIHAR 方法，包括整体方法框架、关键模块设计以及跨受试者适配策略；第 3.3 节给出实验设置与结果分析，从方法对比、模型架构与训练策略、样本构建、模态与设备消融以及跨受试者泛化等角度验证所提方法的有效性；第 3.4 节对本章工作进行总结。

3.1 问题描述

人体活动识别 (Human Activity Recognition, HAR) 是智能感知中的基础任务，在智慧医疗、养老监护、安防监控和智能家居等场景中具有重要应用价值。近年来，随着可穿戴设备、无线感知技术以及深度学习方法的发展，HAR 在识别精度和应用范围上均取得了明显进展。然而，在真实室内环境中构建兼具准确性、鲁棒性和可部署性的人体活动识别系统，仍然面临诸多挑战。




图 3-1 WIHAR 方法整体思路示意图

视觉感知方法在理想条件下通常能够取得较好的识别效果，但其性能高度依赖成像质量、视角条件以及环境光照。在夜间、弱光或存在遮挡的场景中，人体外观特征和关键点信息容易退化，从而影响识别稳定性。同时，持续视频采集还会带来较为突出的隐私问题，因此在卧室、书房等敏感场景中受到一定限制。相比之下，非视觉感知方式在隐私保护和环境适应性方面更具优势，因而逐渐成为人体活动识别研究的重要方向。

在非视觉感知方案中，单一模态仍存在明显局限。IMU 能够直接采集人体局部运动产生的加速度与角速度信息，对细粒度动作变化较为敏感，但其感知范围受佩戴位置限制，对环境信息的刻画较弱，同时还可能受到零偏漂移和佩戴偏差的影响。WiFi

CSI 则通过刻画人体运动引起的无线传播变化实现非接触感知，具有覆盖范围较大、部署灵活等优点，但其特征分布容易受到环境布局、多径传播和设备部署方式变化的影响。因此，IMU 与 WiFi CSI 在感知机理、数据分布和优势信息上具有明显差异，若仅采用简单拼接，往往难以充分利用两种模态之间的互补性。

针对上述问题，本文面向 IMU 与 WiFi CSI 构成的异构双模态人体活动识别场景，研究如何在保持非视觉感知隐私友好与环境适应性优势的同时，提高跨模态表示的一致性、互补信息利用能力以及最终识别性能。为此，本文提出一种基于多模态对齐与融合的人体活动识别方法 **WIHAR**，并在此基础上进一步设计跨受试者适配策略，以提升模型在未见受试者条件下的泛化能力。方法的整体思路如图 3-1 所示。

3.2 方法描述

3.2.1 整体方法框架

WIHAR 以同步采集的 IMU 与 WiFi CSI 时序数据为输入，通过时序特征编码、跨模态特征对齐、跨模态特征融合以及分类预测四个阶段完成人体活动识别，整体流程如图 3-1 所示，整体架构如图 3-2 所示。




图 3-2 WIHAR 模型架构图

首先，对同步采集的 IMU 与 WiFi CSI 数据进行时间对齐，并将其共同作为双模态输入送入网络。随后，模型采用两个参数独立的时序编码分支，分别提取 IMU 与 WiFi CSI 的高层时序特征表示。考虑到两种模态在感知机理与统计特性上的差异，WIHAR 在特征学习阶段引入跨模态双向对比学习约束，在 IMU 到 WiFi CSI 和 WiFi CSI 到 IMU 两个方向上增强同一样本跨模态表示的一致性，从而减小异构特征之间的语义偏差。

在完成特征对齐后，模型进一步通过交叉注意力机制建模模态间的细粒度交互关系，以获得更具判别性的融合表示。最后，融合特征被输入人体活动识别分类模块，用于输出最终的活动类别预测结果。训练过程中，模型采用人体活动识别分类损失与跨模态双向对比学习损失构成的联合目标进行优化，从而同时提升类别判别能力与跨模态表示一致性。

3.2.2 WIHAR 模型

在上述整体方法框架基础上，本节进一步介绍 WIHAR 的具体实现。为便于说明，本文将其划分为时序特征提取、跨模态特征对齐、跨模态特征融合、分类模块以及损失函数五个部分，下面分别进行介绍。

1) Mamba 时序特征提取

IMU 与 WiFi CSI 均属于典型的时间序列信号，其判别信息不仅体现在单个时刻的瞬时观测上，还体现在随时间演化形成的动态模式中。因此，在模态特征提取阶段，本文引入 Mamba 序列模型对两种模态的输入序列分别进行时序编码，以增强模型对局部动态变化与长期时序依赖的建模能力。对应的编码器结构如图 3-3 所示。




图 3-3 Mamba 特征编码器

设 IMU 与 WiFi CSI 模态的原始输入分别表示为

$$X_I \in \mathbb{R}^{B \times C_I \times T}, \quad X_W \in \mathbb{R}^{B \times C_W \times T}, \quad (3-1)$$

其中， B 表示批大小， T 表示时间序列长度， C_I 与 C_W 分别表示 IMU 与 WiFi CSI 的输入特征维度。对于 IMU 模态，原始数据在单个时间步包含 5 个设备、每个设备 6 个通道，因此在送入模型时将设备维与通道维展平为统一的通道维表示，即 $C_I = 5 \times 6 = 30$ ；对于 WiFi CSI 模态，单个时间步的输入特征维度记为 C_W ，在本数据集中对应为 540。需要说明的是，本文在实现中采用 $B \times C \times T$ 的张量组织形式；在进入线性映射层之前，先将其转置为时序建模更常用的 $B \times T \times C$ 形式。

考虑到不同传感通道在量纲范围与数值尺度上存在差异，若直接将原始序列输入编码器，可能会影响模型训练的稳定性，并削弱不同通道之间特征学习的均衡性。因此，在输入 Mamba 编码器之前，本文首先对每种模态数据按通道进行 Z-score 标准化

处理。对于任一输入序列 $X \in \mathbb{R}^{B \times C \times T}$ ，其第 c 个通道在批次维与时间维上的均值和标准差分别定义为

$$\mu_c = \frac{1}{BT} \sum_{b=1}^B \sum_{t=1}^T X_{b,c,t}, \quad \sigma_c = \sqrt{\frac{1}{BT} \sum_{b=1}^B \sum_{t=1}^T (X_{b,c,t} - \mu_c)^2}, \quad (3-2)$$

相应地，标准化后的输入表示为

$$\hat{X}_{b,c,t} = \frac{X_{b,c,t} - \mu_c}{\sigma_c}. \quad (3-3)$$

在此基础上，每个模态的编码器均由输入线性映射层和 L 层堆叠的 Mamba 模块组成。为与代码实现保持一致，设转置操作记为 $\Pi(\cdot)$ ，其作用是交换张量的后两维，即将 $\mathbb{R}^{B \times a \times b}$ 变换为 $\mathbb{R}^{B \times b \times a}$ 。在当前输入情形下， $\Pi(\cdot)$ 将原始序列从 $\mathbb{R}^{B \times C \times T}$ 变换到 $\mathbb{R}^{B \times T \times C}$ 。则任一模态的编码过程可统一表示为

$$\begin{aligned} H^{(0)} &= \Pi(\hat{X}), \\ Z^{(0)} &= H^{(0)} W_{\text{in}} + b_{\text{in}}, \\ Z^{(\ell)} &= \text{Mamba}_{\ell}(Z^{(\ell-1)}), \quad \ell = 1, 2, \dots, L, \\ F &= \Pi^{-1}(Z^{(L)}), \end{aligned} \quad (3-4)$$

其中， $H^{(0)} \in \mathbb{R}^{B \times T \times C}$ 表示转置后的输入序列， $W_{\text{in}} \in \mathbb{R}^{C \times D}$ 、 $b_{\text{in}} \in \mathbb{R}^D$ 分别表示输入线性映射层的权重与偏置， D 表示隐空间特征维度， $\text{Mamba}_{\ell}(\cdot)$ 表示第 ℓ 层 Mamba 模块， $\Pi^{-1}(\cdot)$ 表示对应的逆转置操作，即将特征从 $\mathbb{R}^{B \times T \times D}$ 重新变换回 $\mathbb{R}^{B \times D \times T}$ 。

因此，对于 IMU 与 WiFi CSI 两种模态，编码器输出可分别表示为

$$\bar{F}_I = E_I(\hat{X}_I), \quad \bar{F}_W = E_W(\hat{X}_W), \quad (3-5)$$

其中， $\bar{F}_I, \bar{F}_W \in \mathbb{R}^{B \times D \times T}$ 。结合式 (3-4) 可知，两种模态的编码过程均由“输入转置—线性投影—多层 Mamba 堆叠—逆转置”构成，但对应编码器参数相互独立。

为了便于后续跨模态对齐与特征融合计算，本文进一步将编码器输出重新整理为时间维在前、特征维在后的形式，即

$$F_I = \Pi(\bar{F}_I), \quad F_W = \Pi(\bar{F}_W), \quad (3-6)$$

其中， $F_I, F_W \in \mathbb{R}^{B \times T \times D}$ 。

经过时序编码后，两种模态均被映射为统一维度的高层时序特征表示。在保持时间长度 T 不变的同时，实现了从原始观测空间到高层语义空间的映射，为后续跨模态

对齐与特征融合提供了统一的表示基础。

需要说明的是，本文在该阶段不对时间维度进行池化压缩，而是保留完整的时序特征表示。这是因为跨模态对齐与融合不仅依赖全局统计信息，还需要利用细粒度的时序对应关系。保留完整的时间结构信息有助于后续模块进一步挖掘两种模态在动态变化过程中的互补性，从而提升多模态表示学习效果。

2) 跨模态特征对齐

如第 2.3 节所述，对比学习能够在共享语义空间中实现跨模态特征对齐。基于该思想，本文在 WIHAR 模型中引入跨模态双向对比学习 (Bidirectional Cross-Modal Contrastive Learning, BCMCL) 约束，在特征层面对 IMU 与 WiFi CSI 的全局表示进行对齐，以减小两种模态之间的分布偏差。具体而言，首先利用 Mamba 编码器分别提取 IMU 与 WiFi CSI 的时序特征表示，并将其整理为

$$F_I, F_W \in \mathbb{R}^{B \times T \times D}, \quad (3-7)$$

其中， B 表示批大小， T 表示时间序列长度， D 表示特征维度。为获得样本级的全局表示，本文对时间维度进行平均池化，得到

$$f_I = \text{MeanPool}_T(F_I), \quad f_W = \text{MeanPool}_T(F_W), \quad (3-8)$$

其中， $f_I, f_W \in \mathbb{R}^{B \times D}$ 。随后对特征进行 L_2 归一化：

$$\tilde{f}_I = \frac{f_I}{\|f_I\|_2}, \quad \tilde{f}_W = \frac{f_W}{\|f_W\|_2}. \quad (3-9)$$

在此基础上，构建批内跨模态相似度矩阵：

$$S = \frac{\tilde{f}_I \tilde{f}_W^T}{\tau}, \quad (3-10)$$

其中 $S \in \mathbb{R}^{B \times B}$ ， τ 为温度系数。

进一步采用跨模态双向对比学习损失进行优化，其形式定义为：

$$L_{\text{BCMCL}} = -\frac{1}{2B} \sum_{i=1}^B \left(\log \frac{\exp(S_{ii})}{\sum_{j=1}^B \exp(S_{ij})} + \log \frac{\exp(S_{ii})}{\sum_{j=1}^B \exp(S_{ji})} \right). \quad (3-11)$$

通过在特征层引入该对比约束，模型能够在训练过程中逐步对齐 IMU 与 WiFi CSI 的全局表示，从而为后续跨模态特征融合提供更加一致的语义基础。

3) 跨模态特征融合

完成跨模态特征对齐后，IMU 与 WiFi CSI 特征在整体语义空间中已具有较好的一致性，但两种模态仍保留了不同的信息侧重点。IMU 更擅长刻画人体局部运动的动力学变化，而 WiFi CSI 对人体运动引起的空间传播环境整体扰动更为敏感。为进一步利用两种模态的互补信息，本文采用交叉注意力机制进行跨模态特征融合，其过程如图 3-4 所示。该机制以 IMU 特征为引导，从 WiFi CSI 特征中自适应选择与当前动作状态更相关的信息，并通过残差连接与归一化操作得到融合后的跨模态时序表示。




图 3-4 交叉注意力机制特征融合

设经过 Mamba 编码器提取并重排后的 IMU 与 WiFi CSI 时序特征分别为

$$F_I, F_W \in \mathbb{R}^{B \times T \times D}, \quad (3-12)$$

其中， B 表示批大小， T 表示时间序列长度， D 表示特征维度。本文以 IMU 特征作为查询输入，以 WiFi CSI 特征作为键和值输入，并通过线性映射得到

$$Q = F_I W_Q + b_Q, \quad K = F_W W_K + b_K, \quad V = F_W W_V + b_V, \quad (3-13)$$

其中， $W_Q, W_K, W_V \in \mathbb{R}^{D \times D}$ 为可学习的权重矩阵， $b_Q, b_K, b_V \in \mathbb{R}^D$ 为对应偏置项。

在此基础上，采用多头交叉注意力机制对不同子空间中的跨模态相关性进行建模，并对其输出施加线性映射与 Dropout 操作，即

$$Y = \text{MultiHeadAttn}(Q, K, V), \quad \tilde{Y} = \text{Dropout}(Y W_O + b_O), \quad (3-14)$$

其中， $Y, \tilde{Y} \in \mathbb{R}^{B \times T \times D}$ ， $W_O \in \mathbb{R}^{D \times D}$ 、 $b_O \in \mathbb{R}^D$ 分别表示输出映射层的权重与偏置。

随后，采用残差连接与层归一化得到融合后的跨模态时序特征

$$Z = \text{LayerNorm}(Q + \tilde{Y}), \quad (3-15)$$

其中， $Z \in \mathbb{R}^{B \times T \times D}$ 。需要说明的是，此处残差连接作用于投影后的查询特征 Q ，从而

在保留 IMU 模态引导作用的同时，引入来自 WiFi CSI 模态的补充信息。

在获得融合后的时序特征后，本文进一步对时间维度进行平均池化，以得到全局多模态表示：

$$z = \text{MeanPool}_T(Z), \quad z \in \mathbb{R}^{B \times D}. \quad (3-16)$$

该特征同时融合了 IMU 与 WiFi CSI 两种模态的信息，并作为后续分类模块的输入。

总体而言，该融合方式以 IMU 模态为查询端，以 WiFi CSI 模态为键和值端，通过多头交叉注意力实现模态间的信息交互，并在输出映射、残差连接与层归一化的共同作用下形成稳定的跨模态时序表示。相比简单拼接，该结构能够在保持时间结构信息的同时，更充分地挖掘两种模态之间的互补关系，从而提升多模态人体活动识别的特征表达能力。

4) 分类模块

设经过跨模态特征融合后得到的全局表示为

$$z \in \mathbb{R}^{B \times D}, \quad (3-17)$$

其中， B 表示批大小， D 表示融合特征维度。

在此基础上，本文构建一个由两层全连接层组成的分类模块，用于将融合特征映射到活动类别空间。首先，通过第一层线性变换将输入特征投影到隐藏空间，并结合 ReLU 激活函数与 Dropout 操作完成非线性特征变换，即

$$h = \text{Dropout}(\text{ReLU}(zW_1 + b_1)), \quad (3-18)$$

其中， $W_1 \in \mathbb{R}^{D \times H}$ 、 $b_1 \in \mathbb{R}^H$ 分别表示第一层全连接层的权重与偏置， H 表示隐藏层维度。

随后，经过第二层线性映射得到活动类别对应的预测 logits：

$$o = hW_2 + b_2, \quad (3-19)$$

其中， $W_2 \in \mathbb{R}^{H \times C_a}$ 、 $b_2 \in \mathbb{R}^{C_a}$ 分别表示第二层全连接层的权重与偏置， C_a 表示活动类别数。

最后，对 logits 进行 Softmax 归一化，得到人体活动识别任务的预测概率分布：

$$\hat{y}_a^{(c)} = \frac{\exp(o^{(c)})}{\sum_{k=1}^{C_a} \exp(o^{(k)})}, \quad c = 1, 2, \dots, C_a. \quad (3-20)$$

该分类模块在保持结构简洁的同时，能够通过隐藏层的非线性变换进一步增强融合特征的类别判别能力，从而为人体活动识别任务提供最终预测结果。

5) 损失函数

为了同时优化人体活动识别任务的分类性能以及跨模态特征对齐效果，本文采用联合损失函数对模型进行训练。整体上，模型的优化目标由人体活动识别分类损失和跨模态双向对比学习损失两部分组成，其中前者用于提升活动类别判别能力，后者用于增强 IMU 与 WiFi CSI 特征表示之间的一致性。

首先，在人体活动识别任务中，考虑到 XRFV2 数据集中不同活动类别的数据分布存在一定不均衡现象，若对各类别样本赋予相同的损失权重，模型在训练过程中容易受到高频类别主导，从而削弱对低频类别的识别能力。为缓解这一问题，本文在人体活动识别分支中引入基于类别规模倒数的加权交叉熵损失。设训练集中第 c 类的数据时长为 n_c ，则首先定义该类的初始权重为

$$w'_c = \frac{1}{n_c}. \quad (3-21)$$

进一步地，为避免权重尺度变化对整体损失幅值产生过大影响，对各类别初始权重进行归一化处理，使其平均值为 1：

$$w_c = \frac{w'_c}{\sum_{k=1}^{C_a} w'_k} \times C_a, \quad (3-22)$$

其中， C_a 表示活动类别总数， w_c 表示第 c 类对应的归一化权重。

在此基础上，人体活动识别任务的加权交叉熵损失定义为

$$L_a = - \sum_{c=1}^{C_a} w_c y_a^{(c)} \log \hat{y}_a^{(c)}, \quad (3-23)$$

其中， $y_a^{(c)}$ 和 $\hat{y}_a^{(c)}$ 分别表示真实标签的独热编码和模型预测的类别概率。通过引入类别权重，样本量较少的类别将在优化过程中获得相对更大的损失贡献，从而引导模型更加关注低频类别样本，提升类别不均衡条件下的整体识别能力。

在分类损失之外，本文进一步引入跨模态双向对比学习损失 L_{BCMCL} ，以约束 IMU 与 WiFi CSI 的特征对齐，具体见本节“跨模态特征对齐”部分。

综上，模型的整体优化目标定义为

$$L = L_a + \alpha L_{\text{BCMCL}}, \quad (3-24)$$

其中， α 为非负权重系数，用于平衡人体活动识别任务与跨模态对齐任务在整体优化中的贡献。

通过上述联合优化方式，模型能够在提升人体活动识别性能的同时，增强不同模态特征表示之间的语义一致性，提供更加稳定的优化目标。

3.2.3 基于类别原型的跨受试者适配策略

尽管 WIHAR 模型在训练受试者数据上能够取得较好的识别效果，但在实际部署过程中，模型往往需要面对未参与训练的新受试者。由于不同受试者在身体结构、动作习惯以及设备佩戴方式等方面存在差异，同一活动在不同个体上的多模态信号分布可能并不一致，从而导致模型在跨受试者场景下出现性能下降。如何缓解由个体差异引起的特征分布偏移，使模型在未见受试者上仍保持稳定识别能力，是多模态人体活动识别中的关键问题之一。

从相关研究的发展来看，跨受试者泛化已经从传统的迁移学习逐步扩展到少样本迁移、元学习增强、源自由知识迁移、零样本识别以及语言模型引导语义对齐等多种范式^[6-7,22-25]。然而，现有方法大多面向单一惯性模态或跨数据集设定，对 IMU 与 WiFi CSI 的异构双模态场景关注相对不足；同时，如何在少量目标受试者标注样本条件下，兼顾类别语义一致性与参数高效适配，仍有进一步研究空间。

基于此，本文提出基于类别原型的跨受试者适配策略，通过“类别原型约束”和“参数高效微调”两个环节提升模型对目标受试者的适应能力。前者旨在从类别语义层面约束不同受试者之间的特征表示，使同类活动在共享特征空间中保持更高一致性；后者则在少量标注样本条件下，以较低参数更新代价实现对目标受试者分布的快速适配。两者相互配合，使模型既能够保留源受试者数据中学到的稳定判别知识，又能够针对新受试者的个体特征进行适度调整。

具体而言，在源阶段训练完成后，首先利用源受试者训练数据构建各活动类别的原型表示。设融合特征空间中的第 i 个样本特征向量为 $z_i \in \mathbb{R}^D$ ，则类别 c 的原型向量定义为该类别所有样本特征的均值：

$$p_c = \frac{1}{N_c} \sum_{i=1}^{N_c} z_i, \quad (3-25)$$

其中， N_c 表示类别 c 的样本数量， $p_c \in \mathbb{R}^D$ 。该原型向量刻画了源受试者数据中对应活动类别的中心语义位置，可作为后续目标受试者适配时的类别参照。

在目标受试者适配阶段，首先引入类别原型约束，以减小目标受试者特征与源受试者类别原型之间的分布差异。对于目标受试者的单个样本特征向量 $z_t \in \mathbb{R}^D$ ，本文采用余弦相似度定义类别原型约束损失：

$$L_{proto} = 1 - \cos(z_t, p_c), \quad (3-26)$$

其中， $\cos(\cdot, \cdot)$ 表示余弦相似度函数， $p_c \in \mathbb{R}^D$ 为对应类别的源域原型。通过最小化该损失，可以促使目标受试者样本向其所属类别的原型中心靠拢，从而增强不同受试者之间同类活动特征表示的一致性，降低个体差异带来的分布偏移。

仅依赖类别原型约束仍不足以充分适应目标受试者的个体特征分布。考虑到目标

阶段通常只能获得少量标注样本，若直接对整个网络进行微调，容易引发过拟合，并破坏模型在源阶段学到的稳定表示。为此，本文进一步引入参数高效微调策略，如图 3-5 所示，在冻结主干网络参数的基础上，仅更新轻量化 Adapter 模块及分类层参数，以较小的训练代价实现对目标受试者的快速适配。




图 3-5 基于瓶颈残差结构的 Adapter 模块示意图

具体而言，设融合后的输入特征表示为 $Z \in \mathbb{R}^{B \times D}$ ，其中 B 表示批大小， D 表示特征维度， r 表示降维系数。Adapter 模块首先对输入特征进行层归一化，然后通过下投影、非线性激活、随机失活以及上投影生成增量特征，其过程可表示为

$$\Delta Z = \text{Dropout}(\text{ReLU}(\text{LayerNorm}(Z)W_{\text{down}} + b_{\text{down}}))W_{\text{up}} + b_{\text{up}}, \quad \Delta Z \in \mathbb{R}^{B \times D}, \quad (3-27)$$

其中， $W_{\text{down}} \in \mathbb{R}^{D \times \frac{D}{r}}$ 和 $b_{\text{down}} \in \mathbb{R}^{\frac{D}{r}}$ 分别表示下投影层的权重与偏置， $W_{\text{up}} \in \mathbb{R}^{\frac{D}{r} \times D}$ 和 $b_{\text{up}} \in \mathbb{R}^D$ 分别表示上投影层的权重与偏置。最终，Adapter 模块通过残差连接输出适配后的特征表示：

$$Z' = Z + \Delta Z. \quad (3-28)$$

上述结构本质上是一种带有预归一化的瓶颈残差适配模块，通过在低维子空间中学习增量表示，实现对目标受试者特征分布的高效修正。由于其仅在低维子空间内学习增量表示，因此参数量远小于直接微调整个主干网络。进一步地，本文对上投影层参数采用零初始化，即初始时刻满足 $W_{\text{up}} = 0$, $b_{\text{up}} = 0$ ，从而使得训练初期有 $\Delta Z \approx 0$, $Z' \approx Z$ 。这意味着 Adapter 在微调开始时不会显著扰动源阶段已经学到的稳定特征表示，而是随着目标受试者数据的引入，逐步学习针对个体差异的补偿项。因此，该结构既能够保留原有主干网络的判别能力，又能够在少量样本条件下实现对目标受试者分布的快速修正。

综合来看，类别原型约束和参数高效微调分别从“类别语义约束”和“个体分布适配”两个层面缓解跨受试者偏移问题。前者通过源域原型为目标受试者提供稳定的类别参照，后者通过少量参数更新实现对新受试者特征分布的快速修正。在两种机制的

协同作用下，模型能够在仅使用少量目标受试者标注样本的条件下完成有效适配，从而提升多模态人体活动识别系统在跨受试者场景中的泛化性能。

3.3 实验与结果分析

3.3.1 实验设置

本研究所有实验均在 Linux 服务器环境下完成。实验平台运行 Ubuntu 24.04.2 LTS 操作系统，服务器配备 Intel Xeon Gold 6530 处理器和 251 GB 系统内存，并搭载 4 块 NVIDIA GeForce RTX 4090 GPU 用于深度学习模型训练。在软件环境方面，实验基于 Python 3.8.20 实现，深度学习框架采用 PyTorch 2.0.1，并结合 CUDA 11.7 实现 GPU 加速计算。

在模型训练过程中，采用 Adam 优化器对网络参数进行更新，初始学习率设置为 1×10^{-4} ，权重衰减系数为 1×10^{-4} 。模型最大训练轮数设置为 300，早停轮数设置为 30，批大小设置为 512。本文采用滑动窗口方式对原始数据进行分割，将连续时间序列数据转换为模型输入样本，其中，窗口长度设置为 1 s，滑动步长设置为 0.5 s。

3.3.2 数据集与划分策略

1) 数据集

本文实验采用 XRFV2 数据集。该数据集面向室内连续人体活动理解任务，包含 WiFi CSI 与 IMU 两种模态数据，能够较好反映真实生活环境中的日常活动过程。该数据集采集于餐厅、书房和卧室 3 个典型室内场景。每个场景均部署 1 个发射器和 3 个接收器组成的 WiFi 系统，以约 200 packets/s 的速率采集 CSI 数据，并采用 WiFi CSI Tool 从 30 个 OFDM 子载波中提取幅度与相位信息，单个时间步的 CSI 特征维度为 540。与此同时，志愿者均佩戴 5 个 IMU 设备，包括双手表、双手机和一副智能眼镜。每个设备均记录三轴加速度与三轴角速度数据，因此 IMU 数据可表示为 $T \times 5 \times 6$ 的时序形式。该数据集共包含 16 名志愿者、30 类日常活动，总时长约 16 小时。

在此基础上，本文进一步对 XRFV2 数据集的活动类别分布进行了统计分析。如图 3-6 所示，各活动类别在总时长和样本数量上存在一定差异：部分高频活动占比较高，而部分活动样本相对较少，呈现出较为明显的长尾分布特征。该分布特性容易导致模型在训练过程中偏向高频类别，从而削弱对低频类别的识别能力，并影响模型的泛化性能。因此，在基于该数据集开展实验时，需要采取相应措施以缓解类别不平衡问题带来的影响。

2) 划分策略

为系统评估所提出方法在不同应用条件下的性能与泛化能力，本文采用了三种数据集划分策略，分别对应同分布条件、跨受试者条件以及跨场景条件。

在同分布条件下，采用标准随机划分方式，将完整数据集按照 80% 与 20% 的比例划分为训练集与测试集。具体划分方式如图 3-7 所示，各类活动数据在训练集与测试集中均有分布，且训练与测试样本来源于相同的受试者与采集场景，仅在样本层面进行




图 3-6 活动时长分布

随机划分。因此，训练集与测试集在统计分布上保持一致，该实验条件主要用于评估模型在理想情况下的性能表现，可视为方法性能的上限参考。




图 3-7 标准数据集划分

在跨受试者条件下，采用留一受试者策略进行数据划分，其划分方式如图 3-8 所示。具体而言，在每一轮实验中，选取一个受试者的数据用于模型测试，其余受试者的数据用于模型训练。该划分方式保证训练集与测试集在受试者层面完全不重叠，从而引入由个体差异带来的分布偏移。

在跨场景条件下，采用留一场景策略进行数据划分，其划分方式如图 3-9 所示。具体而言，在每一轮实验中，选取一个场景的数据作为测试集，其余场景的数据用于模型训练。该策略使训练集与测试集在场景层面完全分离，从而引入由空间布局、遮挡关系及无线信号传播特性差异所带来的分布偏移。

需要说明的是，尽管本文在数据组织层面给出了跨场景划分方式，以完整说明 XRFV2 数据集在不同泛化设定下的使用形式，但第三章并未进一步开展对应的跨场景活动识别实验。其主要原因在于，XRFV2 数据集中三个场景所包含的活动类别集合




图 3-8 跨受试者数据集划分




图 3-9 跨场景数据集划分

并不完全一致，而人体活动识别属于离散类别分类任务，要求训练集与测试集在标签空间上保持一致。若直接采用留一场景方式进行活动识别实验，则测试场景中可能出现训练阶段未覆盖的活动类别，此时实验结果将难以真实反映模型的跨场景泛化能力。因此，第三章的实验分析主要围绕同分分布设置与跨受试者设置展开，而将跨场景划分保留为数据集组织方式的说明。

3.3.3 评价指标

为了全面地评估所提出的人体活动识别模型，本文在总体准确率之外，进一步引入宏平均精确率 (Macro-Precision)、宏平均召回率 (Macro-Recall)、宏平均 F1 值 (Macro-F1) 以及逐类别 F1 值 (Per-class F1) 进行分析。准确率用于衡量模型在测试集上的整体分类性能；宏平均指标用于反映模型在类别层面的均衡识别能力；逐类别 F1 值用于分析模型在不同活动类别上的细粒度识别表现。

1) 准确率

准确率是分类任务中最常用的评价指标之一，其定义为被模型正确分类的样本数占测试样本总数的比例。设测试集中共有 N 个样本，其中被模型正确分类的样本数记为 N_{correct} ，则准确率定义为

$$\text{Accuracy} = \frac{N_{\text{correct}}}{N}. \quad (3-29)$$

其中， N_{correct} 表示预测标签与真实标签一致的样本数量。该指标能够直观反映模型在测试集上的整体分类性能，数值越高，说明模型总体识别效果越好。本文中准确率统一以百分数形式表示。

2) 宏平均指标与逐类别 F1

设分类任务包含 C 个类别。对于第 c 类，记真阳性、假阳性和假阴性样本数量分别为 TP_c 、 FP_c 和 FN_c ，则该类的精确率、召回率和 F1 值分别定义为

$$P_c = \frac{TP_c}{TP_c + FP_c}, \quad R_c = \frac{TP_c}{TP_c + FN_c}, \quad F1_c = \frac{2P_c R_c}{P_c + R_c}. \quad (3-30)$$

其中， P_c 表示第 c 类的精确率， R_c 表示第 c 类的召回率， $F1_c$ 表示第 c 类的 F1 值。在具体实现中，当 $TP_c + FP_c = 0$ 或 $TP_c + FN_c = 0$ 时，相应的精确率或召回率记为 0；当 $P_c + R_c = 0$ 时，对应的 $F1_c$ 亦记为 0。为避免不同宏平均定义带来的歧义，本文采用先逐类计算 F1，再对各类别取算术平均的 Macro-F1 定义。

在此基础上，宏平均精确率、宏平均召回率与宏平均 F1 值分别定义为

$$\text{Macro-Precision} = \frac{1}{C} \sum_{c=1}^C P_c, \quad \text{Macro-Recall} = \frac{1}{C} \sum_{c=1}^C R_c, \quad (3-31)$$

$$\text{Macro-F1} = \frac{1}{C} \sum_{c=1}^C F1_c. \quad (3-32)$$

与准确率相比，宏平均指标对每个类别赋予相同权重，因此能够在类别分布不均衡条件下更客观地反映模型的整体识别能力，避免高频类别对总体指标的过度主导。与此同时，由各类别 $F1_c$ 共同构成的 Per-class F1 结果可以进一步揭示模型在不同活动类别上的识别差异，便于分析哪些动作类别更易被正确识别，哪些类别仍存在较明显的区分困难。本文中宏平均精确率、宏平均召回率、宏平均 F1 值以及逐类别 F1 值也统一以百分数形式表示。

3.3.4 方法对比实验

为系统评估 WIHAR 在多模态人体活动识别任务中的性能，本文选取了多种具有代表性的对比方法作为实验基线。这些方法既包括人体活动识别领域常用的时序建模方法，也包括近年来提出的轻量化方法、多设备方法以及通用时间序列建模骨干网络。

各对比方法说明如下。

Attend and Discriminate (AAD)^[57]: 该方法通过注意力机制增强对关键时序特征的建模能力, 是可穿戴设备人体活动识别任务中的代表性方法之一。

TinyHAR^[58]: 该方法是一种面向轻量化部署的人体活动识别模型, 强调在较低计算开销下实现较好的识别性能, 可作为轻量级 HAR 方法的代表。

HARMamba^[2]: 该方法将双向 Mamba 结构引入可穿戴设备人体活动识别任务, 在长时序建模效率与识别性能之间取得了较好平衡, 可作为基于状态空间模型的代表性 HAR 方法。

PatchHAR^[59]: 该方法基于 patch 划分与 MLP 风格结构进行时序建模, 能够通过局部时序片段表示提升对可穿戴设备序列的特征提取能力。

PatchTST^[60]: 该方法是一种基于 patch 建模思想的 Transformer 时序模型, 原始工作主要面向通用时间序列分析任务。本文将适配到 HAR 任务中, 以比较 patch 化时序建模结构在本任务中的表现。

LightHART^[61]: 该方法是一种轻量化 Transformer 人体活动识别模型, 保持较低模型复杂度的同时提升了时序特征提取能力, 可作为轻量 Transformer 结构的 HAR 基线。

ModernTCN^[62]: 该方法是一种现代时序卷积网络结构, 原始工作主要面向通用时间序列分析任务。本文将适配到 HAR 任务中, 以比较纯卷积时序建模方法与本文方法之间的差异。

DecomposeWHAR^[63]: 该方法面向多设备可穿戴人体活动识别任务, 强调对设备内与设备间时空信号的分解与融合, 因此与本文关注的多模态信息建模问题具有较强相关性。

考虑到上述方法大多主要面向单模态输入, 而本文任务使用的是 IMU 与 WiFi CSI 构成的异构双模态数据, 实验中对所有基线均进行了统一适配: 对于仅支持单路输入的方法, 将两种模态在特征维进行拼接; 对于具备多分支建模能力的方法, 则在保持其核心结构思想不变的前提下完成相应输入适配。随后, 在相同的数据划分、滑动窗口设置、训练轮数及评价指标下对各方法重新训练。因此, 本节比较的重点并非复现原论文在各自数据集上的最优结果, 而是在统一实验条件下考察不同方法的相对建模能力。

各方法在 XRFV2 数据集上的识别结果如表 3-1 所示。总体来看, **WIHAR** 在所有对比方法中均取得了最优结果, 其准确率达到 95.81%, 宏平均 F1、宏平均精确率和宏平均召回率分别达到 95.29%、95.48% 和 95.13%, 均高于其余基线方法。与表现最接近的 **DecomposeWHAR** 相比, **WIHAR** 在准确率上进一步提升了 4.15 个百分点; 与 **PatchHAR**、**AAD** 和 **HARMamba** 相比, 分别提升了 4.45 个百分点、4.70 个百分点和 4.99 个百分点; 相较于 **LightHART**、**PatchTST**、**ModernTCN** 和 **TinyHAR**, **WIHAR** 的性能优势更加明显。

为进一步考察各方法在不同活动类别上的细粒度表现, 图 3-10 给出了 30 个活动类别上各基线方法的逐类 F1 值。从图中可以看出, **WIHAR** 在绝大多数类别上取得了

表 3-1 方法对比实验结果

方法	准确率	宏平均 F1	宏平均精确率	宏平均召回率
AAD ^[57]	91.11	90.96	90.64	91.53
TinyHAR ^[58]	87.70	87.48	87.51	88.18
HARMamba ^[2]	90.82	90.40	91.19	89.84
PatchHAR ^[59]	91.36	91.33	91.20	91.58
PatchTST ^[60]	90.26	90.21	90.27	90.33
LightHART ^[61]	90.01	89.58	89.74	89.57
ModernTCN ^[62]	89.14	88.69	89.06	88.80
DecomposeWHAR ^[63]	91.66	90.95	91.22	90.81
本章方法	95.81	95.29	95.48	95.13

最高的 F1 值，这说明表 3-1 中宏平均 F1 的提升并非来源于少数类别上的局部优势，而是体现在更广泛类别范围内的整体改进。与此同时，不同类别之间的识别难度也存在较明显差异。例如，第 9、10、19、21、23 类等类别上，各方法整体 F1 值普遍较高，表明这些活动的模式相对稳定、区分边界较清晰；而第 5、8、17、25、29 类等类别上，多数基线方法的 F1 值下降更为明显，反映出这些类别在时序模式或跨模态表征上具有更高复杂性，更容易与其他活动产生混淆。进一步地可以发现，在上述相对困难的类别上，WIHAR 仍然保持了较为稳定的识别性能，其 F1 值通常高于其余基线方法，且下降幅度相对更小。这表明 WIHAR 不仅能够提升整体识别精度，也能够类别层面增强模型对复杂活动模式的判别能力。结合总体指标与逐类结果可以认为，本文方法的优势并非仅体现在“容易识别”的类别上，而是在类别分布不均、活动模式存在差异的情况下，仍能够保持较好的类别均衡性与鲁棒性。

为了进一步观察各方法在训练过程中的动态表现，图 3-11 给出了各方法在测试集上的准确率随训练轮数变化的曲线。可以看出，WIHAR 相较于其他方法可以快速收敛，并保持相对平稳的趋势；相比之下，其余方法虽然也能够逐步收敛，但整体收敛速度较慢，且部分方法在训练后期仍存在较明显波动。这表明 WIHAR 不仅在最终识别性能上优于各对比方法，在训练稳定性方面也表现出一定优势。

3.3.5 模型架构与训练策略实验

为了验证 WIHAR 中关键结构设计与训练策略的合理性，本文围绕时序编码骨干网络、模态融合方式、类别权重设计以及跨模态双向对比学习四个方面开展实验分析。其中，骨干网络实验主要用于比较不同时序建模结构对人体活动识别性能的影响；其余实验则用于验证关键模块与训练策略对模型性能提升的具体贡献。

首先，为评估不同时序建模结构对人体活动识别性能的影响，本文将双分支编码器中的主干网络分别替换为 ResNet^[64]、LSTM^[65]、GRU^[66]、Transformer^[47] 和 Mamba^[48]，并保持其余网络结构、训练轮数和优化参数一致。这样可以保证不同结果主要反映时序建模能力差异，而不是来自训练细节或参数设置的变化。实验结果如表 3-2 所示。




图 3-10 各方法在不同活动类别上的 F1 值对比

表 3-2 不同骨干网络的实验结果

骨干网络	准确率	宏平均 F1	宏平均精确率	宏平均召回率
ResNet ^[64]	88.29	87.07	89.25	85.88
LSTM ^[65]	92.49	92.37	92.34	92.43
GRU ^[66]	93.47	93.04	93.00	93.15
Transformer ^[47]	95.25	94.91	94.63	95.36
Mamba ^[48]	95.81	95.29	95.48	95.13

从表 3-2 可以看出，不同骨干网络在活动识别任务中的性能差异较为明显。以卷积结构为代表的 ResNet 表现相对较弱，其准确率、宏平均 F1、宏平均精确率和宏平均召回率分别为 88.29%、87.07%、89.25% 和 85.88%，说明仅依赖局部卷积操作难以充分建模长程时序依赖；引入循环结构后，LSTM 与 GRU 的性能均显著提升，其中 GRU 的准确率和宏平均 F1 分别达到 93.47% 和 93.04%，优于 LSTM 的 92.49% 和 92.37%，表明显式时序建模能够有效增强行为模式表征能力。进一步采用 Transformer 后，模型准确率和宏平均 F1 分别提升至 95.25% 和 94.91%，说明自注意力机制在捕获全局时序依赖方面具有更强优势。在此基础上，本文采用的 Mamba 骨干取得最佳性能，其准确率、宏平均 F1、宏平均精确率和宏平均召回率分别达到 95.81%、95.29%、95.48% 和 95.13%，相较于 Transformer 分别提升 0.56 个百分点和 0.38 个百分点，相较于 GRU 分别提升 2.34 个百分点和 2.25 个百分点。总体来看，随着时序建模能力的增强，模型性能呈现出持续提升的趋势，而 Mamba 在各项指标上均表现最优，因此本文在后续实验中选用其作为默认骨干网络。




图 3-11 各方法活动识别准确率随训练轮数变化曲线

在确定默认时序编码骨干网络后，本文进一步围绕跨模态双向对比学习、交叉注意力机制以及类别权重策略三个关键设计开展消融实验，以验证各模块与训练策略对模型性能的具体贡献。表 3-3 给出了不同消融设置下的实验结果。其中，表中“跨模态双向对比学习”“交叉注意力机制”和“交叉熵损失函数类别权重”分别表示移除对应关键模块或训练策略后的实验结果，“-”表示不进行消融时的完整模型结果。

表 3-3 关键模块与训练策略消融实验结果

消融项	准确率	宏平均 F1	宏平均精确率	宏平均召回率
跨模态双向对比学习	88.92	88.59	87.28	90.39
交叉注意力机制	43.07	36.43	44.87	37.39
交叉熵损失函数类别权重	94.14	94.13	94.31	94.02
-	95.81	95.29	95.48	95.13

从表 3-3 可以看出，跨模态双向对比学习、交叉注意力机制和类别权重策略均对 WIHAR 的最终性能具有积极作用，但其影响程度存在明显差异。完整模型在准确率、宏平均 F1、宏平均精确率和宏平均召回率四项指标上分别达到 95.81%、95.29%、95.48% 和 95.13%，整体表现优于所有消融设置，说明本文所采用的关键模块与训练策略在整体上具有良好的协同作用。

首先，在移除跨模态双向对比学习后，模型准确率下降至 88.92%，宏平均 F1 下降至 88.59%，宏平均精确率和宏平均召回率分别降至 87.28% 和 90.39%。与完整模型相比，准确率和宏平均 F1 分别下降了 6.89 个百分点和 6.70 个百分点。这表明，即使后续仍保留交叉注意力机制进行模态融合，若缺少跨模态双向对比学习所提供的前置语义对齐约束，不同模态特征之间仍可能存在较明显的分布偏差，从而削弱融合表示的判别能力。因此，跨模态双向对比学习并非附加性的辅助约束，而是在异构双模态场

景下保证模态表征一致性的重要组成部分。

其次，在移除交叉注意力机制后，模型性能出现最为明显的下降，准确率仅为 43.07%，宏平均 F1、宏平均精确率和宏平均召回率分别降至 36.43%、44.87% 和 37.39%。与完整模型相比，各项指标均大幅下降，说明交叉注意力机制对本文模型具有关键作用。这一结果表明，在 IMU 与 WiFi CSI 构成的异构双模态场景中，若缺少有效的模态交互机制，模型将难以充分建立两种模态之间的细粒度对应关系，从而影响联合表示的判别能力。相比之下，交叉注意力机制能够以 IMU 特征为查询端，从 WiFi CSI 特征中自适应选择与当前动作状态更相关的信息，因此更有利于挖掘异构模态之间的互补特征。

再次，在移除类别权重策略后，模型准确率由 95.81% 下降至 94.14%，宏平均 F1 由 95.29% 下降至 94.13%，宏平均精确率和宏平均召回率也分别下降至 94.31% 和 94.02%。虽然该消融设置下模型整体性能仍保持在较高水平，但相较于完整模型仍存在稳定下降。这说明类别权重策略在整体框架中起到了有效的训练调节作用。由于 XRFV2 数据集中不同活动类别的数据分布存在不均衡现象，若不对各类别样本在损失计算中的贡献进行区分，模型训练过程更容易受到高频类别主导。引入类别权重策略后，低频类别样本在优化过程中的影响得到增强，从而有助于提升模型在类别层面上的均衡识别能力。

综合来看，WIHAR 的性能优势并非来源于单一模块或单一训练策略的局部改进，而是由时序编码骨干网络、跨模态双向对比学习、交叉注意力机制以及类别权重策略共同作用的结果。其中，Mamba 编码器为模型提供了较强的时序特征建模能力，跨模态双向对比学习增强了异构模态表征的一致性，交叉注意力机制提升了模态间的信息交互能力，而类别权重策略则进一步改善了类别分布不均衡条件下的训练过程。上述结果共同验证了 WIHAR 各组成部分的设计合理性，也说明完整模型中各关键模块与训练策略之间具有较好的协同作用，能够共同提升多模态人体活动识别任务中的整体性能。

3.3.6 样本构建实验

对于时序人体活动识别任务而言，窗口长度和滑动步长并不是简单的数据预处理超参数，而是会直接影响“一个样本包含多少动作信息”以及“相邻样本之间是否足够密集”。因此，本实验的目的，是在识别精度、样本密度和系统响应速度之间找到更合适的平衡点。实验中，本文枚举不同的窗口长度与滑动步长组合，其余训练设置保持不变，结果如图 3-12 所示。

从图 3-12 可以看出，窗口长度和滑动步长对性能的影响都很明显，但二者作用方式不同。首先，在步长固定为 0.5 s 时，随着窗口长度从 1.0 s 增加到 3.0 s，活动识别准确率由 95.81% 逐步提升至 99.79%。这说明更长的时间窗口能够覆盖更完整的动作过程，从而为模型提供更充分的时序上下文。其次，在窗口长度固定为 3.0 s 时，随着步长从 0.5 s 增大到 3.0 s，准确率整体由 99.79% 下降到 93.21%。这表明较小步长带来的




图 3-12 样本构建实验结果

高重叠采样有助于提升样本密度，使模型更容易学习到稳定的动作边界和判别模式。

不过，本文并未直接选择精度最高的 3.0 s/0.5 s 组合作为默认设置。原因在于，该组合虽然能够进一步提高准确率，但也会显著增加观测时延、输入长度和训练开销；对于需要较快响应的人体活动感知系统，过长窗口还可能弱化对动作起止边界的敏感性。相比之下，1.0 s/0.5 s 已经能够达到 95.81% 的准确率，同时具有更低的时延和更好的实时性。基于“精度足够高且响应更及时”的考虑，本文最终将窗口长度设为 1.0 s、滑动步长设为 0.5 s，并以此作为后续实验的默认配置。

3.3.7 模态和设备消融实验

为了分析不同模态与设备在人体活动识别任务中的作用，本节从模态组合与设备构成两个层面对模型进行消融研究。

1) 模态消融实验

为评估不同模态组合对识别性能的影响，本文构建了多种输入配置，包括单模态输入（仅 IMU、仅 WiFi 及其幅度/相位表示）以及多模态融合输入。实验结果如表 3-4 所示。可以看出，多模态融合在各项指标上均优于单模态输入。其中，IMU 与 WiFi 联合输入在准确率和宏平均精确率上取得最优结果，而 IMU 与 WiFi 幅度组合在宏平均 F1 和召回率上略有优势，整体性能差异较小，说明不同融合方式均能够有效提升模型表现。在单模态设置下，仅使用 WiFi 信息时模型仍能维持约 85%–87% 的识别性能，而仅使用 WiFi 相位时性能最低，说明不同 WiFi 表示方式对识别效果存在一定影响。相比之下，WiFi 幅度整体表现优于 WiFi 相位。仅使用 IMU 时模型性能显著下降，准确率

降至 37.13%。这一结果说明，在本文当前网络结构与实验设置下，单一 IMU 模态难以充分支撑 30 类活动识别任务，而引入 WiFi 信息后模型性能显著提升。总体来看，IMU 与 WiFi 模态融合能够显著提升识别性能，说明两种模态在信息表达上具有互补性。

表 3-4 模态消融实验结果

模态 1	模态 2	准确率	宏平均 F1	宏平均精确率	宏平均召回率
IMU	-	37.13	24.00	40.13	22.89
WiFi	-	86.72	86.74	86.67	87.02
WiFi 幅度	-	87.01	87.14	86.54	88.00
WiFi 相位	-	84.93	84.88	85.52	84.57
IMU	WiFi	95.81	95.29	95.48	95.13
IMU	WiFi 幅度	95.41	95.49	95.27	95.77
IMU	WiFi 相位	94.65	94.23	93.85	94.65

2) 设备消融实验

为了进一步分析不同设备对模型性能的影响，本文在完整系统基础上逐一移除单个 IMU 设备或 WiFi 接收节点，并重新训练模型进行评估。实验结果如表 3-5 所示。

表 3-5 设备消融实验结果

设备类型	设备编号	准确率	宏平均 F1	宏平均精确率	宏平均召回率
-	-	95.81	95.29	95.48	95.13
IMU	0	94.99	94.55	94.27	94.96
IMU	1	95.59	95.33	95.60	95.11
IMU	2	94.69	94.52	94.63	94.46
IMU	3	95.57	95.25	95.39	95.16
IMU	4	95.37	95.22	95.18	95.30
WiFi	0	95.52	95.24	95.05	95.50
WiFi	1	94.95	94.72	94.95	94.52
WiFi	2	95.34	95.27	95.05	95.55

从表 3-5 可以看出，在不移除任何设备时模型性能最佳。当移除任意单个设备后，各项指标均出现一定程度下降，说明各设备均对活动识别提供了有效信息。具体来看，在 IMU 设备中，移除 IMU-2 时性能下降最为明显，而移除 IMU-1 或 IMU-3 时性能变化较小，表明不同 IMU 设备对模型性能的影响存在差异。在 WiFi 设备中，移除 WiFi-1 时性能下降最为明显，而移除其他节点时影响相对较小。总体而言，移除单个设备后模型仍能维持较高性能，说明系统对单设备缺失具有一定鲁棒性；而完整设备配置始终取得最优结果，表明多设备融合仍有助于进一步提升模型性能。

3.3.8 跨受试者泛化实验

在实际人体活动识别应用中，模型往往需要推广到未参与训练的新受试者。由于不同受试者在身体结构、动作习惯以及设备佩戴方式等方面存在差异，传感数据的统计特性可能发生变化，从而导致模型在跨受试者场景下的识别性能下降。因此，本节通过跨受试者实验评估所提出方法在新受试者上的泛化能力，并进一步分析少样本条

件下适配策略的效果。

在实验设置中，首先利用训练受试者的数据完成源阶段模型训练，并基于训练数据计算各类别的原型表示。在目标受试者阶段，将每一位未参与训练的志愿者依次视为目标受试者，并逐步增加用于适配的标注样本数量。适配过程中冻结主干网络参数，仅更新轻量化 Adapter 模块及分类层参数，从而实现少样本条件下的快速适配。

表 3-6 给出了不同目标受试者在未进行适配时的初始活动识别准确率，可以看出不同受试者之间存在较明显的性能差异，这也进一步说明跨受试者分布偏移问题的存在。

表 3-6 跨受试者设置下各受试者的实验结果

受试者编号	准确率	宏平均 F1	宏平均精确率	宏平均召回率
0	86.21	79.82	80.26	80.31
1	53.99	45.84	53.68	46.41
2	80.53	72.97	75.67	72.36
3	72.98	69.58	73.93	70.78
4	62.22	55.51	57.30	58.09
5	76.68	69.32	71.59	69.64
6	65.11	59.19	67.34	59.36
7	73.06	67.80	72.73	67.50
8	68.41	64.11	65.39	65.88
9	71.59	65.13	68.83	65.43
10	76.30	70.90	72.54	70.97
11	73.66	66.01	70.41	65.73
12	82.19	77.73	80.00	77.51
13	77.57	73.95	74.46	75.50
14	69.38	61.24	65.95	62.76
15	71.18	70.05	72.71	71.91

图 3-13 展示了不同目标受试者在适配数据时长增加时的活动识别准确率变化。横轴表示用于适配的目标受试者数据时长（单位：s），纵轴表示模型在目标受试者上的活动识别准确率。从图中可以看出，当不使用目标受试者数据进行适配时，模型在不同受试者上的识别准确率存在明显差异，最低约为 56%，最高约为 86%，平均准确率约为 72.57%。随着适配数据时长增加，各受试者的识别准确率整体呈持续上升趋势。当适配数据时长增加到 30–50 s 时，大多数受试者的准确率已提升至 80% 以上；当适配数据时长增加到 100 s 左右时，平均准确率约为 87%；当适配数据时长增加到 120 s 时，平均准确率可进一步提升至约 90.99%。与此同时，不同受试者之间的性能差异也逐步缩小，说明所提出的跨受试者适配策略能够在一定程度上缓解个体间的分布偏移问题。




图 3-13 少样本适配条件下的跨受试者活动识别准确率变化

综合来看，通过类别原型约束与参数高效微调相结合的方式，模型能够在较少标注样本条件下完成对目标受试者的快速适配，并显著提升跨受试者场景下的人体活动识别性能。这表明该策略在低标注成本条件下具有较好的应用潜力和实际价值。

3.4 本章小结

本章围绕多模态人体活动识别任务，基于 XRFV2 数据集提出了融合 IMU 与 WiFi CSI 信息的 WIHAR 方法，并对其关键模块和跨受试者适配策略进行了系统分析。该方法通过双分支 Mamba 编码器提取两种模态的时序特征，在此基础上利用跨模态双向对比学习缩小异构特征之间的语义差异，并通过交叉注意力实现模态间信息交互，最终完成人体活动识别。实验结果表明，所提方法在整体性能、关键结构设计、模态协同效果和跨受试者适配能力等方面均取得了较好的结果，说明多模态对齐与融合能够有效提升复杂室内环境下的人体活动识别性能。

4 基于自回归建模机制的人体姿态重构与预测

本章围绕基于自回归建模机制的人体姿态重构与预测问题展开研究。第 4.1 节首先对任务背景与研究动机进行说明，分析现有基于 IMU 的人体姿态方法主要聚焦于当前姿态重构，而对未来姿态预测关注相对较少；第 4.2 节介绍本文提出的 AIPose 方法，包括整体方法框架、模型组成模块及其自回归建模机制；第 4.3 节通过实验对所提方法进行评估，从方法对比、骨干网络选择、样本构建与数据处理、设备消融、泛化能力以及长时姿态预测等方面分析模型性能；第 4.4 节对本章研究内容进行总结。

4.1 问题描述

人体姿态能够描述人体各关键部位之间的空间关系及其随时间变化的运动过程，因此在人机交互、虚拟现实、运动分析、康复辅助以及远程行为监测等场景中具有重要应用价值。然而，在保证隐私性、可部署性和实时性的前提下准确重构人体姿态，并进一步建模人体运动的未来变化，仍然是人体感知研究中的一个关键问题。




图 4-1 AIPose 方法整体思路示意图

现有基于图像或视频的视觉方法能够直接从图像中检测人体关键点，因此在理想条件下通常可以获得较高精度的姿态估计结果。但在真实场景中，这类方法仍然受到光照、遮挡、视角以及隐私问题的限制，尤其是在卧室等隐私敏感环境中，持续视频采集往往不适合作为长期部署方案。因此，在保证人体运动表达能力的同时，探索更加隐私友好且便于部署的非视觉感知方式具有实际意义。

相比视觉方法，基于 IMU 的感知方案不依赖光照条件，对遮挡不敏感，且设备部署较为灵活，因此在可穿戴人体感知系统中受到广泛关注。IMU 能够高频采集人体局

部运动的加速度与角速度信息，并以时序信号形式反映人体运动的动态变化。近年来，多项工作已尝试利用 IMU 重构人体姿态，这些研究推动了基于 IMU 的人体姿态重构发展，也说明仅依赖少量可穿戴 IMU 设备进行姿态建模具有可行性。进一步地，基于惯性测量设备的人体运动建模研究近年来在远程运动监测、行为约束下的运动学估计以及松散与稀疏惯性运动捕捉等方向持续取得进展^[28-29,33-34]，这表明基于 IMU 的人体运动感知正在从静态重构逐步走向更强调约束建模、真实部署与复杂条件适应的研究阶段。不过，现有多数方法主要关注根据一段 IMU 观测序列重构对应时间范围内的人体姿态，即学习 IMU 信号与当前姿态之间的映射关系，而对未来姿态预测通常缺少显式建模。事实上，人体运动具有明显的时间连续性和动态演化特征，当前姿态不仅反映人体的即时状态，也蕴含着未来运动变化的重要线索。如果仅关注当前姿态重构，而忽略人体运动在时间维度上的发展趋势，则难以完整刻画人体运动过程，也会限制系统在预测与交互场景中的应用能力。与此同时，未来运动预测研究本身也在快速发展，相关方法已经从传统的确定性回归扩展到扰动鲁棒预测、多模态感知预测、在线元适配、长时行为预测以及延迟感知或扩散式预测等范式^[39-41,43-45]。然而，这些工作大多面向视觉输入、通用人体运动序列或更复杂的场景先验建模，直接面向 IMU 输入、并在统一框架下同时实现当前姿态重构与未来姿态预测的方法仍相对不足。

针对上述问题，本文提出一种基于自回归建模机制的人体姿态重构与预测方法 AIPose。该方法以当前 IMU 序列为输入，在统一框架下同时完成当前姿态重构与未来姿态预测。具体而言，模型首先根据当前 IMU 序列恢复对应时间窗口内的人体姿态序列；与此同时，模型进一步预测未来时间段内的 IMU 序列，并将预测得到的未来 IMU 序列与当前 IMU 序列尾部进行拼接，构造扩展 IMU 序列，再基于该扩展 IMU 序列预测未来姿态。通过这种“先预测未来 IMU 序列，再预测未来姿态”的方式，AIPose 将未来姿态预测建立在人体运动动态演化过程之上，从而在同一框架下实现“当前姿态重构 + 未来姿态预测”的联合建模。方法的整体思路如图 4-1 所示。

4.2 方法描述

4.2.1 整体方法框架

AIPose 以当前 IMU 序列为输入，通过时序特征提取、当前姿态重构、未来 IMU 序列预测以及未来姿态预测四个阶段实现人体姿态重构与预测，整体流程如图 4-1 所示，整体架构如图 4-2 所示。

首先，将当前 IMU 序列输入时序特征提取模块，得到表征人体当前运动状态的高层时序特征。在此基础上，模型包含两个相互关联的分支：一条分支用于当前姿态重构，直接根据当前时序特征输出当前时间窗口内的人体姿态序列；另一条分支用于未来 IMU 序列预测，根据当前时序特征生成未来时间段内的 IMU 序列。

在完成未来 IMU 序列预测后，模型将预测得到的未来 IMU 序列与当前 IMU 序列尾部进行拼接，构造扩展 IMU 序列，并基于该扩展 IMU 序列进一步预测未来姿态。因




图 4-2 AIPOSE 模型架构图

此，AIPOSE 将未来姿态预测分解为“未来 IMU 序列预测”和“基于扩展 IMU 序列的未来姿态预测”两个步骤，并通过自回归建模机制将二者连接起来。训练过程中，模型采用当前姿态重构损失、未来 IMU 序列预测损失以及未来姿态预测损失构成的联合目标进行优化，从而同时学习当前姿态恢复与未来运动演化规律。

4.2.2 AIPOSE 模型

在上述整体方法框架基础上，本节进一步介绍 AIPOSE 的具体实现。为便于说明，本文将其划分为 IMU 时序特征提取模块、姿态重构模块、IMU 时序预测模块、自回归建模机制以及损失函数五个部分，下面分别进行介绍。

1) IMU 时序特征提取模块

设输入 IMU 序列为

$$\mathbf{X}_{\text{input}} \in \mathbb{R}^{B \times T \times C},$$

其中 B 表示批次大小， T 表示时间窗口长度， C 表示 IMU 通道数。在此基础上，通过 ResNet 对输入序列进行时序特征提取，得到对应的特征表示

$$\mathbf{F} = E(\mathbf{X}_{\text{input}}),$$

其中 $E(\cdot)$ 表示基于 ResNet 的映射函数。该结构利用一维卷积提取 IMU 信号中的局部动态变化，并通过残差连接增强特征表达的稳定性。得到的特征表示 $\mathbf{F}$ 作为统一的中

间表示，将同时用于当前姿态重构与未来 IMU 预测。

2) 姿态重构模块

在获得 IMU 特征表示 $\mathbf{F}$ 后，首先对当前时间窗口内的人体姿态序列进行建模，其映射关系为

$$\mathbf{P}_{\text{rec}} = f_{\text{rec}}(\mathbf{F}).$$

通过全连接层将特征向量映射到姿态空间，并重构为具有时间结构的姿态序列。设姿态重构窗口长度为 L_{rec} ，关节数量为 K ，单个关节的姿态表示维度为 D_p ，则输出形式为

$$\mathbf{P}_{\text{rec}} \in \mathbb{R}^{B \times L_{\text{rec}} \times K \times D_p}.$$

其中， D_p 的具体取值由姿态表示形式决定。例如，在二维关键点建模任务中， $D_p = 2$ ；在参数化人体姿态建模任务中， D_p 可对应关节旋转表示的维度。

为保证输出数值稳定并与具体任务的数据预处理方式保持一致，重构结果可根据姿态表示形式采用相应的输出约束方式。该模块实现了从 IMU 特征到当前姿态序列的映射，为后续联合建模提供当前时刻的姿态估计结果。

3) IMU 时序预测模块

在完成当前姿态重构的同时，模型还需要基于当前 IMU 序列对应的时序特征，对未来时间段内的 IMU 序列进行预测。该模块整体结构如图 4-3 所示。




图 4-3 基于共享 Transformer 编码器的 IMU 时序预测模块

具体而言，模块首先利用 Transformer 编码器对当前输入特征进行时序建模，得到表征当前运动状态的时序记忆特征；随后，结合目标位置编码与当前时序记忆特征的时间维平均池化结果构造预测查询序列，并再次输入共享参数的 Transformer 编码器，从而生成未来时间窗口对应的 IMU 序列预测结果。该设计使模型能够在保留当前运动上下文的基础上，对未来惯性动态进行建模，为后续自回归姿态预测提供合理输入。

设 IMU 时序特征提取模块输出的特征表示为

$$\mathbf{F} \in \mathbb{R}^{B \times T_f \times D_f}, \quad (4-1)$$

其中, B 表示批大小, T_f 表示特征序列长度, D_f 表示特征维度。首先, 将输入特征映射到隐藏空间并加入对应的位置编码, 得到当前序列的时序记忆特征:

$$\mathbf{M} = \text{Encoder}\left(\mathbf{F}W_{\text{in}} + \mathbf{E}_{\text{pos}}^{(1:T_f)}\right), \quad (4-2)$$

其中, $W_{\text{in}} \in \mathbb{R}^{D_f \times D_h}$ 表示输入投影矩阵, $\mathbf{E}_{\text{pos}}^{(1:T_f)} \in \mathbb{R}^{1 \times T_f \times D_h}$ 表示与输入序列对应的可学习位置编码, D_h 表示隐藏层维度。由此有

$$\mathbf{M} \in \mathbb{R}^{B \times T_f \times D_h}. \quad (4-3)$$

在预测阶段, 模型将未来时间位置编码与当前时序记忆特征的全局上下文相结合, 并通过共享参数的 Transformer 编码器和输出映射层直接得到未来 IMU 序列预测结果, 即

$$\mathbf{X}_{\text{future}} = \text{Encoder}\left(\mathbf{E}_{\text{pos}}^{(1:T_{\text{pred}})} + \text{MeanPool}_T(\mathbf{M})\right)W_{\text{out}} + b_{\text{out}}, \quad (4-4)$$

其中, $\mathbf{E}_{\text{pos}}^{(1:T_{\text{pred}})} \in \mathbb{R}^{1 \times T_{\text{pred}} \times D_h}$ 表示与预测序列对应的可学习位置编码, $W_{\text{out}} \in \mathbb{R}^{D_h \times C}$, $b_{\text{out}} \in \mathbb{R}^C$ 分别表示输出映射层的权重与偏置, C 表示 IMU 通道数。因此有

$$\mathbf{X}_{\text{future}} \in \mathbb{R}^{B \times T_{\text{pred}} \times C}. \quad (4-5)$$

式 (4-4) 表明, 未来 IMU 序列的生成并不是对各时刻进行独立回归, 而是以未来时间位置编码作为时序索引, 并引入 $\text{MeanPool}_T(\mathbf{M})$ 所提供的当前运动状态全局上下文, 在共享参数的 Transformer 编码器中完成未来动态建模。这样既能够区分不同预测时刻, 又能够保持与当前运动模式的一致性, 从而更有效地刻画未来时间窗口内的惯性变化过程。

4) 自回归建模机制

在获得未来 IMU 序列预测结果 $\mathbf{X}_{\text{future}}$ 后, 本文进一步引入自回归建模机制, 以实现未来时间窗口内的人体姿态预测。该机制的核心思想是: 未来姿态并不直接由当前时序特征一次性回归得到, 而是先构造与未来时间段对应的扩展 IMU 序列, 再基于该扩展 IMU 序列进行姿态建模。这样可以使未来姿态预测仍建立在 IMU 时序动态演化过程之上, 从而保持“先预测运动, 再预测姿态”的建模思路。

设当前 IMU 输入序列为

$$\mathbf{X}_{\text{input}} \in \mathbb{R}^{B \times T_{\text{input}} \times C}, \quad (4-6)$$

其中, B 表示批大小, C 表示 IMU 通道数, $T_{\text{input}} = L_{\text{input}}f_{\text{imu}}$ 表示当前 IMU 输入窗口对应的时间步数。设 IMU 时序预测模块输出的未来 IMU 序列预测结果为

$$\mathbf{X}_{\text{future}} \in \mathbb{R}^{B \times T_{\text{pred}} \times C}, \quad (4-7)$$

其中, $T_{\text{pred}} = L_{\text{pred}} f_{\text{imu}}$ 表示未来预测窗口对应的时间步数。

为了使未来姿态预测阶段的输入仍保持连续的时间结构, 本文首先从当前 IMU 输入序列中截取与未来预测阶段相邻的尾部片段:

$$\mathbf{X}_{\text{tail}} = \mathbf{X}_{\text{input}}[:, T_{\text{input}} - T_{\text{pred}} : T_{\text{input}}, :], \quad \mathbf{X}_{\text{tail}} \in \mathbb{R}^{B \times T_{\text{pred}} \times C}. \quad (4-8)$$

在此基础上, 自回归姿态预测过程可统一表示为

$$\mathbf{P}_{\text{pred}} = f_{\text{pred}}(E(\text{Concat}(\mathbf{X}_{\text{tail}}, \mathbf{X}_{\text{future}}))), \quad \mathbf{P}_{\text{pred}} \in \mathbb{R}^{B \times L_{\text{pred}} \times K \times D_p}, \quad (4-9)$$

其中, $\text{Concat}(\cdot, \cdot)$ 表示沿时间维度进行拼接操作, $E(\cdot)$ 表示 IMU 时序特征提取模块, $f_{\text{pred}}(\cdot)$ 表示未来姿态预测映射函数, K 表示关节数量, D_p 表示单个关节的姿态表示维度。由式 (4-9) 可知, 模型首先将当前时刻附近的真实 IMU 观测 $\mathbf{X}_{\text{tail}}$ 与预测得到的未来 IMU 序列 $\mathbf{X}_{\text{future}}$ 拼接为扩展 IMU 序列, 再基于该扩展输入完成未来姿态预测。

可以看出, 该机制并非直接由当前 IMU 时序特征一次性生成未来姿态, 而是先利用当前 IMU 输入预测未来 IMU 序列, 再将当前时刻附近的真实观测与预测得到的未来 IMU 动态组合为扩展 IMU 序列, 最后基于该扩展输入完成未来姿态预测。因此, 未来姿态建模过程始终依赖于 IMU 序列在时间维度上的连续演化关系, 体现了自回归建模“由当前状态递推未来状态”的基本思想。通过这种方式, 模型能够在当前观测基础上, 结合预测得到的未来 IMU 动态信息, 对未来姿态进行连续建模。

5) 损失函数

为实现当前姿态重构、未来 IMU 预测以及未来姿态预测的联合优化, 本文采用多任务学习策略构建整体损失函数。设当前姿态重构结果、未来 IMU 预测结果及未来姿态预测结果分别为 $\mathbf{P}_{\text{rec}}$ 、 $\mathbf{X}_{\text{future}}$ 和 $\mathbf{P}_{\text{pred}}$, 对应的真实值分别为 $\mathbf{P}_{\text{rec}}^*$ 、 $\mathbf{X}_{\text{future}}^*$ 和 $\mathbf{P}_{\text{pred}}^*$, 则整体损失函数定义为

$$\mathcal{L} = \alpha \|\mathbf{P}_{\text{rec}} - \mathbf{P}_{\text{rec}}^*\|_1 + \beta \|\mathbf{X}_{\text{future}} - \mathbf{X}_{\text{future}}^*\|_1 + \gamma \|\mathbf{P}_{\text{pred}} - \mathbf{P}_{\text{pred}}^*\|_1,$$

其中 α 、 β 和 γ 为权重系数, 用于平衡不同子任务对模型训练的影响。

通过上述联合优化, 模型在学习当前姿态重构的同时, 能够建模 IMU 时序动态, 并进一步提升未来姿态预测的准确性。

4.3 实验与结果分析

4.3.1 实验设置

本章实验在与第三章一致的硬件与软件环境下进行。在模型训练过程中，采用 Adam 优化器对网络参数进行更新，初始学习率设置为 1×10^{-3} ，训练轮数为 200，批大小为 256。损失函数采用 L1 损失，并对姿态重构、IMU 序列预测以及未来姿态预测三个子任务分别赋予权重系数 $\alpha = 1$ 、 $\beta = 1$ 和 $\gamma = 1$ 。

在数据构建方面，采用滑动窗口方式对原始时序数据进行划分。IMU 输入窗口长度 L_{input} 为 4s，姿态重构窗口长度 L_{rec} 为 1s，姿态预测窗口长度 L_{pred} 为 1s，滑动步长设置为 1s。对于输入 IMU 数据，本文在输入模型前按通道进行标准化预处理，以提高不同通道输入分布的一致性，从而有利于模型的稳定训练。数据按预设方案划分为训练集与测试集，本文后续各项方法对比、消融分析与泛化实验均在相同测试划分上报告结果，以保证不同设置之间的可比性。

在模型结构设置中，IMU 时序特征提取模块采用 ResNet 结构，IMU 时序预测模块采用 Transformer 结构，其隐藏层维度为 128，层数为 2，注意力头数为 4，Dropout 率为 0.1。模型输出形式根据具体任务进行相应调整：在二维人体姿态建模任务中，单个关节的姿态表示维度取 $D_p = 2$ ，输出二维关键点坐标序列；在参数化人体姿态建模任务中， D_p 对应关节旋转表示的维度，输出参数化姿态序列。

4.3.2 数据集与样本构建

1) 数据集

本章实验采用 XRFV2、DIP-IMU^[67]、AMASS^[68] 和 IMUPoser^[31] 四个数据集。其中，XRFV2 作为本章实验的主要数据集，用于评估所提方法在二维人体姿态重构与预测任务中的性能；DIP-IMU、AMASS 和 IMUPoser 作为补充实验数据集，主要用于考察所提方法及各对比方法在其他 IMU 姿态数据上的适用性。由于第三章已对 XRFV2 数据集的采集设备、场景设置及原始数据结构进行了详细介绍，因此本节不再重复相关内容，而主要结合本章实验需求，对四个数据集作简要说明，并进一步补充 XRFV2 数据集中人体姿态监督信号的构建过程。

XRFV2 是一个面向室内连续人体活动理解的数据集，包含 IMU、WiFi 以及同步视频等多种模态数据。本章主要基于其中的 IMU 数据开展人体姿态重构与预测实验，并利用同步视频信息构建二维人体姿态监督序列。由于该数据集采集于真实室内环境，能够较好反映日常活动中的人体运动过程，因此适合作为本章主体实验的数据基础。

DIP-IMU 是一个典型的真实惯性人体姿态数据集，主要面向稀疏 IMU 条件下的人体姿态估计任务。该数据集由受试者佩戴多个 IMU 设备采集得到，并同步提供对应的人体姿态标签，具有较强的任务针对性。与 XRFV2 上的二维关键点监督不同，DIP-IMU 中的姿态标签采用参数化关节旋转形式表示，因此更适合用于评估模型在惯性姿态建模任务中的表现。本文在该数据集上构建了与主实验一致的滑动窗口样本，用于补充

验证所提方法及各对比方法在真实 IMU 姿态数据上的性能。

AMASS 是一个大规模参数化人体动作数据集，由多个光学动作捕捉数据集统一映射到 SMPL 表示框架后构建而成。该数据集提供了丰富的人体动作参数序列，具有动作类型多样、受试者数量较多和表示形式统一等特点。本文在补充实验中使用 AMASS 数据，以进一步考察不同方法在另一类参数化人体姿态数据上的适用性。由于其姿态表示形式与 DIP-IMU 更为接近，因此该数据集可与 DIP-IMU 共同用于分析模型在参数化姿态建模任务中的表现。

IMUPoser 是一个面向消费级可穿戴设备场景的人体姿态数据集，包含与人体运动同步采集的 IMU 序列及对应姿态标签。与 DIP-IMU 和 AMASS 类似，该数据集中的姿态标签同样采用参数化关节旋转形式表示，因此可用于评估模型在参数化人体姿态建模任务中的表现。相较于前两个补充数据集，IMUPoser 更强调基于日常移动设备进行姿态建模的应用场景，因此本文进一步在该数据集上开展补充实验，以考察所提方法在另一类真实 IMU 姿态数据上的适用性。

表 4-1 对本章涉及的四个数据集进行了对比。

表 4-1 本章使用数据集的对比

数据集	数据规模	姿态标签形式
XRFV2	16 名志愿者，3 个场景，30 类活动	二维关键点序列
DIP-IMU	10 名受试者，64 段序列	参数化关节旋转
AMASS	300 余名受试者，11000 余段序列	参数化关节旋转
IMUPoser	10 名受试者，167 段序列	参数化关节旋转

对于 XRFV2 数据集，本文在已有 IMU 数据基础上，进一步利用同步采集的视频构建人体二维姿态序列作为监督信号。具体而言，本文采用 OpenPose 算法^[69]对视频逐帧提取人体关键点位置，并基于 Body25 模型获得 25 个二维关键点。然而，直接由 OpenPose 提取的二维关键点序列仍存在一定噪声。受遮挡、视角变化及图像质量波动等因素影响，部分关键点在个别帧中可能无法被稳定检测；同时，不同受试者在身高、体型以及与摄像机相对位置上的差异，也会导致姿态关键点在图像坐标系中的位置与尺度存在明显变化。为此，本文对原始姿态序列进行了进一步处理：对于置信度为零的关键点，采用时间上相邻的最近有效关键点进行填补，以保证姿态序列在时间维度上的连续性；同时，为减弱个体差异及拍摄尺度差异的影响，对关键点坐标进行中心化与标准化处理，即以躯干中心关键点 MidHip 作为参考点进行平移，并以左右肩关键点之间的欧氏距离作为尺度因子进行标准化，具体形式为

$$\hat{p}_{i,k} = \tanh \left(\frac{p_{i,k} - p_{i,c}}{\|p_{i,l} - p_{i,r}\|_2} \right), \quad (4-10)$$

其中， $p_{i,k}$ 表示第 i 帧中第 k 个关键点的二维坐标， $p_{i,c}$ 表示该帧的躯干中心关键点坐标， $p_{i,l}$ 与 $p_{i,r}$ 分别表示左肩与右肩关键点坐标， $\|p_{i,l} - p_{i,r}\|_2$ 表示肩宽尺度因子。当肩

宽小于阈值 ε 时, 将其截断为 ε 以避免数值不稳定。图 4-4 展示了姿态处理前后的可视化结果。可以看出, 经过关键点填补、中心化与标准化处理后, 不同样本的人体姿态在坐标范围和尺度上更加一致, 有助于后续模型学习稳定的姿态表示。




图 4-4 姿态中心化与标准化处理示意图

2) 样本构建与划分策略

为了构建适用于人体姿态重构与预测任务的训练样本, 本文以 XRFBV2 数据集为例, 从连续采集的 IMU 序列与姿态序列中提取时间对齐的片段。由于 IMU 与姿态数据的采样频率不同, 因此在样本构建时, 首先基于统一时间轴建立二者之间的对应关系, 再按照固定时间窗口从连续序列中截取样本。设 IMU 时间序列为

$$\mathbf{X} = \{x_1, x_2, \dots, x_T\}, \quad x_t \in \mathbb{R}^C, \quad (4-11)$$

其中, C 表示 IMU 通道数。本文使用 5 个 IMU 设备, 每个设备包含三轴加速度与三轴角速度, 共 6 个通道, 因此 $C = 30$ 。设人体姿态序列为

$$\mathbf{P} = \{p_1, p_2, \dots, p_N\}, \quad p_i \in \mathbb{R}^{K \times 2}, \quad (4-12)$$

其中, $K = 25$ 表示人体关键点数量。

图 4-5 给出了样本构建过程的时间结构示意图。对于任一样本, 其参考时刻 t 表示

该样本时间窗口的结束时刻。以该时刻为参照，本文从连续序列中分别截取当前 IMU 输入序列、未来 IMU 监督序列、当前姿态监督序列以及未来姿态监督序列，从而构建用于姿态重构与预测的监督样本。




图 4-5 样本构建过程时间结构示意图

设 IMU 采样频率为 f_{imu} ，姿态数据帧率为 f_{pose} ，当前 IMU 输入窗口长度为 L_{input} ，当前姿态重构窗口长度为 L_{rec} ，以及未来姿态预测窗口长度 L_{pred} ，三个窗口长度均以秒为单位。在此基础上，样本中各部分定义如下：

$$\mathbf{X}_{input} = \mathbf{X} \left[(t - (L_{input} + L_{pred}))f_{imu} : (t - L_{pred})f_{imu} \right], \quad (4-13)$$

$$\mathbf{X}_{future} = \mathbf{X} \left[(t - L_{pred})f_{imu} : tf_{imu} \right], \quad (4-14)$$

$$\mathbf{P}_{rec} = \mathbf{P} \left[(t - (L_{rec} + L_{pred}))f_{pose} : (t - L_{pred})f_{pose} \right], \quad (4-15)$$

$$\mathbf{P}_{pred} = \mathbf{P} \left[(t - L_{pred})f_{pose} : tf_{pose} \right], \quad (4-16)$$

$$\mathcal{S} = \left\{ \mathbf{X}_{input}, \mathbf{X}_{future}, \mathbf{P}_{rec}, \mathbf{P}_{pred} \right\}. \quad (4-17)$$

其中， $\mathbf{X}_{input}$ 表示当前 IMU 输入序列，用于提供姿态重构与预测的先验信息； $\mathbf{X}_{future}$ 表示与未来姿态预测阶段对应的 IMU 序列； $\mathbf{P}_{rec}$ 表示当前人体姿态序列，用于当前姿态重构任务； $\mathbf{P}_{pred}$ 表示未来人体姿态序列，用于未来姿态预测任务。由此，一个完整样本由上述四个部分共同构成。

在数据集划分策略方面，本章在主体实验中采用与第三章一致的同分布划分方式，并进一步通过跨受试者与跨场景实验评估模型的泛化能力。考虑到不同场景之间在摄像机视角、人体活动区域以及姿态空间分布上存在显著差异，跨场景设置将引入更强

的分布偏移，因此本文将其作为泛化实验进行单独分析，而不作为主要对比实验设置。

4.3.3 评价指标

为全面评估本文方法在人体姿态重构与预测任务中的性能，本文根据不同数据集的姿态表示形式采用不同的评价指标。对于 XRFV2 数据集，由于其监督信号为二维关键点序列，因此主要采用平均关节位置误差（Mean Per Joint Position Error, MPJPE）、关键点正确率（Percentage of Correct Keypoints, PCK）以及逐关节平均位置误差（Per-joint MPJPE）进行评估，其中 MPJPE 与 Per-joint MPJPE 的单位均为像素（px），PCK@5、PCK@10 和 PCK@20 中的阈值也均以像素为单位。对于 DIP-IMU、AMASS 和 IMUPoser 数据集，由于其姿态标签采用参数化关节旋转形式表示，因此进一步采用平均关节角误差（Mean Joint Angle Error, MJAE）和位置误差（Positional Error, PE）进行评估。需要说明的是，在具体实验中，对于本文方法，分别对当前姿态重构结果和未来姿态预测结果计算对应指标，以全面评估模型在重构与预测两个任务上的性能；而对于各对比方法，由于其原始设计主要面向当前姿态估计任务，且未针对本文的未来姿态预测任务进行专门建模，因此本文仅对其当前姿态重构结果计算相应指标。

对于 XRFV2 数据集，本文以二维关键点序列作为姿态监督信号。设预测姿态序列为 $\hat{\mathbf{P}} \in \mathbb{R}^{B \times T \times K \times 2}$ ，真实姿态序列为 $\mathbf{P}$ ，其中 B 表示批大小， T 表示时间长度， K 表示关键点数量。由于模型输出的姿态坐标在标准化空间中表示，因此在计算相关指标之前，需要先将预测结果与真实值映射回同一坐标尺度。具体而言，先对模型输出进行截断处理，将其限制在 $(-0.9999, 0.9999)$ 范围内，以避免后续反变换时出现数值不稳定；随后通过反双曲正切函数 $\text{atanh}(\cdot)$ 将数据从 $\tanh$ 空间映射回连续空间，并结合样本对应的尺度因子恢复关键点坐标，最终计算 MPJPE、PCK 与逐关节 MPJPE。

对于 DIP-IMU、AMASS 和 IMUPoser 数据集，设预测姿态序列为 $\hat{\mathbf{R}} \in \mathbb{R}^{B \times T \times J \times 3}$ ，真实姿态序列为 $\mathbf{R}$ ，其中 J 表示关节数量，姿态采用轴角形式表示。由于该类数据不再以二维关键点为监督信号，因此本文进一步采用 MJAE 和 PE 对模型性能进行评估。

1) MPJPE

MPJPE 定义为

$$\text{MPJPE} = \frac{1}{BTK} \sum_{b=1}^B \sum_{t=1}^T \sum_{k=1}^K \|\hat{p}_{b,t,k} - p_{b,t,k}\|_2. \quad (4-18)$$

其中， $\|\cdot\|_2$ 表示欧氏距离。该指标用于衡量预测关键点与真实关键点之间在图像平面中的平均位置偏差，单位为像素（px）。MPJPE 数值越小，表示模型预测精度越高。

2) PCK

PCK 用于衡量预测关键点是否足够接近真实位置。设关键点判定阈值为 δ_{PCK} ，则 PCK 定义为

$$\text{PCK}(\delta_{\text{PCK}}) = \frac{\left| \left\{ (b, t, k) \mid \|\hat{p}_{b,t,k} - p_{b,t,k}\|_2 \leq \delta_{\text{PCK}} \right\} \right|}{BTK}. \quad (4-19)$$

其中, δ_{PCK} 为在原始图像坐标系下设定的关键点判定阈值, 其单位为像素 (px)。当预测关键点与真实关键点之间的欧氏距离不超过该阈值时, 认为该关键点预测正确。本文在后续实验中统一报告 $\text{PCK}@5$ 、 $\text{PCK}@10$ 和 $\text{PCK}@20$, 其中阈值单位均为像素 (px), 结果统一以百分比 (%) 表示。例如, $\text{PCK}@10$ 表示关键点预测误差不超过 10px 时的占比。 PCK 数值越大表示模型性能越好。

3) Per-joint MPJPE

为进一步分析不同身体部位上的误差分布, 本文对每个关键点分别计算平均关节位置误差。对于第 k 个关键点, 其 Per-joint MPJPE 定义为

$$\text{MPJPE}^{(k)} = \frac{1}{BT} \sum_{b=1}^B \sum_{t=1}^T \|\hat{p}_{b,t,k} - p_{b,t,k}\|_2, \quad k = 1, 2, \dots, K. \quad (4-20)$$

该指标能够反映模型在不同关节部位上的误差差异, 从而更细致地评估模型对不同关键点的建模能力。由于该指标同样在原始图像坐标系下计算, 因此其单位与 MPJPE 一致, 均为像素 (px)。

4) MJAE

MJAE 用于衡量预测关节旋转与真实关节旋转之间的差异。具体而言, 先将预测轴角姿态和真实轴角姿态转换为旋转矩阵, 再计算对应关节的旋转误差角, 并在所有样本、时间步和关节上取平均。设第 j 个关节在时刻 t 的预测旋转矩阵和真实旋转矩阵分别为 $\hat{\mathbf{Q}}_{b,t,j}$ 和 $\mathbf{Q}_{b,t,j}$, 则 MJAE 可表示为

$$\text{MJAE} = \frac{1}{BTJ} \sum_{b=1}^B \sum_{t=1}^T \sum_{j=1}^J \theta(\hat{\mathbf{Q}}_{b,t,j}, \mathbf{Q}_{b,t,j}), \quad (4-21)$$

其中, $\theta(\cdot, \cdot)$ 表示两个旋转矩阵之间的测地角距离。该指标单位为度 (deg), 数值越小表示预测关节旋转越接近真实值。

5) PE

为进一步从空间位置角度衡量预测结果与真实姿态之间的差异, 本文还计算 PE。具体而言, 将预测姿态与真实姿态分别映射为对应的关节位置序列, 再计算各关节之间的欧氏距离并取平均。设预测关节位置序列和真实关节位置序列分别为 $\hat{\mathbf{X}} \in \mathbb{R}^{B \times T \times J \times 3}$ 和 $\mathbf{X} \in \mathbb{R}^{B \times T \times J \times 3}$, 则 PE 定义为

$$\text{PE} = \frac{1}{BTJ} \sum_{b=1}^B \sum_{t=1}^T \sum_{j=1}^J \|\hat{x}_{b,t,j} - x_{b,t,j}\|_2. \quad (4-22)$$

该指标用于衡量预测姿态在空间关节位置层面的整体偏差，单位为厘米（cm），数值越小表示模型性能越好。

4.3.4 方法对比实验

为了系统评估 AIPose 的性能，本文在方法对比实验中分别从主数据集 XRFV2 和补充数据集 DIP-IMU、AMASS 与 IMUPoser 两个层面展开分析。首先，在 XRFV2 数据集上，将所提方法与多种代表性基线方法进行比较，以验证其在二维关键点姿态重构任务中的有效性；进一步地，为考察所提方法及各对比方法在其他 IMU 姿态数据上的表现，本文又在 DIP-IMU、AMASS 与 IMUPoser 数据集上进行了补充对比实验。通过上述两部分实验，可以从不同数据条件和不同姿态表示形式两个角度，对所提方法的性能进行更加全面的评估。

为保证比较的一致性，本文选取了近年来具有代表性的惯性人体姿态方法作为对比对象。这些方法大多面向稀疏 IMU 条件下的人体姿态估计任务，能够从不同角度反映现有惯性姿态建模方法在时序建模、动态约束和实际部署方面的设计思路。具体而言，各对比方法如下。

PIP^[26]：该方法从物理约束角度出发，面向稀疏 IMU 设备条件下的人体运动跟踪任务，是近年来具有代表性的惯性姿态方法之一。

TIP^[27]：该方法将 Transformer 引入惯性人体姿态重构任务，通过时序注意力机制建模 IMU 序列与人体姿态之间的映射关系。

IMUPoser^[31]：该方法利用手机、手表和耳机中的 IMU 进行全身姿态估计，强调消费级移动设备场景下的姿态建模能力。

DynaIP^[35]：该方法从部位级运动动力学建模角度提升稀疏惯性条件下的人体姿态估计性能，具有较强的动态建模特征。

ASIP^[36]：该方法通过序列结构学习与调制机制提升惯性姿态估计的精度与稳定性，是近年来代表性的高精度惯性姿态方法。

MobilePoser^[32]：该方法面向移动消费设备场景下的实时全身姿态估计与人体位移恢复，强调实际部署条件下的实时性与可用性。

需要说明的是，所选基线方法大多原本面向三维人体姿态估计或不同设备配置下的稀疏 IMU 建模任务，且未针对本文所涉及的当前姿态重构与未来姿态预测任务进行专门设计。为了在统一实验设置下进行公平比较，本文在保留各基线核心时序建模模块的基础上，根据不同数据集任务形式对其输出层进行相应调整，并统一采用相同的数据划分原则、训练轮数、优化器及评价方式进行重新训练。因此，本节比较的重点并非复现原论文在其原始任务上的最优结果，而是考察不同时序建模策略在本文任务设置下的相对表现。

1) XRFV2 数据集上的方法对比实验

为了评估 AIPose 在 XRFV2 数据集上的人体姿态重构性能，本文将所提方法与上述多种代表性基线方法进行比较。在该实验中，本文将“当前姿态重构”作为所有方法

共享的对比任务，在保留各基线核心时序建模模块的基础上，仅将输出层替换为与本文一致的二维关键点回归头，并统一采用相同的数据划分、训练轮数、优化器和评价指标进行重新训练。表 4-2 给出了不同方法在当前姿态重构任务中的整体性能比较结果。可以看出，AIPose 在各项评价指标上均取得了最优结果。其中，AIPose 的 MPJPE 为 52.20 px，显著低于所有对比方法；同时，其在 PCK@5、PCK@10 和 PCK@20 上分别达到 16.13%、26.86% 和 44.55%，也均优于其余基线方法。对比方法中，表现相对较好的 PIP 的 MPJPE 为 66.95 px，AIPose 较其降低了 14.75 px；与 ASIP、TIP 和 DynaIP 相比，AIPose 的 MPJPE 也分别降低了 18.72 px、19.84 px 和 23.98 px。相较于 IMUPoser 和 MobilePoser，AIPose 的优势更加明显。上述结果表明，在 XRFV2 任务设置下，AIPose 能够更有效地利用 IMU 时序信息进行人体姿态重构，提升当前姿态重构的整体精度。

表 4-2 不同方法在当前姿态重构任务中的对比结果

方法	MPJPE	PCK@5	PCK@10	PCK@20
PIP ^[26]	66.95	14.41	23.11	38.13
TIP ^[27]	72.04	13.63	21.66	35.91
IMUPoser ^[31]	92.70	9.27	14.62	24.92
DynaIP ^[35]	76.18	13.02	20.25	33.07
ASIP ^[36]	70.92	14.14	22.13	35.83
MobilePoser ^[32]	96.50	9.01	14.01	23.64
本章方法	52.20	16.13	26.86	44.55

为了进一步分析不同方法在各身体部位上的误差分布，图 4-6 展示了不同方法在当前姿态重构任务中的逐关节 MPJPE。可以看出，不同方法在各关键点上的误差分布趋势总体一致：位于躯干中心或靠近身体主干的关键点误差相对较低，而位于四肢末端或头部局部区域的关键点误差则明显较高。这说明在当前任务中，不同身体部位的重构难度存在显著差异。

具体来看，颈部、髋部等靠近身体主干的关键点误差普遍较小，而腕部、踝部、足趾以及眼耳等关键点误差相对较大。造成这一现象的一个重要原因在于，本文仅使用了 5 个 IMU 设备进行姿态建模，设备观测信息相对稀疏。在这种设置下，模型无法直接获得所有身体部位的局部运动信息，而需要根据有限的惯性观测对完整的人体二维关键点进行推断。对于躯干、髋部等靠近人体主干、运动相对稳定且与多设备信息关联更强的部位，模型更容易建立稳定的映射关系；而对于腕部、踝部、足趾等四肢末端关节，其与设备位置通常更远，运动自由度更高，且其姿态变化往往需要通过更长的运动链条进行间接推断，因此误差更容易累积。类似地，眼部、耳部等头部局部关键点不仅空间尺度较小，而且对整体肢体惯性信息的响应不如主干关节直接，因此也表现出较高的重构误差。

在此基础上进一步比较不同方法可以发现，AIPose 在大多数关键点上均取得了更低的误差，且这种优势不仅体现在躯干和近端关节上，在腕部、踝部、足部等高难度关




图 4-6 不同方法在当前姿态重构任务中各关键点的 MPJPE

键点上同样较为明显。这表明，AIPose 的性能提升并非仅来源于少数容易建模的关键点，而是在整体骨架范围内均表现出更好的误差控制能力。结合表 4-2 中的整体结果可以进一步说明，AIPose 能够在稀疏 IMU 条件下更有效地利用时序信息，从而提升对复杂关节和远端关节的姿态建模精度。

除最终性能外，不同方法在训练过程中的优化行为也存在差异。为进一步观察各方法在训练阶段的表现，图 4-7 给出了不同方法在测试集上的姿态重构 MPJPE 随训练轮数变化的曲线。可以看出，AIPose 在训练早期即表现出较快的误差下降速度，并且在后续训练过程中整体收敛更为平稳。相比之下，其余方法虽然也能够随着训练逐步降低误差，但在收敛速度和最终稳定性方面均略逊于 AIPose。该结果说明，AIPose 不仅在最终测试性能上具有优势，而且在训练阶段也表现出较好的优化稳定性与收敛特性。

综上所述，在统一的数据划分、训练设置和评价指标下，AIPose 在 XRFV2 数据集上的当前姿态重构任务中表现出最优的整体性能。无论从整体误差、关键点命中率，还是从逐关节误差分布与训练收敛过程来看，AIPose 均表现出较强的时序建模能力与较好的训练稳定性。这说明所提出方法能够更有效地利用历史 IMU 观测信息，为后续未来姿态预测任务奠定良好基础。




图 4-7 不同方法在当前姿态重构任务中 MPIPE 随训练轮数的变化

2) DIP-IMU、AMASS 与 IMUPoser 数据集上的方法对比实验

为进一步考察所提方法及各对比方法在其他 IMU 姿态数据上的表现，本文在 DIP-IMU、AMASS 和 IMUPoser 三个补充数据集上开展了方法对比实验。与 XRFV2 数据集上的二维关键点姿态建模任务不同，这三组实验主要面向参数化人体姿态建模，并采用平均关节角误差 (MJAE) 和位置误差 (PE) 作为评价指标。需要说明的是，由于各对比方法原始设计主要面向当前姿态估计任务，且未针对本文的未来姿态预测任务进行专门建模，因此表 4-3 中仅统计各方法在当前姿态重构任务上的指标结果。

表 4-3 不同方法在 DIP-IMU、AMASS 与 IMUPoser 数据集上的对比结果

方法	DIP-IMU ^[67]		AMASS ^[68]		IMUPoser ^[31]	
	MJAE	PE	MJAE	PE	MJAE	PE
PIP ^[26]	4.70	4.02	4.16	6.98	5.84	6.15
TIP ^[27]	4.03	3.21	3.21	6.58	5.96	7.88
IMUPoser ^[31]	7.48	6.13	8.25	14.13	8.82	11.30
DynaIP ^[35]	5.11	4.26	5.25	11.19	5.96	6.85
ASIP ^[36]	3.88	3.20	3.09	6.05	5.67	6.94
MobilePoser ^[32]	6.22	4.91	7.35	13.66	8.71	9.89
本章方法	4.76	3.71	5.21	7.04	5.94	6.59

整体来看，不同方法在三个补充数据集上的性能排序表现出一定一致性。ASIP 在 DIP-IMU 和 AMASS 数据集上均取得了最优的当前姿态重构结果，其中在 DIP-IMU 数据集上的 MJAE 和 PE 分别为 3.88,deg 和 3.20,cm，在 AMASS 数据集上分别为 3.09,deg 和 6.05,cm；在 IMUPoser 数据集上，ASIP 取得了最低的 MJAE，而 PIP 取得了最低的

PE。与此同时, TIP 在三个数据集上的结果也相对稳定, 整体处于较优水平; 相比之下, IMUPoser 和 MobilePoser 的误差普遍较大, 说明在本文统一实验设置下, 这类方法对当前姿态重构任务的适应性相对有限。

本文方法在 DIP-IMU、AMASS 和 IMUPoser 数据集上的 MJAE/PE 分别为 4.76,deg/3.71,cm、5.21,deg/7.04,cm 和 5.94,deg/6.59,cm。尽管从当前姿态重构精度来看, 本文方法在三个补充数据集上均未达到最优, 但整体结果保持了较好的稳定性: 在 DIP-IMU 和 AMASS 数据集上均优于 DynaIP、MobilePoser 和 IMUPoser, 在 IMUPoser 数据集上的 MJAE 与 PIP、TIP 和 DynaIP 接近, PE 仅略高于 PIP。上述结果表明, 本文方法虽然并非针对当前姿态重构精度进行单目标优化, 但在不同参数化人体姿态数据上仍表现出较稳定的建模能力, 体现出一定的跨数据集适用性。

进一步对比三个数据集可以发现, AMASS 上各方法的 PE 整体高于 DIP-IMU, 而 IMUPoser 上不同方法之间的 MJAE 差异相对较小。这说明在参数化人体姿态建模任务中, 旋转误差与空间位置误差并不完全同步: 部分方法虽然能够较好地拟合关节旋转参数, 但在映射到空间关节位置后仍可能产生较明显的位置偏差。本文方法同样呈现出类似趋势, 即在 AMASS 数据集上位置误差增大更为明显, 而在 IMUPoser 数据集上则表现出相对均衡的误差水平。这在一定程度上反映出不同数据集在动作类型、设备配置以及空间运动复杂度等方面存在差异, 从而对模型的参数化姿态建模能力提出了不同要求。

需要强调的是, 与这些仅针对当前姿态估计进行建模的对比方法不同, 本文方法在统一框架下不仅能够完成当前姿态重构, 还能够进一步实现未来姿态预测。虽然这一能力未在表 4-3 中直接体现, 但补充实验结果表明, 本文方法在具备未来姿态预测能力的同时, 当前姿态建模性能仍保持较稳定水平。例如, 在 DIP-IMU、AMASS 和 IMUPoser 数据集上, 其未来姿态预测的 MJAE/PE 分别为 4.80,deg/3.79,cm、5.41,deg/7.37,cm 和 6.15,deg/6.79,cm。总体而言, 未来预测误差相较当前重构虽有一定上升, 但增幅仍处于相对可控范围内, 说明所提出的统一建模框架在扩展到未来姿态预测任务后, 仍能够维持较好的当前姿态建模能力。综合来看, 三个补充数据集上的实验结果从另一个角度验证了本文方法在更一般 IMU 姿态建模任务中的适用性, 也说明其在统一框架下兼顾当前姿态重构与未来姿态预测具有一定优势。

4.3.5 骨干网络选择实验

为分析不同时序建模结构对模型性能的影响, 本文基于 XRFV2 主实验数据集设置, 对 IMU 时序预测模块中的骨干网络进行对比实验。在实验中, 固定 IMU 时序特征提取模块为 ResNet 结构^[64], 并分别采用 Transformer^[47]、LSTM^[65]、GRU^[66] 以及 Mamba^[48] 作为 IMU 时序预测模块的骨干网络, 其余训练参数保持一致。在相同训练设置下, 分别评估不同结构在当前姿态重构与未来姿态预测任务中的性能表现。

实验结果如表 4-4 所示。总体来看, 不同时序建模结构对模型性能具有显著影响。综合当前姿态重构与未来姿态预测两类任务的各项指标, Transformer 表现出最优的整

体性能。在未来姿态预测任务中取得最低 MPJPE (57.36 px), 同时在 PCK@5、PCK@10 及 PCK@20 指标上均达到最佳水平 (分别为 16.48%、26.65% 和 43.51%), 表明其在关键点定位精度与预测稳定性方面具有明显优势。相比之下, GRU 在当前姿态重构 MPJPE 上取得最低值 (51.55 px), 略优于 Transformer (52.20 px), 但其在 PCK 指标及未来姿态预测性能上均略逊于 Transformer, 说明其在误差最小化方面具有一定优势, 但整体建模能力稍弱。LSTM 的整体表现介于 GRU 与 Mamba 之间, 在所有指标上均未取得最优结果, 但性能相对稳定。相比之下, Mamba 结构在各项指标上均明显落后, 例如其当前姿态重构 MPJPE 达到 66.90 px, 未来姿态预测 MPJPE 达到 74.05 px, 且对应 PCK 指标也显著低于其他方法, 说明其在当前任务设置下难以有效建模 IMU 时序信息。

表 4-4 不同骨干网络的模型性能比较

骨干网络	当前姿态重构				未来姿态预测			
	MPJPE	PCK@5	PCK@10	PCK@20	MPJPE	PCK@5	PCK@10	PCK@20
GRU	51.55	15.94	26.79	44.69	57.53	16.18	26.26	43.06
LSTM	53.38	15.29	25.62	42.95	59.31	15.69	25.43	41.76
Mamba	66.90	13.18	21.38	35.88	74.05	13.00	20.77	34.58
Transformer	52.20	16.13	26.86	44.55	57.36	16.48	26.65	43.51

综合各项指标可以看出, Transformer 在姿态预测精度与稳定性方面具有最优的综合表现, 而 GRU 在当前重构误差上具有一定优势。整体而言, Transformer 在本任务中的表现更加均衡且稳定, 因此本文最终选用 Transformer 作为 IMU 时序预测模块的骨干网络。

4.3.6 样本构建与数据处理实验

1) 样本构建实验

为分析 IMU 输入序列长度对模型性能的影响, 本文设置不同长度的 IMU 观测窗口进行对比实验。在实验中, 保持模型结构及其他训练参数不变, 仅调整输入 IMU 序列长度, 并分别计算对应的姿态重构误差与姿态预测误差。

实验结果如图 4-8 所示, 从图中可以看出, 随着 IMU 输入长度增加, 模型误差整体呈下降趋势。当输入长度由 1 s 增加到 4 s 时, 姿态重构误差和姿态预测误差均明显下降, 说明适当延长观测窗口有助于模型获得更充分的时序信息。继续增大输入长度时, 模型性能仍有提升, 但改进幅度相对减小, 同时会带来更长的观测时延和更高的计算开销。

2) 数据标准化实验

为分析输入 IMU 标准化对模型性能的影响, 本文进一步设计数据标准化实验。在实验中, 保持模型结构、训练参数及样本构建方式不变, 仅改变输入 IMU 是否经过标准化预处理。具体而言, 一组实验直接使用原始 IMU 数值进行建模, 另一组实验则先对 IMU 各通道数据进行标准化后再输入模型。实验结果如表 4-5 所示。

从整体结果来看, 输入 IMU 标准化处理对模型性能具有显著影响。无论是在当前




图 4-8 样本构建实验结果

表 4-5 不同 IMU 标准化设置下的模型性能比较

IMU 标准化	当前姿态重构				未来姿态预测			
	MPJPE	PCK@5	PCK@10	PCK@20	MPJPE	PCK@5	PCK@10	PCK@20
否	94.75	10.58	16.37	26.84	97.19	10.51	16.00	26.13
是	52.20	16.13	26.86	44.55	57.36	16.48	26.65	43.51

姿态重构任务还是未来姿态预测任务中，采用标准化处理后，模型均取得了更优的结果。在当前姿态重构任务中，进行标准化后 MPJPE 由 94.75 px 降低至 52.20 px，下降了 42.55 px；同时，PCK@5、PCK@10 和 PCK@20 分别由 10.58%、16.37% 和 26.84% 提升至 16.13%、26.86% 和 44.55%。在未来姿态预测任务中，标准化处理同样带来了明显改进，其 MPJPE 由 97.19 px 降低至 57.36 px，下降了 39.83 px；对应的 PCK@5、PCK@10 和 PCK@20 也分别由 10.51%、16.00% 和 26.13% 提升至 16.48%、26.65% 和 43.51%。上述结果表明，对输入 IMU 进行标准化处理不仅能够提升当前姿态重构精度，也能够显著改善未来姿态预测的稳定性与关键点定位能力。造成这一现象的原因在于，原始 IMU 信号的不同通道在数值范围、物理量尺度及波动幅度上通常存在较大差异。例如，加速度与角速度本身属于不同物理量，不同设备、不同轴向之间的取值分布也可能并不一致。若直接使用原始 IMU 数值进行建模，模型在训练过程中需要同时适应不同通道之间的尺度差异，这会增加参数优化难度，并可能削弱对有效时序模式的学习。相比之下，对输入 IMU 数据进行标准化处理后，各通道输入能够被映射到更为一致的数值范围，从而有助于减弱通道间尺度不一致带来的干扰，使模型将更多建模能力集中于人体运动本身对应的动态变化规律。因此，标准化处理能够在一定程度上提升模型

训练稳定性，并改善最终的姿态重构与预测性能。

综合来看，输入 IMU 标准化是本章任务设置中的关键预处理步骤。该处理不仅显著降低了当前姿态重构与未来姿态预测的整体误差，也提升了关键点定位指标表现。因此，本文在后续实验中统一采用标准化后的 IMU 数据作为模型输入。

4.3.7 设备消融实验

为分析不同 IMU 设备在人体姿态重构与预测任务中的贡献，本文设计设备消融实验。在保持模型结构与训练参数一致的前提下，通过移除部分设备输入，考察模型性能变化，从而评估各设备信息对姿态建模的影响。原始输入包含 5 个 IMU 设备（编号为 0 至 4），本文分别构造单设备移除与双设备移除两类实验设置。实验结果如表 4-6 所示。

表 4-6 单设备与双设备消融实验模型性能

消融设置	当前姿态重构				未来姿态预测			
	MPJPE	PCK@5	PCK@10	PCK@20	MPJPE	PCK@5	PCK@10	PCK@20
0	51.63	15.75	26.47	44.30	58.43	16.01	26.01	42.80
1	51.76	16.05	27.01	44.85	57.71	16.28	26.45	43.33
2	50.70	16.23	27.27	45.34	57.33	16.35	26.61	43.61
3	51.90	15.74	26.51	44.37	58.06	15.96	25.92	42.66
4	50.82	15.89	26.82	44.73	57.33	16.13	26.18	42.91
0,1	52.88	15.13	25.59	43.13	59.74	15.39	25.09	41.53
0,2	55.37	15.38	25.66	42.81	63.77	15.69	25.25	41.19
0,3	54.39	15.08	25.22	42.42	61.53	15.11	24.50	40.53
0,4	53.17	15.34	25.65	43.02	60.65	15.48	25.01	41.12
1,2	52.51	15.57	26.22	43.96	59.15	15.93	25.82	42.34
1,3	52.80	15.65	26.23	43.82	59.29	15.85	25.57	41.86
1,4	51.85	15.72	26.51	44.47	58.67	15.86	25.80	42.39
2,3	52.27	15.49	25.99	43.53	59.26	15.64	25.32	41.63
2,4	51.91	15.50	26.23	44.15	58.49	15.65	25.53	42.18
3,4	51.97	15.30	25.76	43.31	59.38	15.35	24.93	41.30
-	52.20	16.13	26.86	44.55	57.36	16.48	26.65	43.51

从单设备消融结果来看，移除不同设备后模型性能存在一定差异，但整体波动幅度较小，说明模型在单一设备缺失情况下仍具有一定鲁棒性。其中，移除编号为 2 的设备时，当前姿态重构 MPJPE 最低，为 50.70 px，且在当前姿态重构的 PCK@5、PCK@10 和 PCK@20 指标上均取得该组实验中的最高值，分别为 16.23%、27.27% 和 45.34%；但从完整输入结果来看，模型在部分未来姿态预测 PCK 指标上仍以全部设备输入时表现最佳。移除编号为 4 的设备时性能与之接近。相比之下，移除编号为 0 或 3 的设备时，模型误差相对较高，例如移除编号为 0 时未来姿态预测 MPJPE 为 58.43 px，移除编号为 3 时当前姿态重构 MPJPE 为 51.90 px。上述结果表明，不同设备对模型性能的贡献存在差异，其中部分设备（如 0 和 3）对姿态建模更为关键，而另一些设备（如 2 和 4）在信息上可能与其他设备存在一定冗余。

进一步分析双设备消融结果可以发现，当同时移除两个设备时，模型性能整体呈现下降趋势。相较于单设备消融，双设备消融下 MPJPE 整体增大，而各项 PCK 指标均有所降低，说明多设备信息融合对于提升模型性能具有重要作用。在具体组合上，不同设备对的影响程度存在明显差异。例如，移除组合 (0,2) 时模型性能下降最为明显，当前姿态重构 MPJPE 上升至 55.37 px，未来姿态预测 MPJPE 达到 63.77 px；移除组合 (0,3) 与 (0,4) 时误差同样较高。相比之下，移除组合 (1,4)、(2,4) 或 (3,4) 时性能下降幅度相对较小，其中 (1,4) 组合在双设备消融中表现较优。

总体来看，设备消融实验表明：(1) 模型对单个设备缺失具有一定鲁棒性，但不同设备的重要性存在差异；(2) 随着移除设备数量增加，模型性能进一步下降，说明多设备信息融合对姿态重构与预测具有重要意义；(3) 不同设备组合之间存在非均匀影响，表明各设备提供的信息具有一定互补性。在实际应用中，应优先保证关键设备的稳定工作，并尽可能维持多设备输入的完整性，以获得更稳定的姿态建模性能。

4.3.8 泛化实验

为评估所提出模型在不同数据分布下的泛化能力，本文设计跨场景与跨受试者实验。两组实验均采用留一法评估方式，即在训练阶段使用除目标测试集之外的数据进行训练，并在测试阶段仅在未参与训练的数据上进行评估。

通过该设置，可以较好地模拟模型在未知环境或未知用户条件下的实际应用性能，从而更加全面地评估模型的泛化能力。

1) 跨场景实验

为分析模型在不同环境条件下的泛化能力，本文采用留一场景法进行实验。具体而言，每次选取一个场景作为测试集，其余场景数据用于训练，从而评估模型在未见场景上的表现。实验结果如表 4-7 所示，从表中可以看出，模型在不同测试场景下的性能存在一定差异。其中，在“餐厅”与“书房”场景下模型表现相对较好，而在“卧室”场景下误差明显较高。这说明环境变化会对模型性能产生较大影响，不同场景中的空间布局、动作分布以及采集条件差异，都可能影响 IMU 与姿态之间的映射关系。总体来看，尽管跨场景条件下模型性能有所下降，但仍能够保持一定的姿态重构与预测能力，说明所提出方法具备一定的跨环境泛化能力。

表 4-7 跨场景实验模型性能

编号	当前姿态重构				未来姿态预测			
	MPJPE	PCK@5	PCK@10	PCK@20	MPJPE	PCK@5	PCK@10	PCK@20
0	204.38	4.26	5.98	9.25	227.20	4.33	6.04	9.26
1	149.23	3.59	5.29	9.48	157.64	3.62	5.33	9.57
2	140.34	3.82	5.78	9.88	144.85	4.04	5.97	10.03
平均值	164.65	3.89	5.68	9.54	176.57	4.00	5.78	9.62

2) 跨受试者实验

为进一步评估模型在不同个体之间的泛化能力, 本文采用留一受试者法进行实验。具体而言, 每次选取一名志愿者作为测试对象, 其余志愿者数据用于训练, 从而评估模型在未见受试者上的表现。实验结果如表 4-8 所示, 从表中可以看出, 模型在不同受试者上的性能存在一定波动, 但整体误差范围相对稳定。部分受试者 (如编号 2、12) 对应的误差较低, 而个别受试者 (如编号 4) 误差相对较高, 这可能与个体运动模式差异、体型差异或设备佩戴方式差异有关。总体而言, 模型在跨受试者条件下能够保持相对稳定的性能, 说明其在不同个体之间具有一定的泛化能力。但与同分布测试相比, 跨受试者实验仍存在明显性能下降, 这也说明个体差异仍是影响 IMU 姿态建模稳定性的关键因素之一。

表 4-8 跨受试者实验模型性能

编号	当前姿态重构				未来姿态预测			
	MPJPE	PCK@5	PCK@10	PCK@20	MPJPE	PCK@5	PCK@10	PCK@20
0	94.32	8.30	12.39	20.12	100.30	8.65	12.65	20.28
1	106.06	5.53	9.12	15.23	113.27	5.56	9.15	15.38
2	89.85	7.74	12.25	21.41	94.82	8.05	12.44	21.02
3	108.81	6.02	9.45	16.59	112.94	6.20	9.55	16.53
4	126.74	5.25	7.57	12.41	138.22	5.48	7.84	12.65
5	104.77	7.44	11.77	20.06	113.25	7.44	11.74	19.88
6	96.79	6.35	11.02	19.67	102.72	6.51	11.07	19.55
7	110.76	7.11	11.54	20.42	120.40	7.69	12.22	21.04
8	116.00	8.04	11.14	17.70	124.32	8.58	11.58	17.96
9	95.69	4.64	9.38	18.19	101.93	4.84	9.65	18.36
10	98.37	7.82	11.81	19.00	104.05	8.00	11.88	18.84
11	104.81	6.72	10.50	17.71	113.36	6.97	10.82	18.00
12	87.90	7.75	12.53	21.09	94.47	7.96	12.64	20.97
13	92.30	6.47	11.33	20.02	99.47	6.76	11.50	19.80
14	105.48	7.25	11.24	19.04	112.43	7.34	11.13	18.50
15	118.60	5.94	10.32	18.35	127.34	6.45	10.59	18.27
平均值	103.58	6.77	10.84	18.56	110.83	7.03	11.03	18.56

4.3.9 长时姿态预测实验

为分析模型在时间维度上的预测性能变化, 本文对不同时间区间内的姿态误差进行统计, 从而评估模型在当前重构与未来预测任务中的表现差异。具体而言, 以当前时间点为参考, 将时间轴划分为多个连续区间, 并分别计算各区间内的平均 MPJPE。其中, 区间 $[-1, 0)$ 表示当前时间窗口内的姿态重构结果, 其余区间表示未来预测时间范围内的姿态预测结果。实验结果如图 4-9 所示。从图中可以看出, 在当前时间窗口内 (即区间 $[-1, 0)$), 模型能够获得较低误差, 说明基于 IMU 特征进行姿态重构具有较高精度。随着时间进入未来预测阶段 ($t \geq 0$), 模型误差随预测时间增加而逐步上升。在较短预测区间内, 误差增长相对平缓; 而在更远时间范围内, 误差增长速度明显加快。

这表明随着预测步长增加，误差会逐渐累积，模型对长期运动变化的刻画能力受到一定限制。总体来看，模型在当前姿态重构任务中表现较为稳定，在短期预测范围内仍具有较好的精度，但在中长期预测中性能逐渐下降。该结果说明，所提出方法更适合短时姿态预测场景，同时也表明预测长度对模型性能具有显著影响。




图 4-9 长时姿态预测实验结果

4.4 本章小结

本章针对基于 IMU 的人体姿态重构与未来短时姿态预测问题，提出了 AIPose 方法。该方法以 IMU 时序信号为输入，在统一框架下同时完成当前姿态重构与未来姿态预测，并通过自回归建模机制实现对人体运动连续演化过程的建模。实验结果表明，AIPose 在 XRFV2 主数据集上的当前姿态重构任务中优于多种代表性惯性姿态方法，同时在未来姿态预测方面也表现出较好性能；在 DIP-IMU、AMASS 与 IMUPoser 等补充数据集上，尽管当前姿态重构精度并未达到最优，但整体性能保持稳定，体现出较好的跨数据集适用性。实验分析进一步说明，IMU 输入窗口长度、时序预测骨干网络、设备配置以及输入标准化策略都会对模型效果产生明显影响。泛化实验表明，模型在跨场景与跨受试者条件下仍具有一定稳定性，但环境变化和个体差异仍会带来性能下降。总体来看，本章验证了基于 IMU 进行人体姿态重构与短时预测的可行性，也为后续人体运动状态建模研究奠定了基础。

5 总结和展望

5.1 总结

本文围绕复杂室内环境下的非视觉人体感知问题，分别从多模态人体活动识别和基于 IMU 的人体姿态重构与预测两个课题展开研究。前者关注 IMU 与 WiFi CSI 异构双模态信息的对齐、融合与跨受试者适配问题，后者关注基于当前 IMU 序列同时实现当前姿态重构与未来姿态预测的问题。两个课题在任务目标和建模方式上各有侧重，但均服务于隐私友好、可部署的人体感知需求，共同构成了本文的主要研究内容。

在多模态人体活动识别课题中，针对单一非视觉模态信息表达有限以及异构模态之间难以有效协同的问题，本文提出了基于多模态对齐与融合的人体活动识别方法 WIHAR。该方法通过双分支 Mamba 时序编码器提取 IMU 与 WiFi CSI 的时序特征，并结合跨模态双向对比学习与交叉注意力机制实现模态对齐与特征融合。在 XRFV2 数据集上的实验结果表明，WIHAR 在各项指标上均优于对比方法，准确率达到 95.81%，宏平均 F1、宏平均精确率和宏平均召回率分别达到 95.29%、95.48% 和 95.13%。进一步的消融实验表明，时序编码骨干、跨模态双向对比学习、交叉注意力机制以及类别权重策略均对模型性能提升具有重要作用。与此同时，本文设计的跨受试者适配策略能够在少量目标受试者标注样本条件下有效提升模型在未见个体上的识别性能，说明该方法具有较好的应用潜力。

在基于 IMU 的人体姿态重构与预测课题中，针对现有方法主要关注当前姿态重构而缺少未来姿态预测能力的问题，本文提出了基于自回归建模机制的人体姿态重构与预测方法 AIPose。该方法以当前 IMU 序列为输入，通过 IMU 时序特征提取模块、姿态重构模块、IMU 时序预测模块以及自回归建模机制，在统一框架下同时实现当前姿态重构与未来姿态预测。实验结果表明，AIPose 在当前姿态重构任务中优于多种代表性惯性姿态方法，其 MPJPE 为 52.20 px，PCK@5px、PCK@10px 和 PCK@20px 分别达到 16.13%、26.86% 和 44.55%；在未来姿态预测任务中，其 MPJPE 为 57.36 px，PCK@5px、PCK@10px 和 PCK@20px 分别达到 16.48%、26.65% 和 43.51%。此外，骨干网络选择、样本构建、输入标准化及传感器消融实验进一步验证了模型设计的合理性，并表明在当前任务设置下，采用 Transformer 作为 IMU 时序预测模块的骨干网络、选择适当的输入窗口长度以及对 IMU 数据进行按通道标准化处理，均有助于提升姿态建模性能。

总体来看，本文从人体活动识别和人体姿态重构与预测两个层面对非视觉人体感知问题进行了系统研究。第三章验证了多模态对齐与融合对于提升复杂室内环境下人体活动识别性能的有效性，第四章验证了基于当前 IMU 序列同时实现当前姿态重构与未来姿态预测的可行性。两部分研究相互衔接，共同表明，基于可穿戴传感器与无线感知信号的非视觉人体感知方法在隐私敏感、光照受限或视觉不适用场景中具有较好

的研究价值与应用前景。

5.2 展望

本文围绕非视觉人体感知中的两个典型任务开展了研究，并在方法设计与实验验证方面取得了一定结果。实验结果表明，本文提出的 WIHAR 和 AIPose 方法在各自任务中均具有较好的有效性，能够为复杂室内环境下的人体活动识别与人体姿态重构与预测提供参考。不过，从整体实验结果来看，本文工作仍存在一定局限，部分性能较弱的实验结果也提示了后续值得进一步深入研究的问题。

一方面，模型的泛化能力仍有待进一步提升。第三章中的跨受试者实验和第四章中的跨受试者、跨场景实验均表明，当受试者、传感器佩戴方式或环境分布发生变化时，模型性能会出现不同程度下降，尤其第四章中的跨场景实验误差增长较为明显。这说明当前方法在同分布条件下能够取得较好效果，但对于分布偏移带来的影响仍较为敏感。后续研究可进一步考虑更强的域不变特征学习、跨模态域对齐或测试时自适应策略，以增强模型在未知个体和未知环境下的稳定性。

另一方面，长时动态建模能力仍然不足。第四章实验表明，AIPose 在短时姿态预测任务中能够取得较好效果，但随着预测时间增长，误差会逐渐累积，模型性能明显下降。同时，从逐关节误差结果来看，腕部、踝部、足趾以及头部局部关键点等远端部位的建模误差仍然较高。这说明当前方法对于长期运动演化规律和复杂关节运动的刻画仍不够充分。后续研究可进一步探索更强的长时序建模方法、多尺度预测策略以及人体结构先验约束，以提升模型对长时动态变化和复杂关节运动的建模能力。

总体而言，本文工作的不足主要体现在跨域泛化能力和长时动态建模能力两个方面。未来可在现有研究基础上，进一步提升模型在复杂分布变化条件下的适应能力，以及对更长时间范围人体运动演化过程的刻画能力，从而推动非视觉人体感知方法向更高精度、更强泛化和更高实用性方向发展。

致 谢

行文至此，本论文的撰写工作已接近尾声，硕士阶段的学习生活也即将告一段落。回顾这段时光，从最初的选题思考，到研究工作的逐步推进，再到论文内容的不断修改与完善，这一路有探索时的迷茫，也有突破后的欣慰；有实验受阻时的压力，也有问题解决后的踏实与平静。硕士阶段的学习与科研经历，不仅让我在专业知识、研究方法和实践能力上得到了锻炼，也让我在不断思考与积累中对坚持、责任和成长有了更加深刻的理解。值此论文完成之际，谨向在这段旅程中给予我帮助、支持和鼓励的人，致以诚挚的感谢。

首先，我想感谢一路坚持下来的自己。科研和论文写作并不是一个轻松的过程，许多问题都需要在反复尝试与不断修改中逐步解决。面对研究中的困难、实验中的不确定性以及写作中的反复打磨，我也曾感到焦虑和困惑，但最终还是选择沉下心来，一步一步向前推进。感谢自己在压力面前没有轻易放弃，在困难面前始终保持耐心，在平凡而重复的积累中不断完成自我调整与成长。正是这些并不轻松却十分真实的经历，让我更加懂得坚持的意义，也让我对未来有了更多信心。

其次，我要衷心感谢我的导师王飞副教授，以及在研究生阶段给予我帮助与支持的老师和同学们。在论文选题、研究设计、实验开展以及论文修改的过程中，导师始终给予我细致耐心的指导和严格认真的要求，使我能够不断理清研究思路、完善研究内容，并顺利完成本论文。导师严谨务实的治学态度和认真负责的工作作风，使我受益良多，也将对我今后的学习和工作产生长久影响。同时，我也要感谢研究生阶段遇到的老师和同学们。老师们在课程学习和科研训练中给予的指导，让我不断夯实基础、拓展视野；同学们在课题讨论、实验交流和日常学习生活中的帮助与陪伴，也为这段忙碌的求学历程增添了许多温暖与力量。

最后，谨以此文为自己的硕士阶段写下一个阶段性的总结。过去的学习与研究经历已经成为我人生中十分宝贵的一部分，它不仅记录了我的努力与成长，也让我更加明确了未来前行的方向。未来，无论是继续在相关领域深入学习，还是走向新的工作岗位，我都会珍惜这段时光所赋予我的积累与历练，继续保持认真踏实的态度和求真务实的精神，在新的起点上不断学习、不断进步，以更加成熟和坚定的姿态迎接未来的挑战。

参考文献

- [1] Miao S, Chen L, Hu R. Spatial-temporal masked autoencoder for multi-device wearable human activity recognition[J]. *Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies*, 2024, 7(4): 1-25.
- [2] Li S, Zhu T, Duan F, et al. HARMamba: Efficient and lightweight wearable sensor human activity recognition based on bidirectional mamba[J]. *IEEE Internet of Things Journal*, 2024, 12(3): 2373-2384.
- [3] Alghamdi F, Alotaibi B, Alqhtani S. A systematic literature review on human activity recognition using smart devices: advances, challenges, and future directions[J/OL]. *Artificial Intelligence Review*, 2025, 58(1): 1-39. DOI: 10.1007/s10462-025-11275-x.
- [4] Bock M, Heller T, Van Laerhoven K. Past, Present, and Future of Sensor-based Human Activity Recognition Using Wearables: A Surveying Tutorial[J/OL]. *Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies*, 2025, 9(2): 1-41. DOI: 10.1145/3729467.
- [5] Nguyen T, Pham M. Improving Human Activity Recognition With Wearable Sensors Through BEE [J/OL]. *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, 2024, 32: 1245-1254. DOI: 10.1109/TNSRE.2024.3378901.
- [6] Zhang W, Liu Y, Chen H. Few-shot transfer learning for wearable IMU-based human activity recognition[J/OL]. *Neural Computing and Applications*, 2024: 1-20. DOI: 10.1007/s00521-024-09645-7.
- [7] Li J, Wang S, Zhang Q. Efficient few-shot human activity recognition via meta-learning and data augmentation[J/OL]. *Neural Computing and Applications*, 2025: 1-25. DOI: 10.1007/s00521-025-11408-x.
- [8] Garcia C, Martinez A. EHUNAM, a WiFi CSI-based dataset for human and machine sensing[J/OL]. *Scientific Data*, 2025, 12(1): 1-16. DOI: 10.1038/s41597-025-06238-4.
- [9] Varga D, Toth Z. A CSI Dataset for Wireless Human Sensing on 80 MHz Wi-Fi Channels[J/OL]. *IEEE Communications Magazine*, 2023, 61(4): 82-88. DOI: 10.1109/MCOM.005.2200720.
- [10] Pham Q, Nguyen L. Wi-Fi sensing based person identification and activity recognition using two-phase deep learning[J/OL]. *Engineering Applications of Artificial Intelligence*, 2024, 130: 107768. DOI: 10.1016/j.engappai.2024.107768.
- [11] Li M, Wang J. WiSigPro: Transformer for elevating CSI-based human activity recognition[J/OL]. *Expert Systems with Applications*, 2024, 238: 121890. DOI: 10.1016/j.eswa.2024.121890.
- [12] Zhang F, Liu C. WiMANS: A Benchmark Dataset for WiFi-based Multi-user Activity Sensing[C/OL] //European Conference on Computer Vision (ECCV). Springer, 2024: 1-20. DOI: 10.1007/978-3-031-73465-8_58.
- [13] Kiss P, Nagy M. Time matters: Empirical insights into temporal generalization in CSI-based Wi-Fi sensing[J/OL]. *Internet of Things*, 2025, 26: 100987. DOI: 10.1016/j.iot.2025.100987.
- [14] Gao Z, Wang Y, Chen J, et al. MMTSA: Multi-modal temporal segment attention network for efficient human activity recognition[J]. *Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies*, 2023, 7(3): 1-26.

-
- [15] Pratama A, Lavric A. Bringing it all together: Wearable data fusion[J/OL]. npj Digital Medicine, 2023, 6(1): 1-9. DOI: 10.1038/s41746-023-00897-6.
- [16] Chen L, Wang P. Multi-modal lifelog data fusion for improved human activity recognition: A hybrid approach[J/OL]. Information Fusion, 2024, 105: 102345. DOI: 10.1016/j.inffus.2024.102345.
- [17] Liu H, Zhang W. Encoding human activities using multimodal wearable sensory data[J/OL]. Expert Systems with Applications, 2025, 250: 123891. DOI: 10.1016/j.eswa.2024.123891.
- [18] Ahmad I, Li W. HyperHAR: Inter-sensing Device Bilateral Correlations and Hyper-correlations Learning Approach[J/OL]. Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies, 2024, 8(2): 1-24. DOI: 10.1145/3632228.
- [19] Hong Z, Li Z, Zhong S, et al. Crosshar: Generalizing cross-dataset human activity recognition via hierarchical self-supervised pretraining[J]. Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies, 2024, 8(2): 1-26.
- [20] Dai G, Xu H, Yoon H, et al. ContrastSense: Domain-invariant contrastive learning for in-the-wild wearable sensing[J]. Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies, 2024, 8(4): 1-32.
- [21] Zhu G, Zhao D, Li C, et al. MASTER: A multi-modal foundation model for human activity recognition[J]. Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies, 2025, 9(3): 1-26.
- [22] Wang Y, Zhang L. A holistic multi-source transfer learning approach using wearable sensors for personalized daily activity recognition[J/OL]. Complex & Intelligent Systems, 2024: 1-19. DOI: 10.1007/s40747-023-01218-w.
- [23] Yan Z, Tang H, Liu M. IMUZero: Zero-Shot Human Activity Recognition by Language-Based Cross Modality Fusion[J/OL]. Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies, 2025, 9(2): 1-29. DOI: 10.1145/3770669.
- [24] Dai G, Xu H, Yoon H. MobHAR: Source-free Knowledge Transfer for Human Activity Recognition on Mobile Devices[J/OL]. Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies, 2025, 9(2): 1-27. DOI: 10.1145/3770670.
- [25] Yan D, Tang K. Large Language Model-guided Semantic Alignment for Human Activity Recognition [J/OL]. Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies, 2025, 9(2): 1-26. DOI: 10.1145/3770671.
- [26] Yi X, Zhou Y, Habermann M, et al. Physical inertial poser (pip): Physics-aware real-time human motion tracking from sparse inertial sensors[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 13167-13178.
- [27] Jiang Y, Ye Y, Gopinath D, et al. Transformer inertial poser: Real-time human motion reconstruction from sparse imus with simultaneous terrain generation[C]//SIGGRAPH Asia 2022 Conference Papers. 2022: 1-9.
- [28] Brown M, Davis S. A wearable sensor and framework for accurate remote monitoring of human motion[J/OL]. Communications Engineering, 2024, 3(1): 1-13. DOI: 10.1038/s44172-024-00168-6.
- [29] Kim M, Lee S. Learning-based 3D human kinematics estimation using behavioral constraints[J/OL]. Nature Communications, 2025, 16(1): 1-15. DOI: 10.1038/s41467-025-58624-6.
- [30] 张明李华王强. 基于人体和场景上下文的多人 3D 姿态估计[J/OL]. 软件学报, 2024, 35(4): 1680-

1696. DOI: 10.13328/j.cnki.jos.2024.6837.
- [31] Mollyn V, Arakawa R, Goel M, et al. Imuposer: Full-body pose estimation using imus in phones, watches, and earbuds[C]//Proceedings of the 2023 CHI Conference on Human Factors in Computing Systems. 2023: 1-12.
 - [32] Xu V, Gao C, Hoffmann H, et al. Mobileposer: Real-time full-body pose estimation and 3d human translation from imus in mobile consumer devices[C]//Proceedings of the 37th Annual ACM Symposium on User Interface Software and Technology. 2024: 1-11.
 - [33] Park J, Cho H. Human Motion Capture from Loose and Sparse Inertial Sensors with Garment-aware Diffusion Models[C/OL]//International Joint Conference on Artificial Intelligence (IJCAI). IJCAI, 2025: 1235-1243. DOI: 10.24963/ijcai.2025.135.
 - [34] Habermann M, Xu P. Ultra Inertial Poser: Scalable Motion Capture from Sparse Inertial Sensors and Ultra-Wideband Ranging[J/OL]. ACM Transactions on Graphics, 2024, 43(4): 1-17. DOI: 10.1145/3658152.
 - [35] Zhang Y, Xia S, Chu L, et al. Dynamic inertial poser (dynaip): Part-based motion dynamics learning for enhanced human pose estimation with sparse inertial sensors[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 1889-1899.
 - [36] Wu Y, Wang C, Yin L, et al. Accurate and steady inertial pose estimation through sequence structure learning and modulation[J]. Advances in Neural Information Processing Systems, 2024, 37: 42468-42493.
 - [37] Van Wouwe T, Lee S, Falisse A, et al. Diffusionposer: Real-time human motion reconstruction from arbitrary sparse sensors using autoregressive diffusion[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 2513-2523.
 - [38] Chen L H, Zhang J, Li Y, et al. Humanmac: Masked motion completion for human motion prediction [C]//Proceedings of the IEEE/CVF international conference on computer vision. 2023: 9544-9555.
 - [39] Yue X, Wang J. Human Motion Prediction Under Unexpected Perturbation[C/OL]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2024: 6790-6799. DOI: 10.1109/CVPR52729.2024.00690.
 - [40] Lou Y, Zhang H. Multimodal Sense-Informed Forecasting of 3D Human Motions[C/OL]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2024: 5679-5688. DOI: 10.1109/CVPR52729.2024.00581.
 - [41] Sun W, Li J. MoML: Online Meta Adaptation for 3D Human Motion Prediction[C/OL]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2024: 7891-7899. DOI: 10.1109/CVPR52729.2024.00790.
 - [42] Yan H, Liu Z. Forecasting of 3D Whole-body Human Poses with Grasping Objects[C/OL]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2024: 4568-4577. DOI: 10.1109/CVPR52729.2024.00469.
 - [43] Schwarz M, Gall J. FutureHuman3D: Forecasting Complex Long-Term 3D Human Behavior[C/OL]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2024: 3457-3466. DOI: 10.1109/CVPR52729.2024.00350.
 - [44] Zhao K, Zhang Y. LAL: Enhancing 3D Human Motion Prediction with Latency-aware Auxiliary Learning[C/OL]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR).

- IEEE, 2025: 1235-1244. DOI: 10.1109/CVPR52730.2025.01200.
- [45] Liu P, Wang C. Nonisotropic Gaussian Diffusion for Realistic 3D Human Motion Prediction[C/OL]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2025: 2346-2355. DOI: 10.1109/CVPR52730.2025.02250.
- [46] Yu C, Li W. Vision-Guided Action: Enhancing 3D Human Motion Prediction with Gaze-informed Affordance[C/OL]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2025: 3457-3466. DOI: 10.1109/CVPR52730.2025.03250.
- [47] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [48] Gu A, Dao T. Mamba: Linear-time sequence modeling with selective state spaces[C]//First conference on language modeling. 2024.
- [49] Wilson J, Taylor E. A framework to automatically detect near-falls using a wearable inertial measurement cluster[J/OL]. Communications Engineering, 2024, 3(1): 1-11. DOI: 10.1038/s44172-024-00325-x.
- [50] Varga D. Mitigating data leakage in a wifi csi benchmark for human action recognition[J]. Sensors, 2024, 24(24): 8201.
- [51] Quy T D, Lin C Y, Shih T K. Enhanced human activity recognition using wi-fi sensing: Leveraging phase and amplitude with attention mechanisms[J]. Sensors, 2025, 25(4): 1038.
- [52] 黄伟周明徐亮. 基于细粒度特征融合的部分多模态哈希[J/OL]. 软件学报, 2024, 35(10): 4210-4226. DOI: 10.13328/j.cnki.jos.7076.
- [53] Choi H, Beedu A, Essa I. Multimodal contrastive learning with hard negative sampling for human activity recognition[J]. arXiv preprint arXiv:2309.01262, 2023.
- [54] 刘浩陈静赵伟. 基于多元实体对齐的视觉-语言多模态预训练[J/OL]. 软件学报, 2025, 36(2): 678-694. DOI: 10.13328/j.cnki.jos.7321.
- [55] 王磊孙明李丽. 基于多模态对比学习的代码表征增强预训练方法[J/OL]. 软件学报, 2024, 35(8): 3456-3472. DOI: 10.13328/j.cnki.jos.7016.
- [56] 陈阳吴峰郑涛. 面向跨模态检索的查询感知双重对比学习网络[J/OL]. 软件学报, 2024, 35(9): 3890-3906. DOI: 10.13328/j.cnki.jos.7021.
- [57] Abedin A, Ehsanpour M, Shi Q, et al. Attend and discriminate: Beyond the state-of-the-art for human activity recognition using wearable sensors[J]. Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies, 2021, 5(1): 1-22.
- [58] Zhou Y, Zhao H, Huang Y, et al. Tinyhar: A lightweight deep learning model designed for human activity recognition[C]//Proceedings of the 2022 ACM International Symposium on Wearable Computers. 2022: 89-93.
- [59] Wang S, Zhang L, Wang X, et al. Patchhar: A mlp-like architecture for efficient activity recognition using wearables[J]. IEEE Transactions on Biometrics, Behavior, and Identity Science, 2024, 6(2): 169-181.
- [60] Nie Y, Nguyen N H, Sinthong P, et al. A time series is worth 64 words: Long-term forecasting with transformers[J]. arXiv preprint arXiv:2211.14730, 2022.
- [61] Haque S T, Ni J, Li J, et al. Lighthart: lightweight human activity recognition transformer[C]//International Conference on Pattern Recognition. 2024: 425-441.

- [62] Luo D, Wang X. ModernTCN: A Modern Pure Convolution Structure for General Time Series Analysis.[C]//ICLR. 2024.
- [63] Xie H, Li H, Zheng C, et al. Decomposing and fusing intra-and inter-sensor spatio-temporal signal for multi-sensor wearable human activity recognition[C]//Proceedings of the AAAI Conference on Artificial Intelligence: vol. 39: 13. 2025: 14441-14449.
- [64] He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016.
- [65] Hochreiter S, Schmidhuber J. Long Short-Term Memory[J]. Neural Computation, 1997, 9(8): 1735-1780.
- [66] Cho K, van Merriënboer B, Gulcehre C, et al. Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation[C]//Proceedings of the Conference on Empirical Methods in Natural Language Processing (EMNLP). 2014.
- [67] Huang Y, Kaufmann M, Aksan E, et al. Deep inertial poser: Learning to reconstruct human pose from sparse inertial measurements in real time[J]. ACM Transactions on Graphics (TOG), 2018, 37(6): 1-15.
- [68] Mahmood N, Ghorbani N, Troje N F, et al. AMASS: Archive of motion capture as surface shapes [C]//Proceedings of the IEEE/CVF international conference on computer vision. 2019: 5442-5451.
- [69] Cao Z, Hidalgo G, Simon T, et al. Openpose: Realtime multi-person 2d pose estimation using part affinity fields[J]. IEEE transactions on pattern analysis and machine intelligence, 2019, 43(1): 172-186.

攻读学位期间取得的研究成果

答辩委员会会议决议

答辩委员会表决，一致同意通过论文答辩，并建议授邢立豹软件工程专业工程硕士学位。

常规评阅人名单

本学位论文共接受 7 位专家评审，其中常规评阅人 5 名，名单如下：

XXX	教授	西安交通大学
XXX	教授	西安交通大学
XXX	教授	西安交通大学
XXX	教授	西安交通大学
XXX	教授	西安交通大学

学位论文独创性声明 (1)

本人声明：所呈交的学位论文系在导师指导下本人独立完成的研究成果。文中依法引用他人的成果，均已做出明确标注或得到许可。论文内容未包含法律意义上已属于他人的任何形式的研究成果，也不包含本人已用于其他学位申请的论文或成果。

本人如违反上述声明，愿意承担以下责任和后果：

1. 交回学校授予的学位证书；
2. 学校可在相关媒体上对作者本人的行为进行通报；
3. 本人按照学校规定的方式，对因不当取得学位给学校造成的名誉损害，进行公开道歉。
4. 本人负责因论文成果不实产生的法律纠纷。

论文作者 (签名)： 日期： 年 月 日

学位论文独创性声明 (2)

本人声明：研究生 所提交的本篇学位论文已经本人审阅，确系在本人指导下由该生独立完成的研究成果。

本人如违反上述声明，愿意承担以下责任和后果：

1. 学校可在相关媒体上对本人的失察行为进行通报；
2. 本人按照学校规定的方式，对因失察给学校造成的名誉损害，进行公开道歉。
3. 本人接受学校按照有关规定做出的任何处理。

指导教师 (签名)： 日期： 年 月 日

学位论文知识产权权属声明

我们声明，我们提交的学位论文及相关的职务作品，知识产权归属学校。学校享有以任何方式发表、复制、公开阅览、借阅以及申请专利等权利。学位论文作者离校后，或学位论文导师因故离校后，发表或使用学位论文或与该论文直接相关的学术论文或成果时，署名单位仍然为西安交通大学。

论文作者 (签名)： 日期： 年 月 日

指导教师 (签名)： 日期： 年 月 日

(本声明的版权归西安交通大学所有，未经许可，任何单位及任何个人不得擅自使用)